智能教育系统的神经认知诊断

摘要：认知诊断是智慧教育的一个基本问题，它旨在发现学生对特定知识概念的掌握程度。现有方法通常采用人工设计的函数(如 logistic 函数)来模拟学生做题过程中的学生-试题交互函数，不足以捕获学生与习题之间的复杂关系。在本文中，我们提出了一种通用的神经认知诊断(NeuralCD)框架，该框架用神经网络来学习复杂的学生-试题交互函数，以获得准确、可解释的诊断结果。具体来说，我们将学生和习题映射到特征向量上，并利用多层神经网络来建模它们的交互函数，其中应用单调性假设来确保这两个向量的可解释性。此外，我们通过专一化每个习题所需的概念，提出了 NeuralCD 的两种实现，即使用传统 Q-矩阵的 NeuralCDM 和基于丰富文本内容的改进的 NeuralCDM+。在真实数据集上的大量实验结果表明，NeuralCD 框架具有准确性和可解释性。

1 引言

认知诊断在许多现实世界场景中是一项必要且基本的任务，如游戏(Chen and Joachims 2016)、医疗诊断(Guo et al. 2017)和教育。具体而言，在智慧教育系统中(Anderson 等，2014;Burns et al. 2014)，认知诊断旨在发现学生在学习过程中的状态，如他们对特定知识概念的熟练程度(Liu et al. 2018)。图 1 显示了认知诊断的一个示例。一般来说，学生通常首先选择习题一组习题(如 e1，…，e4)，然后留下他们的回答(如正确或错误)。然后，我们的目标是推断他们对相应概念的实际掌握程度(例如，三角函数)。在实践中，这些诊断报告是必要的，因为它们是提供后续教学服务的基础，如习题推荐和有针对性的教学(Kuh et al. 2011)。

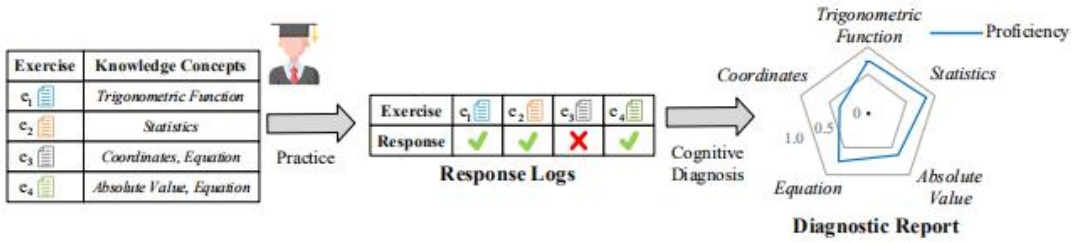

图 1：认知诊断示例。学生选择一些习题进行练习并留下作答结果。通过认知诊断方法，我们得到了包含学生熟练程度的诊断报告。

国内外学者提出了许多认知诊断模型，如确定性输入，噪声与门模型(DINA) (De La Torre 2009)，项目反应理论(IRT) (Embretson and Reise 2013)，多维 IRT (MIRT) (Reckase 2009)和矩阵分解(MF) (Koren, Bell, and V olinsky 2009)。尽管取得了一些效果，但这些工作依赖于人工设计的交互函数，只是将学生和习题的特征进行线性组合，如 logistic 函数(Embretson 和 Reise 2013)或内积(Koren, Bell，和 Volinsky 2009)，这可能不足以捕捉学生和习题之间的复杂关系(DiBello, Roussos，和 Stout 2006 年)。此外，具体的交互函数的设计依赖特定专家领域的经验，通常需要专业的知识。因此，迫切需要找到一种自动学习复杂交互函数的

方法，而不是手工设计它们。在本文中，我们提出了一个神经认知诊断(NeuralCD)框架来解决这个问题：将神经网络集成到复杂的非线性交互模型中。虽然神经网络近似连续函数的能力已经在很多领域得到了证明，如自然语言处理(Zhang et al. 2018)和推荐系统(Song et al. 2019)，但由于以下领域的挑战，要适应认知诊断仍然是非常重要的。首先，神经网络的黑盒特性使得它们很难得到可解释的诊断结果。也就是说，很难明确地得到一个学生对某一知识概念的掌握程度(如方程)。其次，传统的认知诊断模型是人工设计的，具有非神经功能，这使得它们难以利用习题的文本内容。然而，利用神经网络来发掘习题文本内容中所包含的丰富信息对于认知诊断而言十分重要。

为了解决这些挑战，我们提出了一个 NeuralCD 框架来近似学生和习题之间的交互，同时保留了可解释性。我们首先得到学生和习题的特征向量，并利用多层神经网络建模学生回答习题的复杂交互函数。为了确保这两个参数的可解释性，我们应用在多层神经网络上应用了单调性假设 (Reckase 2009)。然后，在总体框架的基础上，提出了 NeuralCDM 和 NeuralCDM+两种实现。在 NeuralCDM 中，我们简单地从传统的 Q-矩阵中提取习题特征向量(如图 6 所示)，并实现了全连接层为正的单调性，这表明了该框架的可行性。而在 NeuralCDM+中，我们演示了如何使用神经网络挖掘习题文本的信息来扩展框架。特别是，我们的 NeuralCD 是一个通用框架，因为它可以涵盖许多传统模型，如 MF, IRT 和 MIRT。最后，我们在真实数据集上进行了大量实验，结果表明，NeuralCD 框架在保证准确性和解释性的前提下是有效的。

2 相关工作

在本节中，我们从以下三个方面简要回顾了相关工作。

认知诊断。现有的关于学生认知诊断的研究主要来自教育心理学领域。DINA (De La Torre 2009;von davvier 2014)和 IRT (Embretson and Reise 2013)是最典型的两个模型，它将学生回答一个习题的结果建模为学生的特征(θ)和习题(β)之间的交互函数。具体来说，在 DINA 中，θ和β是二进制的，其中β直接来自 Q 矩阵(一个人为标记的习题-知识点关联矩阵，如图 6 所示)。另外还考虑了两个习题的参数，即猜测参数和粗心参数(参数化为 g 和 s)。学生 i 答对习题题 j 的概率为 $P(r_{ij}=1|\theta_i) = g_i^{1-\eta_{ij}}(1-s_j)^{\eta_{ij}}$，其中$\eta_{ij}=\prod_k \theta_{ik}^{\beta_{jk}}$。而在 IRT 上，θ和β是连续的、单维的潜在特征，分别代表学生能力和习题难度。参数间的相互作用以逻辑函数的方式建模，例如，一个简单的版本是 sigmoid(a(θ−β))，其中 a 是习题参数。虽然 IRT(Fischer 1995)中增加了额外的参数—潜在特征参数扩展成了 MIRT 模型 (Adams, Wilson, and Wang 1997;Reckase 2009) 。但是大多数交互函数仍然是类逻辑函数形式的。这些传统的模型依赖于人工设计的功能，十分依赖于专家经验，这限制了它们的应用范围。

矩阵分解。近年来，一些关于数据挖掘的研究已经证明了矩阵分解(MF)在认知诊断中的可行性。在矩阵分解(MF)中，学生和习题对应的是用户和项目。例如 Toscher 等(2010)改进了 SVD(奇异值分解)方法来分解分数得分矩阵，得到

学生和习题的潜在特征向量。Thai-Nghe 等人(2010)在教育场景下应用了矩阵分解等推荐系统技术，并将其与传统的回归方法进行了比较。此外，Thai-Nghe 等人(2015)提出了智能辅导系统中学生建模的多元参数分解方法。虽然潜在特征向量在预测学生成绩方面有一定的效果，但在认知诊断方面并不能解释隐性特征向量，即特征向量中的元素与特定知识概念之间没有明确的对应关系。

人工神经网络。使用人工神经网络的技术在许多领域都达到了先进水平，例如语音识别(Chan et al. 2016)，文本分类(Zhang, Zhao, and LeCun 2015)和图像字幕(Wang, Chen, and Hu 2019)。还有一些教育应用，如试题难度预测(Huang et al. 2017)、公式图像转录(Yin et al. 2018)和学生成绩预测(Huang et al. 2019)。然而，利用神经网络进行认知诊断并不是一件简单的事情，因为神经网络的固有特性导致其在参数解释方面表现不佳。据我们所知，深度知识追踪(DKT) (Piech et al. 2015)是第一次尝试使用循环神经网络(RNN)来模拟学生的学习过程。然而，DKT 的目的是预测学生的成绩，并没有区分习题和它所包含的知识概念，因此不适合认知诊断。很少有神经网络的研究对学生认知诊断具有高度的可解释性。为此，本文提出了一种神经认知诊断(NeuralCD)框架，该框架借鉴了教育心理学的概念，并将其与从数据中学到的交互函数相结合。NeuralCD 利用神经网络既能获得较高的准确率，又能实现较高的解释。此外，该框架具有通用性，可以覆盖许多传统模型，同时易于扩展。

3 神经认知诊断

我们首先正式引入认知诊断任务。然后对 NeuralCD 框架进行了详细的描述。然后，我们设计了一个带有传统 Q -矩阵的认知诊断网络 NeuralCDM 来展示框架的可行性，并通过加入习题文本内容来改进 NeuralCDM+以获得更好的性能。最后，我们通过展示 NeuralCD 框架与一些传统模型的密切关系来说明它的通用性。

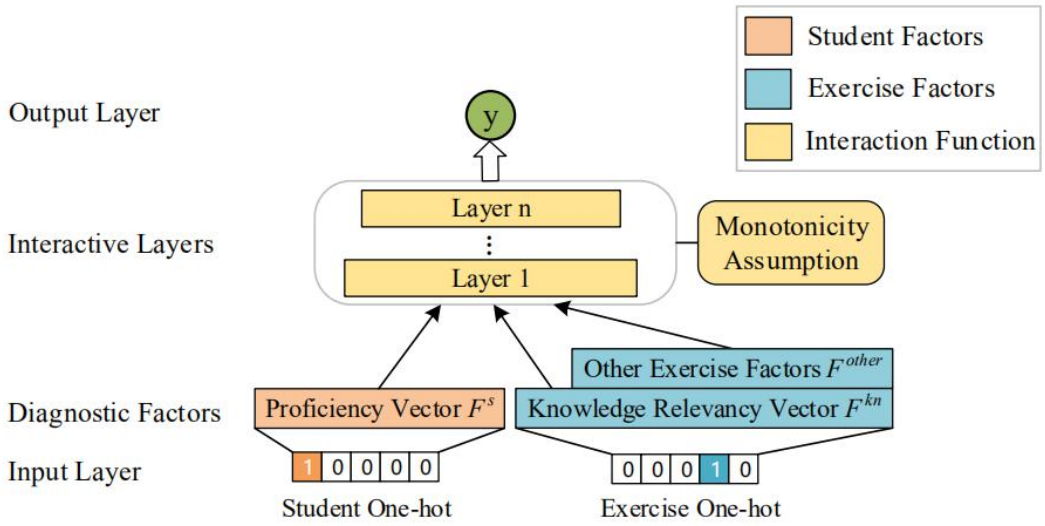

图 2：神经认知诊断框架结构

3.1 任务概述

假设一个学习系统中有 N 个学生，M 个习题，K 个知识概念，可以表示为 $S = \{s_1, s_2,\ldots,s_N\}$， $E = \{e_1, e_2,\ldots,e_M\}$和 $K_n= \{k_1, k_2, \ldots k_K\}$。每个学生将选择一些习题练习,得到试题作答记录 R，R 用三元组数据(s、e、r) 表示,其中 $e\in E$，$s\in S$，r 是学生 s 在习题 e 上的作答得分。此外,我们还需要专家标注的 Q-矩阵(试题-知识点关联矩阵)，$Q = \{Q_{ij}\}_{M\times K}$,其中，如果习题 e_i 与知识概念 k_j 有关，则 $Q_{ij}= 1$，否则 $Q_{ij}= 0$。基于学生的作答记录 R 和 Q 矩阵，我们的认知诊断任务的目标是在预测学生表现的同时挖掘学生对知识概念的熟练程度。

3.2 神经认知诊断框架

一般来说，一个认知诊断系统需要考虑三个方面的参数:学生参数、习题参数以及它们之间的交互函数(DiBello, Roussos, and Stout 2006)。在本文中，我们提出了一个通用的 NeuralCD 框架，使用多层神经网络建模来解决这些问题，如图 2 所示。具体地，我们对每个响应日志使用相应学生和习题的一个热向量，以获得学生和习题的诊断参数。然后交互层学习各参数之间的交互函数，输出正确回答题的概率。训练结束后，我们得到学生的熟练度向量作为诊断结果。具体情况介绍如下。

学生参数：学生参数表征学生的特点，影响学生对习题的反应。由于我们的目标是挖掘学生对知识概念的熟练程度，所以我们没有像 IRT 和 MIRT 那样使用潜在特征向量来指导学生的自我评价。相反，我们把学生参数设计成类似于 DINA 的可解释向量，但有一个主要的区别是它们是连续的。具体来说，我们使用一个向量 F^s 来描述一个学生，即熟练度向量。F^s 的每个元素值都是连续的([0,1])，表明学生对某一知识概念的掌握程度。例如，F^s=[0.9,0.2]表示对第一种知识概念的掌握程度高，而对第二种知识概念的掌握程度低。通过参数估计过程得到 F^s。

习题参数：习题参数是表征习题特征的参数。我们把习题参数分为两类。第一个表明了习题和知识概念之间的关系，这是基本的，因为我们需要它使 F^s 的每个元素对应我们的诊断目标的特定知识概念。我们称之为知识关联向量，表示为 F^{kn}。F^{kn} 的维度与 Fs 相同，第 i 项表示习题与知识概念 k_i 的相关性。F^{kn} 的每一项都是非负的。F^{kn} 事先给出(例如，由 Q 矩阵得到)。其他参数属于第二类，是可选的。在合理的情况下，可以纳入 IRT 和 DINA 的知识难度、习题难度和区分度参数。

交互函数：我们使用人工神经网络来获取交互函数，原因如下。首先，神经网络已经被证明能够近似任何连续函数(Hornik, Stinchcombe, and White 1989)。神经网络具有较强的拟合能力，能够很好地捕捉学生与习题参数之间的关系。第二，使用神经网络，交互函数可以在稀疏数据中学习。这使得 NeuralCD 更加普遍，可以应用于更广泛的领域。第三，该框架具有神经网络的高度可扩展性。例如，额外的信息，如习题文本，可以集成到神经网络中(我们将在下面的小节中讨论它的可扩展性)。从数学上，我们可以将 NeuralCD 框架的输出公式表述为：

$$y = \varphi_n(\ldots\varphi_1(F^s, F^{kn}, F^{other}, \theta_f)) \qquad (1)$$

其中φ_i等同于第 i MLP 层的映射函数;F^{other}指除 F^s 和 F^{kn} 以外的参数(例如:难度参数);θ_f 为各交互层的模型参数。然而，由于一些内在原因，神经网络通常在解释方面表现不佳(Samek et al. 2016)。幸运的是，我们发现在一些 IRT 和 MIRT 模型中使用的单调性假设(Reckase 2009)可以用来确保学生和习题参数的解释性。单调性假设在几乎所有情况下都是通用的，因此它对 NeuralCD 框架的通用性影响不大。假设定义如下:

单调性假设：在学生知识熟练程度的任何维度上，正确回答这个问题的概率都是单调增加的。这个假设应该转换为相互作用函数的一个特性。直觉上，我们假设学生正确回答了习题 e。在训练过程中，如果模型输出错误的预测(即低于 0.5 的值)，优化算法会提高学生的熟练程度。每一种知识熟练度的增加由 F^{kn} 控制。在介绍了 NeuralCD 框架的结构之后，我们接下来将展示一些具体的实现。我们首先设计了一个基于 NeuralCD 的附加习题参数(即知识难度和习题区分度)的诊断模型(§3.3)，并通过整合文本信息(§3.4)进一步展示了它的可扩展性(§3.5)，通过展示它如何覆盖传统模型(§3.5)进一步展示了它的通用性(§3.5)。

3.3 神经认知诊断模型

本文介绍了一种基于 NeuralCD 框架的神经认知诊断模型(NeuralCDM)。图 3 显示了 NeuralCDM 的结构。

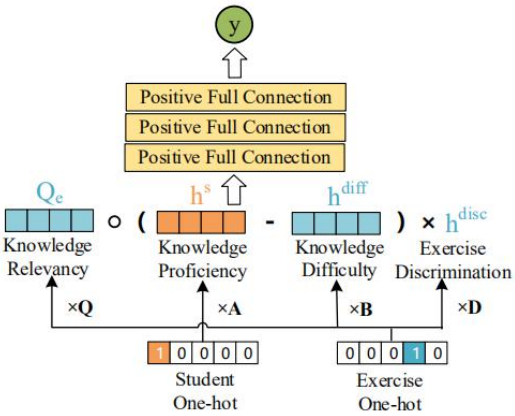

图 3：NeuralCD 模型。橙、蓝、黄分别表示学生参数，习题参数和交互函数

学生参数。在 NeuralCDM 中，每个学生都用一个知识熟练度向量表示。前面提到的学生参数 F^s 等价于 h^s 由，它由学生 one-hot 向量 x^s 与经过训练得到的矩阵 A 相乘得到，即：

$$h^s = sigmoid(x^s \times A) \tag{2}$$

其中，$h^s \in (0,1)^{1\times K}$,$x^s \in \{0,1\}^{1\times N}$, $a \in R^{N\times K}$。

习题参数。对于每个习题，前面提到的习题参数 F_{kn} 现在用 Q_e 表示，它直接来自预先给定的 Q 矩阵:

$$Q_e = x^e \times Q \tag{3}$$

其中 $Q_e \in \{0,1\}^{1\times K}$, $x^e \in \{0,1\}^{1\times M}$,是习题的 one-hot 表示。为了做出更准确的诊断，我们采用了另外两个习题参数:知识难度 h^{diff} 和习题区分度 h^{disc}。$h^{diff} \in (0,1)^{1\times K}$，表示习题所检验的每个知识概念的难度，是由 IRT 中使用的习题难度

扩展而来的。$h^{disc} \in (0,1)$，在一些 IRT 和 MIRT 模型中使用，表示习题能够区分知识掌握程度高的学生和知识掌握程度低的学生。它们可以由(4)(5)式得到：

$$h^{diff} = sigmoid(x^e \times B), B \in R^{M \times K} \tag{4}$$

$$h^{disc} = sigmoid(x^e \times D), D \in R^{M \times 1} \tag{5}$$

其中 B 和 D 是可训练的矩阵。

交互函数。交互层的第一层受到 MIRT 模型的启发。公式为:

$$x = Q_e \circ (h^s - h^{diff}) \times h^{disc} \tag{6}$$

其中∘表示向量的元素对应相乘。下面是两个全连接层和一个输出层:

$$f_1 = \phi(W_1 \times x^T + b_1) \tag{7}$$

$$f_2 = \phi(W_2 \times f_1 + b_2) \tag{8}$$

$$y = \phi(W_3 \times f_2 + b_3) \tag{9}$$

其中φ为激活函数。这里我们使用 Sigmoid。可以采用不同的方法来满足单调性假设。我们采用了一个简单的策略:将 W_1、W_2、W_3 中的每个元素限制为正。不难证明，h^s 中的每个元素的梯度都是正的。因此在训练过程中始终满足单调性假设。NeuralCDM 的损失函数为预测值 y 和标签 r 之间的交叉熵：

$$loss_{CDM} = -\sum (r_i \log y_i + (1 - r_i) \log(1 - y_i)) \tag{10}$$

经过训练，我们得到的 h^s 值作为诊断结果，表示学生的知识熟练程度。

3.4 基于文本信息扩展的神经认知诊断框架

在 NeuralCDM 和一些传统方法(如 DINA)中，Q -矩阵是关于习题知识概念的信息来源。然而，由于不可避免的误差和主观偏见，人工标记的 Q 矩阵可能是不足的(Liu, Xu, and Ying 2012;DiBello, Roussos，Stout　2006)。另一方面，习题文本已被证明与一些习题特征(如难度、相关知识概念)高度相关(Su et al. 2018;Huang et al. 2017)，因此可以利用它来完善 Q 矩阵。例如，在 Q 矩阵中，可能只有“方程”被标记为一个需要方程解决的习题所对应的知识点。然而，我们可能会发现，由于“÷”在文本中存在，所以也需要“除法”。传统的认知模型由于其手工非神经交互函数的限制，没有充分利用文本内容。然而，使用神经网络，我们能够将文本信息纳入我们的框架。我们将扩展模型表示为 NeuralCDM+，其结构如图 4 所示。具体来说，我们首先预先训练 CNN(卷积神经网络)来预测与输入习题相关的知识概念。CNN 在文本处理中具有提取局部信息的优势，能够从文本中捕获重要的单词(例如与特定知识概念高度相关的单词)。该网络以单词在文本中的连接 word2vec 嵌入为输入，将每个预定义知识概念的相关性输出到习题中。以人工标记的 Q 矩阵作为训练标记。我们定义 $V_i^k = \{V_{ij1}, V_{ij1}, ..., V_{ijk}\}$ 为 CNN 输出的习题知识概念的 top-k 集合。

然后 V_i^k 将与 Q 矩阵结合。人为标记的 Q 矩阵虽然存在缺陷，但仍具有很高的可信度。因此，我们认为以 Q -矩阵标记的知识概念相对于 $\{k_j \mid k_j \in V_i^k and Q_{ij} = 0\}$ 中的概念更为相关。为此，我们采用了如下的双贝叶斯方法。为方便起见，我们将部分顺序定义为：

$$a >_i^+ b, if\ Q_{ia} = 1\ and\ Q_{ib} = 0\ b \in V_i^k \tag{11}$$

定义其他的关系集为：$D_V = \{(i,a,b) \mid a >_i^+ b, i = 1,2,...,M\}$。按照传统的贝叶斯处理，我们假设 Q 服从零均值高斯先验，每个维度的标准差是σ。为了给 Q-矩阵标签更高的可信度，我们用类逻辑函数定义 $p(a >_i^+ b \mid \tilde{Q}_i)$:

$$p(a >_i^+ b \mid \tilde{Q}_i) = \frac{1}{1 + e^{-\lambda(\tilde{Q}_{ia} -}} \tag{12}$$

λ参数控制标注与未标注知识概念关联值的区分。$\tilde{Q}$ 相对于 D_V 的对数后验分布为:

$$\begin{aligned} \ln p(\tilde{Q} \mid D_V) &= \ln \prod_{(i,a,b) \in D_V} p(a >_i^+ b \mid \tilde{Q}_i) p(\tilde{Q}_i) \\ &= \sum_{i=1}^{M} \sum_{a=1}^{K} \sum_{b=1}^{K} I(a >_i^+ b) \ln \frac{1}{1 + e^{-\lambda(\tilde{Q}_{ia} -}} \\ &+ C - \sum_{i=1}^{M} \sum_{j=1}^{K} \frac{\tilde{Q}_{ij}^2}{2\sigma^2} \end{aligned} \tag{13}$$

其中 C 是一个常数,在优化时可以忽略。在使用 NeuralCDM 中的 $\tilde{Q}$ 矩阵之前，我们需要将其元素限制在范围(0,1)，并将未标记或未预测的概念元素设置为 0。因此，$sigmoid(\tilde{Q}) \circ M$ 用于替换 NeuralCDM 中的 Q，其中 $M \in \{0,1\}^{M \times K}$ 是一个掩码矩阵，如果 $j \in V_i^k$ 或者 Qij= 1，则 M_{ij}= 1;否则 M_{ij}= 0。我们将 $\tilde{Q}$ 与认知诊断模型一起训练，因此损失函数为:

$$loss = -\ln p(\tilde{Q} \mid D_V) + loss_{CDM} \tag{14}$$

3.5 一般性的神经认知诊断框架模型

在本小节中，我们展示了 NeuralCD 是一个可以覆盖许多传统认知诊断模型的通用框架。我们接下来将展示 NeuralCD 和传统模型(包括 MF、IRT 和 MIRT)之间的密切关系。

矩阵分解(MF)。在 MF 中，Q_e 和 h^s 可以分别作为习题和学生潜在特征向量。设置 h^{diff}=0 和 h^{disc}=1，第一层的输出是 $x = Q_e \circ h^s$。然后，为了像 MF(即 $y = Q_e \cdot h^s$)那样，其余所有层需要做的就是将 x 中每个元素的值相加，这很容易实现。MF 方法不采用单调性假设。

项目反应理论(IRT)。以 IRT 为例：$y = sigmoid((h^s - h^{diff}) \times h^{disc})$。设置 Q_e=1，并设置 h^s 和 h^{diff} 为一维向量，第一层的输出为 $x = (h^s - h^{diff}) \times h^{disc}$，接着是一个 Sigmoid 激活函数。单调性假设是通过限制 h^{disc} 为正来实现的。IRT 的其他变体(例如：$y' = C + (1 - C)y$，其中 C 是猜测参数)可以通过一些更改来实现。

多维项目反应理论(MIRT)。一个直接的扩展从 IRT 到 MIRT 是使用多维潜在特征向量的习题和学生。本文以(Adams, Wilson, and Wang 1997)提出的典型模

型为例:

$$y = \frac{e^{Q_e.h^s - d_e}}{1 + e^{Q_e.h^s - d_e}} \tag{15}$$

设置 hdisc=1,第一层由的输出(6)式得到: $x = Q_e \circ (h^s - h^{diff})$ 。在方程(7)中设置 W_1 =[1 1⋯1],b_1 = 0 和φ(x) = x,我们得到： $f_1 = Q_w \circ h^s - d_e$ ，其中 $d_e = Q_e.h^{diff}$ 。其他层需要做的是类似的设置,很容易实现。如果将 Q_e 的每个项限制为正，则可以实现单调性假设。

3.6 讨论

我们介绍了 NeuralCD 框架的细节，并展示了它的特殊案例。需要指出的是，学生的熟练度向量 F^s 和习题的知识关联向量 F^{kn} 是 NeuralCD 框架中需要的基本参数。如果合理的话，习题区分度等其他参数也可以被纳入。第一个交互层的形成是不受限制的，但最好包含 $F^s \circ F^{kn}$ 项以确保 F^s 的每个维度响应对应的知识概念。全连接层参数全为正只是实现单调性假设的策略之一。更复杂的网络结构用来设计交互层。例如，循环神经网络可以用来捕捉学生学习过程的时间特征。

4 实验

我们首先将我们的 NeuralCD 模型与一些关于学生表现预测任务的基本模型进行比较。然后对模型进行了解释和评价。

4.1 数据集介绍

我们在实验中使用了两个真实数据集，即 Math 和 ASSIST。科大讯飞公司提供的 Math 数据集来自于广泛使用的在线学习系统，包含数学习题和高中生考试作答记录。ASSIST 是一个由 ASSISTments 在线辅导系统(Feng, Heffernan, and Koedinger 2009)收集的开放数据集，它只提供学生的作答记录和习题对应的知识概念。我们选择了公共修正版本，消除了以前工作提出的重复数据问题(Xiong et al. 2016)。表 1 总结了数据集的基本统计数据。我们分别过滤出 Math 和 ASSIST 作答记录小于 30 和 15 的学生，以确保每个学生都有足够的数据进行诊断。因此，对于 Math 数据集，我们得到了 2507 个习题和 497 个知识概念，剩下的没有出现在日志中的知识概念的习题用于 NeuralCDM+中 Q-矩阵的融合。我们对每个学生的回答日志进行 80%/20%的训练/测试分割。至于 ASSIST，我们按照与 Math 相同的方式划分作答记录，但由于没有提供习题文本，所以没有在此数据集上计算 NeuralCDM+。所有模型均采用 5 倍交叉验证法进行评估。学生在数学方面的知识熟练程度是稳定的，因为数据集是由考试日志组成的。然而，一个学生对一个知识概念的熟练程度可能会发生变化，因为他将不断地被给予这个概念的习题，直到他达到一定的标准(例如，连续正确回答 3 个相关的习题)。为了分析静态模型(例如，NeuralCD 模型和静态传统模型)是否适合应用于 ASSIST，我们比较了 Math 和 ASSIST 之间的两个度量。第一个指标是每个学生对每个知识概念的平均作答量:

$$\mathrm{AVG}_{\#\log} = \frac{\sum_i^N \sum_j^K Log(i,j)}{\sum_i^N \sum_j^K I(Log(i,j)>0)} \tag{16}$$

其中 Log(i, j)为学生 S_i 回答的与知识概念 k_j 相关的习题量。此外，另一个度量是得分的平均标准差:

$$\mathrm{STD}_{\#\log>1} = \underset{s_i \in S}{mean}(\underset{k_j \in K_n, Log(i,j)>1}{mean}(std_{ij})) \tag{17}$$

其中 std_{ij} 给出了学生 s_i 在与知识概念 k_j 相关的习题中获得的分数的标准差。如表 1 所示，尽管 ASSIST 的 AVG#log 值比 Math 大得多，但它们的 STD#log 值非常接近。因此，我们可以合理地假设在 ASSIST 中学生的知识状态也是稳定的，并且我们的静态 NeuralCD 模型和基本模型都适用于这两个数据集。在模型解释中将会有更多的讨论。

4.2 实验参数设置

完整连接层(公式(7)~(9))的尺寸分别为 512、256、1，并且 Sigmoid 被用作所有层的激活函数。我们设置超参数λ = 0.1 (公式(12))和σ = 1 (公式(13))。对于 top-k 知识概念选择中的 k，我们使用使预测网络达到 0.85 召回率的值。也就是说，在我们的实验中，k = 20。我们用 Xavier 初始化方法初始化参数(gloria 和 Bengio 2010)，它用从 N(0, std^2) 采样的随机值中填充权重，其中 $std = \sqrt{2/(n_{in}+n_{out})}$。$n_{in}$ 表示输入权值的神经元数量，n_{out} 表示输入结果的神经元数量。我们在 NeuralCDM+中使用的 CNN 架构包含 3 个卷积层，然后是一个完整的连接输出层。最大池化层(Maxpool)在第 1 层和第 3 层卷积层之后使用。卷积层的通道分别为 400、200、100，内核大小分别设置为 3、4、5。卷积层采用 ReLu 激活函数，输出层采用 Sigmoid 激活函数。采用多标签二元交叉熵作为损失函数进行 CNN 训练。为了评估我们的 NeuralCD 模型的性能，我们将其与传统方法，即 DINA, IRT, MIRT 和 PMF 进行了比较。所有模型均由 PyTorch 使用 Python 实现，所有实验均运行在 Linux 服务器上，使用 4 个 2.0GHz Intel Xeon E5-2620 cpu 和特斯拉 K20m GPU。

4.3 实验结果

学生表现预测：认知诊断模型的性能很难评价，因为我们不能获得学生的真实知识水平。在大多数模型中，诊断结果通常是通过预测学生的表现来获得的，这些预测任务的表现可以从一个方面间接评价模型(Liu et al. 2018)。考虑到我们在数据中使用的所有习题都是客观习题，我们从分类方面和回归方面使用评价指标，包括精度、均方根误差 (Pei et al. 2018)和 AUC(曲线下面积)(Bradley 1997)。表 2 为各模型对学生成绩预测任务的实验结果。“±”后的误差柱为每个模型 5 次评估运行的标准差。从表中，我们可以观察到 NeuralCD 模型在两个数据集上几乎优于所有其他基线，这表明了我们的框架的有效性。此外，NeuralCDM+优于 NeuralCDM 的性能证明了 Q-矩阵细化方法的有效性，也证明了精细估计的知识

关联向量对认知诊断的重要性。

模型可解释性：为了评估 NeuralCD 框架的可解释性(即诊断结果是否合理)，我们进一步进行了几个实验。从直观上看，如果学生 a 对知识概念 k 的掌握程度高于学生 b，那么学生 a 比学生 b 更有可能正确回答与 k 相关的习题(Chen et al. 2017)。我们采用一致度(Degree of Agreement, DOA) (Pirotte et al. 2007)作为这类排名绩效的评价指标。对于知识概念 k, DOA(k)表述为:

$$DOA(k)=\frac{1}{Z}\sum_{a=1}^{N}\sum_{b=1}^{N}\delta(F_{ak}^{s},F_{bk}^{s})\sum_{j=1}^{M}I_{ij}\frac{J(i,a,b)\wedge\delta(r_{aj},r_{bj})}{J(j,a,b)} \tag{18}$$

其中 $Z=\sum_{a=1}^{N}\sum_{b=1}^{N}\delta(F_{ak}^{s},F_{bk}^{s})$。$F_{ak}^{s}$ 表示学生 a 对知识概念 k 的掌握程度。如果 x > y，则δ(x, y) = 1，否则δ(x, y) = 0。如果习题 j 包含知识概念 k，则 I_{jk}= 1，否则 I_{jk}= 0。如果学生 a 和 b 都做了习题 j，那么 J(j, a, b) = 1，否则 J(j, a, b) = 0。我们将所有知识概念 DOA(k)值作为评价诊断结果的质量(即模型获得的知识熟练程度)。在传统模型中，我们只与 DINA 进行比较，因为对于 IRT、MIRT 和 PMF，它们的潜在特征与知识概念之间没有明确的对应关系。此外，我们还在两个简化的 NeuralCDM 模型上进行了实验。在第一个简化模型(记为 NeuralCDM-Q 矩阵)中，知识关联向量是在无监督训练过程中估计的，而不是从 Q 矩阵中获取。而在另一个简化模型(记为 NeuralCDM -单调性)中，通过消除全连接层上的正限制来消除单调性假设。利用这两个约简模型分别论证了精细估计的知识关联向量和单调性假设的重要性。此外，我们进行了一个额外的实验，随机估计学生的知识熟练程度，并计算 DOA 进行比较。图 5 为实验结果。从图中我们可以看到，NeuralCDM 和 NeuralCDM+的 DOA 明显高于基本模型，这证明了他们诊断的知识熟练程度是合理的。NeuralCDM- Q 矩阵和 NeuralCDM-单调性的 DOA 值都远低于 NeuralCDM，说明 Q -矩阵信息和单调性假设对于获得可解释的诊断结果(知识熟练度向量)都很重要。此外，NeuralCDM 在 Math 数据集上的表现比在 ASSIST 上表现更好。这主要是由于作答记录中的矛盾，即一个学生回答的一些习题中含有知识概念 k_j 且作答正确，而另一些习题中含有 k_j 且作答错误(原因可能是知识熟练程度的变化，或者习题中含有其他知识概念)。如表 1 所示，ASSIST 具有比 Math 数据集大得多的 AVG#log 和略高的 STD#log>1 值，这使得作答记录中的矛盾更多。

案例研究：在这里，我们展示了一个学生对数据集 ASSIST 的 NeuralCDM 诊断结果的示例，见图 6。图 6 的上半部分显示了关于五个知识概念的三个习题的 q -矩阵和一个学生对这些习题的反应。下面子图中的条形图代表了学生对每个知识概念的熟练程度。用不同颜色和标记的线条表示三个习题的知识难度(为了清晰起见，我们只给出每个习题的相关知识概念的难度)。从图中我们可以看出，当学生的熟练程度满足习题的要求时，他更有可能做出正确的反应。例如，习题 3 要求掌握“排序分数”，难度为 0.35。该学生对“排序分数”的熟练程度为 0.60，高于要求，因此他正确回答了这个问题。NeuralCDM 中的知识难度(h^{diff})和知识熟练度(h^{s})均可如预期的那样解释。

4.4 讨论

从以上实验中，我们可以看到 NeuralCD 模型为认知诊断提供了准确和可解释的结果。未来的研究仍有一些方向。首先，我们可以努力设计一个更有效的知识概念预测模型，这将促进 NeuralCDM+的性能。其次，神经网络权值的正约束可能会限制近似能力，因此我们需要探索更灵活的方法来满足单调性假设。在许多在线自学环境下，学生的知识状况发生了变化，我们希望将 NeuralCD 扩展到动态认知诊断。

5 结论

本文提出了一种用于学生认知诊断的神经认知诊断框架 NeuralCD 框架。具体来说，我们首先讨论了框架中基本的学生和习题参数，并在框架上放置了一个单调性假设，以确保其可解释性。然后，在该框架下实现了一个具体的模型 NeuralCDM，验证了其可行性，并通过结合习题文本对 NeuralCDM 进行了进一步扩展，以细化 Q -矩阵。在真实数据集上的扩展实验结果表明，我们的模型具备良好的准确性和可解释性。我们还发现 NeuralCD 可以泛化一些传统的认知诊断模型(如 MIRT)。本工作对诊断网络的结构进行了直观的设计。然而，由于神经网络具有很高的灵活性和潜力，我们希望这项工作能够引起进一步的研究。