学校代号 10532　　学　号 S180900763

分 类 号 TP391　　密　级 公　开

湖南大學
HUNAN UNIVERSITY

硕士学位论文

基于慕课数据的学习者评估模型研究与应用

学位申请人姓名　刘畅

培 养 单 位　电气与信息工程学院

导师姓名及职称　王炼红 副教授

学 科 专 业　电子科学与技术

研 究 方 向　教育大数据分析

论文提交日期　2021年4月9日

学校代号：10532

学　　号：S180900763

密　　级：公开

湖南大学硕士学位论文

基于慕课数据的学习者评估模型研究与应用

学位申请人姓名：　　刘畅

导师姓名及职称：　　王炼红 副教授

培 养 单 位：　　电气与信息工程学院

专 业 名 称：　　电子科学与技术

论文提交日期：　　2021年4月9日

论文答辩日期：　　2021年5月16日

答辩委员会主席：　　黎福海 教授

Research and Application of Learner Evaluation Model Based on MOOC Data

by

LIU Chang

B.E. (Xiangtan University) 2018

A thesis submitted in partial satisfaction of the

requirements for the degree of

Master of engineering

in

Electronic Science and Technology

in the

Graduate school

of

Hunan University

Supervisor

Professor Wang Lianhong

April,2021

湖 南 大 学

学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写的成果作品。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果由本人承担。

作者签名：　　日期：　　年　　月　　日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权湖南大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于

1、保密□，在_____年解密后适用本授权书。

2、不保密☑。

（请在以上相应方框内打“√”）

作者签名：　　日期：　　年　　月　　日

导师签名：　　日期：　　年　　月　　日

摘　要

大数据、云计算、人工智能等新兴信息技术的发展，促进了互联网与教育领域的深度融合，进一步提高了教育信息化的水平，催生了新型智能教育生态系统。在新的教育模式下，学习者可以突破时间与空间的限制，更加方便、快捷的获取教育资源、学习知识。但是，面对学习平台上大量的教育资源，如何对学习者和教育资源分别进行合理评估，从而提供匹配机制以便学习者可以快速检索需要的教育资源，已经成为当前智能教育生态系统建设面临的一个严峻问题。

认知诊断模型从学习者的认知结构出发，建模学习者知识水平、试题特性与学习者最终的试题作答结果之间的潜在关系。结合模型求解算法并根据试题作答结果可对学习者的知识水平与试题的特性进行评估。

论文针对传统认知诊断模型先验信息单一、机理不完善等问题进行研究，提出了一种新的高阶认知诊断模型——认知反应模型，用于对学习者进行评估。论文主要创新工作如下：

（1）建立了能力与努力特征联合补偿机制，对学习者认知阶段建模。认知过程指的是学习者对课程知识学习掌握的过程。本文建立了一种能力特征与努力特征在联合影响学习者知识水平效果上的联合补偿机制，并基于这种机制对学习者认知阶段进行建模。除此之外，还讨论了如何根据学习活动数据量化学习者的努力特征，并将量化的努力特征参数作为扩充的模型先验信息。

（2）引入知识点对作答习题的重要性等级，完善学习者反应阶段建模。反应过程指的学习者凭借其自身知识掌握作答习题的过程。本文除了考虑试题猜测参数、失误参数等传统认知诊断模型中涉及的试题特性之外，还引入了知识点对作答习题的重要性等级这一特性，构建知识弱项参数对学习者的反应阶段建模。

（3）最后，开发了个性化教学辅助系统。该系统依据认知反应模型对慕课课程相关数据的评估结果，构建个体与群体画像，以可视化的形式呈现学习者、知识、试题的相关特征，供学习者与教师参考；另一方面，根据对学习者试题作答结果的预测值，实现可根据学习者自定义难度等级进行试题推荐的功能。

通过对所采集的慕课数据，训练集数据比例在 40%-90%范围内随机抽取进行实验，结果表明：基于认知反应模型的评估结果来预测学习者的试题作答结果时，准确率保持在 77.4%-84.1%，相比较 DINA、HO-DINA、Fuzzy-CDF 与 NeuralCD 模型的最优预测准确率 75.0%-82.0%而言，有显著提升，且鲁棒性更好。

关键词：学习评估；认知反应；联合补偿机制；知识弱项；试题推荐

Abstract

The development of emerging information technologies such as big data, cloud computing and artificial intelligence has promoted the deep integration of Internet and education, further improved the level of education informatization, and spawned a new intelligent education ecosystem. In the new education mode, learners can break through the limitation of time and space, more convenient and fast access to educational resources and learning knowledge. However, in the face of a large number of educational resources on the learning platform, how to reasonably evaluate the learners and educational resources, so as to provide a matching mechanism so that learners can quickly retrieve the needed educational resources, has become a serious problem in the construction of the current intelligent education ecosystem.

Based on the cognitive structure of learners, the cognitive diagnosis model models the potential relationship between learners' knowledge level, test characteristics and the final answer results. Combined with the model solving algorithm and according to the answer results of the test questions, the knowledge level of the learners and the characteristics of the test questions can be evaluated.

Aiming at the problems of traditional cognitive diagnosis model, such as single prior information and imperfect mechanism, this paper proposes a new high-order cognitive diagnosis model, cognitive and response model, to evaluate learners. The main innovations are as follows:

(1) A joint compensation mechanism for ability and effort characteristics has been established to model the cognitive stage of learners. Cognitive process refers to the process of learners' mastery of course knowledge. This paper establishes a joint compensation mechanism for the ability characteristics and effort characteristics to jointly influence the knowledge level of learners, and based on this mechanism, models the cognitive stage of learners. In addition, it also discussed how to quantify learners' effort characteristics based on learning activity data, and use the quantified effort characteristics parameters as the extended model prior information.

(2) The importance level of knowledge points to answer exercises is introduced to improve the modeling of learners' reaction stage. The reaction process refers to the process in which learners use their own knowledge to answer exercises. In addition to considering the characteristics of test questions involved in traditional cognitive diagnosis models such as test questions guessing parameters and error parameters, this

paper also introduces the importance of knowledge points to the answering exercises, and constructs the knowledge weakness parameters to the learner’s response stage. mold.

(3) Finally, a personalized teaching aid system was developed. The system constructs individual and group portraits based on the evaluation results of the cognitive response model on the relevant data of MOOC courses, and presents the relevant characteristics of learners, knowledge, and test questions in a visual form for the reference of learners and teachers; on the other hand, according to The predictive value of the answering result of the learner's test questions, realizes the function of recommending test questions according to the learner's self-defined difficulty level.

The collected MOOC data is randomly selected for experiments on the training set data ratio in the range of 40%-90%,and the results show that: based on the Cognitive and Diagnosis model to predict the learner's test scores, the accuracy rate remains at 77.4%-84.1%, compared with the DINA, HO-DINA, Fuzzy-CDF and NeuralCD models, the optimal prediction accuracy rate is 75.0% -82.0%, there is a significant improvement, and the robustness is better.

Key Words: learning assessment; cognitive and response; joint compensation mechanism; knowledge weakness; test questions recommendation

目　录

学位论文原创性声明 I
学位论文版权使用授权书 I
摘　要 II
Abstract III
目　录 V
第 1 章　绪　论 1
1.1 研究背景 1
1.2 国内外研究现状 2
1.2.1 学习者评估模型研究现状 2
1.2.2 认知诊断模型研究现状 4
1.3 研究思路与方法 5
1.4 本文组织结构 6
第 2 章　学习评估基本理论与模型 7
2.1 学习者评估理论 7
2.1.1 经典测量理论 7
2.1.2 概化理论 7
2.1.3 项目反应理论 8
2.1.4 认知诊断理论 8
2.2 认知诊断基础理论 8
2.2.1 认知诊断模型 8
2.2.2 认知属性 9
2.2.3 Q 矩阵 9
2.3 经典认知诊断模型 9
2.3.1 IRT 模型 10
2.3.2 MIRT 模型 11
2.3.3 融合模型 12
2.3.4 DINA 模型 12
2.3.5 HO-DINA 模型 12
2.4 模型参数求解算法 13
2.4.1 联合极大似然估计 13
2.4.2 贝叶斯估计 14
2.4.3 马尔可夫链蒙泰卡罗 15

2.5 评估模型对比分析 16
2.6 本章小结 18
第 3 章　面向慕课学习者评估的认知反应模型 19
3.1 C&RM 结构 20
3.2 认知阶段建模 21
3.2.1 二维潜在特征 21
3.2.2 知识水平衡量 23
3.3 反应阶段建模 31
3.3.1 试题掌握程度表征 31
3.3.2 试题作答结果 32
3.4 参数估计算法 33
3.5 基于 C&RM 的仿真实验分析 35
3.5.1 实验基础 35
3.5.2 参数估计精度评价指标 36
3.5.3 实验内容与结果 37
3.6 本章小结 38
第 4 章　基于 MOOC 数据的学习者评估实验与应用 40
4.1 基于 MOOC 数据的学习者评估实验 40
4.1.1 MOOC 数据获取与处理 40
4.1.2 实验对比模型及特点分析 43
4.1.3 实验结果与分析 44
4.2 基于评估结果的个性化教学辅助系统 49
4.2.1 个性化分析功能 49
4.2.2 个性化试题推荐功能 53
4.3 本章小结 54
总结与展望 55
参考文献 57
附录 A　攻读学位期间获得的研究成果 61
附录 B　攻读学位期间参加的科研项目 62
致谢 63

第 1 章　绪　论

1.1 研究背景

21 世纪，教育改革和人才培养是每个国家和地区都重点关注的要务之一。我国在 2018 年 4 月发布的《教育信息化 2.0 行动计划》中曾提及，要提高我国教育事业的信息化应用水平。在“互联网+”的新时代特色背景下，搭建“互联网+教育”大平台，探讨“互联网+教育”下的人才培养新模式将是促进教育事业信息化和现代化改革的有效途径。

慕课（Massive Open Online Course，MOOC），作为近年来教育领域一种针对大众的在线教学方式，以其免费学习、课程种类丰富、覆盖范围广的特点吸引了广大学习者群体的参与学习，取得了教育历史的一次伟大创新。MOOC 凭借其强大的开放性打破了教学的时空限制，是对传统教育形式、手段和过程的一种变革和颠覆。而以 MOOC 为代表的新型智能教育模式堪称人类教育历史上的第四次革命，必然会形成一个集成移动互联、云计算服务、物联网、大数据分析等新一代信息技术的新型智能教育生态系统[1]。这种新型智能教育生态系统将会在促进教育平衡，培养学生个性化发展上发挥不可替代的作用。

此外，新型智能教育在飞速发展的同时也暴露出一些不足：

①线上教育资源虽然极为丰富，但是更多的只是“量”的堆积，没有“质”的改变。

通常情况下，学习者的在线学习需要在有限的时间内完成自己的学习任务。这些学习任务对知识获取的广度或深度上都具有一定的要求，比如有的学习者想根据自己的兴趣拓展学习一些知识，有的学习者想深入学习某些知识来提高自己。

然而，面对平台上大量的学习资源，许多学习者的第一感觉是“下不了手”。这是因为资源数量太多，并且没有合理的量化指标（比如一些试题的难度系数，对相关知识点的考察程度等等）对教育资源进行标签化处理，从而导致许多学习者无法根据自身特定需求自定义的快速检索需要的资源进行学习，极大的影响了学习效率。

②学习者得不到有效评估。

目前教育系统中，对学习者的评估工作大多停留在传统的唯分数论的基础上，而不是对学习者更具体的知识掌握程度进行评估。以 2019 年新冠肺炎对教学工作的冲激影响为例，大量的教学工作被迁移到线上进行，但是目前的线上教学生态系统不够完善，学习者得不到有效的评估，教师对所教授的学习者个体及群体

的知识掌握情况了解也比较模糊，因而对自己教学成果得不到很好的反馈和总结。最终导致所有学习者只能接受“一刀切”方式的知识灌输和试题训练，形成恶性循环。再加上部分学习者自制力差或资源受限，不会或无法进行主动学习来弥补自己的不足，造成线上学习工作最终呈现出来的效果不理想。

③学习者与教育资源之间的匹配机制有待完善。

现有的一些匹配机制主要是根据学习者相互之间对知识领域兴趣偏好的相似性开展个性化推荐。但是根据学习者知识掌握水平匹配不同难度等级的习题进行推荐的研究却不是很多。这也跟学习者与教育资源的评估研究现状有关，因为推荐工作的前提就是要对推荐用户和推荐资源都展开合理的量化评估。

由此可见，面向学习者与教育资源的评估研究是促进新型智能教育生态系统建设工作的重中之重。针对学习者的评估研究，应当聚焦于学习者的知识结构，评估学习者的知识水平，进而进行教学辅助工作的调整[2]。针对数字教育资源建设，应当把师生对数字教育资源使用的个性需求作为核心导向，推动数字教育资源的供给侧结构性改革[3]，扩大数字教育资源带来的效率和效益。

在“互联网+”的时代特色背景下，借助物联网、大数据、人工智能、云计算等技术，可以收集包含学习者整个学习历程中的教育大数据。针对学习者评估、数字教育资源完善的研究离不开这些教育大数据的支持。对于教育大数据而言，传统的分析建模方法已然不再适用，而且还面临着数据维度高，映射关系复杂等问题[4]。因此，面向教育大数据的分析、挖掘研究吸引了诸多学者的关注。对教育大数据的研究主要分为学习分析和教育数据挖掘两个方向。其中，教育数据挖掘领域侧重对数据建模，结合教育学、统计学、心理学等领域技术和方法对教育大数据进行分析和处理，探究学习者最终的学习成效与学习行为、教育资源、教学行为等中间过程变量的相关关系，依此来分析学习者的学习趋势，并指导一些教学辅助工作的开展。

因此，在新的技术背景下，以“技术服务教育”的理念为指导，基于学习分析、教育数据挖掘等技术，构建面向学习者以及教育资源的新评估模型，推动新型智能教育生态系统的建设，促进学习者学习方式的变革和施教者教育模式的创新，为教育系统中的学习者、施教者、管理者提供精准、便捷、个性化的优质服务，是教育发展和变革的新需求。本文课题来源于中国高校产学研创新基金“新一代信息技术创新项目”《基于线上线下多模态教育数据挖掘及应用》项目。

1.2 国内外研究现状

1.2.1 学习者评估模型研究现状

智能教育系统中，可以根据学习者的个性化特征为学习者提供自适应的学习

资源，从而使学习更加有效[5]。而学习者评估模型就是用来评估学习者的个性化特征的，因此构建理想的学习者评估模型识别学习者的个性化特征是智能教育的核心。

学习者评估模型涉及的个性化特征可以分为六类[6]：学习者信息、学习者与知识相关的特征、学习者自身认知特征、社交互动、人格特质、学习动机。

学习者信息主要包含学习者的个人资料，比如年龄、性别、年级等一些个人信息。这些信息常被用来标记学习者。

学习者与知识相关的特征主要指学习者的知识水平，Adda[7]通过识别数字图书馆中学习者访问量大的领域概念来建模学习者掌握不佳的知识。De la Torre[8]建立 DINA 从知识水平、猜测行为、失误行为三个方面建模预测学习者的试题作答表现。Qi liu[9]结合 DINA 模型与模糊集理论建立 Fuzzy-CDF 模型对学习者的知识水平进行 0-1 之间的模糊值评估。Huang 基于知识、知识与知识之间的关系以及知识与项目之间的关系的模型，对学习者的知识进行建模。还有一些研究人员使用学习者在自适应学习系统中更细致的行为痕迹，比如回答问题的尝试次数[10]、回答问题所花费的时间[11]等。

学习者的认知特征一般指的是学习者的自身潜在特质：智力，记忆力等方面。能力是一种不可直接观测的理论构造，它必须从与能力相关的任务的表现中推断出来[12]。Liu[13]提出了一种利用蚁群算法通过适应性测验测量学习者能力的方法。文献[14-16]利用 IRT 模型在一段时间内对学习者持续进行能力估计，绘制能力变化曲线以评估教师教学的有效性。De la Torre[17]在 DINA 模型的基础上引入较知识状态更高阶的能力建模，实现对学习者的能力估计。Chou[18]使用基于能力的课程中课程与能力之间的对应关系以及学生所修课程和成绩来评估学生的能力。

学习者的社会特征同样会影响其学业表现。文献[19]研究了学习者在 MOOC 的在线讨论板块的社交参与改善了学习成果。文献[20]倡导开放式社交学习者建模方法，并强调了可视化学习者表现来增强学习者之间的交互，以帮助学习者在社交环境中进行自主学习。

人格特性与涉及理解、预测或人类行为的任何计算领域有关[21]。这一方向的代表性特征是学习风格或是学习方法。文献[22]构建推荐模型基于学习者的个性和学习风格推荐学习课程的呈现方式，结果表明学习者的课程参与度有了改善。文献[23]设计了一种“SRINSPIREus”学习框架，能对各种学习偏好的学习者匹配相应的学习策略提高学习的自适应性。

学习动机一般指学习者的情感、兴趣、学习目标、学习参与度等。积极进取、参与度高的学习者通常会获得更好的学习成果[24]。文献[25]利用学习者 web 学习过程中的学习行为建模，动态评估学习者的参与度。文献[26]使用学习者的学习参与数据建模，并应用到智能辅助系统的决策中。此外，学习者的兴趣则有助于

维持学习者学习的积极性与较高的参与度[27]。

1.2.2 认知诊断模型研究现状

在对学习者知识水平进行评估的诸多研究成果中，认知诊断模型被认为是最有效的。认知诊断模型是一种心理学模型，该模型旨在描述学习者知识水平、试题特性与学习者的试题作答结果之间的潜在作用结构。基于该模型结构，可以根据观测的学习者试题作答结果数据，利用模型求解算法对学习者的知识水平与试题的特性进行评估。在得到对学习者知识水平、试题特性的评估结果之后，还可以生成学习者对未作答试题的预测作答结果，从而建立基于预测结果的试题推荐机制向学习者推荐试题，节约学习者的时间成本，提高学习效率[28]。

基础的认知诊断模型主要有项目反应理论（Item Response Theory, IRT）[29]、确定输入噪音与门模型（Deterministic inputs, noisy and gate model, DINA）[8]、融合模型（Fusion model）[30]、属性层级模型(Attribute hierarchy model, AHM)[31]等。其中 DINA 与 IRT 模型是最具代表性、应用最广泛的两个模型，这两个模型都是利用学习者能力特征（或知识特征）与试题属性来建模学习者的试题作答结果，然后通过可观测的学习者试题作答结果与一些先验信息实现对学习者能力特征（或知识特征）的估计。不同点在于 IRT 模型中学习者能力特征是一个一维连续值，代表了学习者的整体能力水平，而 DINA 模型中，学习者知识特征是由多维二元离散向量表示的，每个维度的 0 或 1 值代表学习者是否掌握相关的知识点。在 DINA 模型基础上，De la Torre 引入“能力”这一高阶特征,认为学习者的知识水平取决于学习者的高阶潜在特征——能力特征,从而构建了能力决定知识水平，知识水平决定试题作答结果的高阶 DINA 模型（Higher-order DINA model，HO-DINA）[17]。涂东波等[31-33]对 DINA 模型进行扩展，开发了适用于多级评分场景的认知诊断模型。这些模型对学习者知识水平的评估结果都是二元类型（仅掌握和未掌握两种状态）。针对该问题，Qi liu[9] 基于模糊集合理论构建了 FuzzyCDF 模型，将学习者能力特征决定下的知识水平由原来的确定性变量模糊化为模糊变量，并运用模糊逻辑对知识水平与试题作答结果之间的关系进行建模。Fuzzy-CDF 模型对知识水平的评估结果是介于 0-1 之间的连续值，更加细粒度的呈现了评估结果。李忧喜等[34]在 Fuzzy-CDF 的基础，根据题库中知识点出现的次数定义了知识点重要性这一特征参数，并认为知识点的重要性影响了学习者的知识掌握过程。但是，实际上知识点的重要性应当是相对于作答试题而言的。而且不能仅凭借知识点在题库中的出现次数定义其重要性，因为同一知识点对作答不同试题的重要性也可能是不同的。在此考虑下，可以将知识点对作答习题的重要性这一特征参数应用到试题作答过程建模。Yamaguchi 等[35]将两种基础认知诊断模型进行加权混合提升了预测性能。Fei Wang 等[36]主张使用神经网络从数据中学习训练新的认

知诊断模型——NeuralCD 模型。该模型使用神经网络来模拟学习者的认知结构，并对神经网络中的训练参数进行约束、赋予现实意义，然后通过学习者试题作答数据来训练神经网络，得到对学习者知识水平的评估结果。但是，该模型需要大规模的数据进行训练才能取得比较好的效果，并且由于神经网络的高复杂性，容易导致过拟合。

尽管引入“能力”特征的高阶模型[9,17,34]相比较低阶基础模型，在评估结果的解释性、精确度等方面都有了明显的提升，但上述高阶模型都未考虑如下要素及作用：学习者高阶的能力特征可以区分为相互独立的两个维度：先天能力特征与后天努力特征。学习者的知识水平不仅与学习者的先天能力相关，还与其后天努力相关；此外，这两个特征在对学习者知识水平的影响上还存在特定的补偿机制。

1.3 研究思路与方法

不管是学习者，还是试题，它们的特征都是不可直接观测的，而是隐藏在学习者相关的学习数据中[37]。因此，需要尽可能完备地采集学习者的学习数据，并且对学习者、知识、试题三者之间的潜在关系结构进行建模。将采集的数据进行预处理输入到构建的认知诊断模型中，对模型进行求解，实现对学习者、知识、试题特性的评估。评估完成后根据学习者与试题的量化特性，建立推荐机制实现试题推荐。研究过程可分为如下图 1.1 所示的五个阶段：

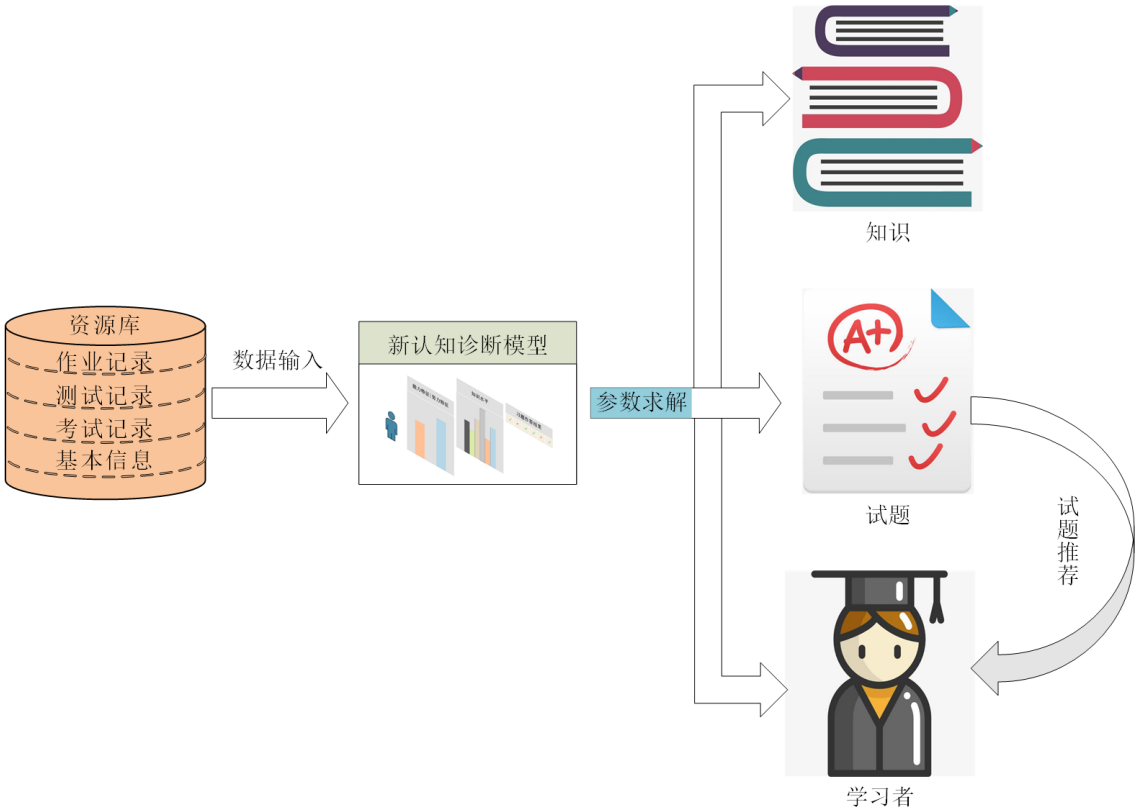

图 1.1 研究思路

（1）数据准备

基于 Python 爬虫技术，对中国大学 MOOC 平台上的湖南大学《信号与系统》线上课程进行数据采集，获取学习者的试题、作业、考试成绩与试题作答记录。对这部分数据进行清洗，构建了新的学习数据集 HNU_SAS。

（2）模型构建

改进现有认知诊断模型架构，构建新的认知诊断模型——认知反应模型，对学习者、知识、试题三者之间的潜在关系结构进行建模。认知反应模型架构中，将学习者的学习过程划分为以下三个层次：

①学习者凭借自身先天能力水平及后天努力程度达到一定的知识水平。

②根据学习者自身的知识水平以及试题对知识的考察情况得到学习者对试题的掌握程度。

③根据学习者对试题的掌握程度，同时考虑学习者的粗心作答、猜测作答等随机行为，获得学习者对试题的作答结果。

其中，层次一为学习者的认知阶段，层次二、三构成学习者的反应阶段。

（3）参数求解算法设计

认知反应模型是一个概率模型，并且模型中涉及到了学习者、知识、习题等方面的大量的未知特征参数。因此，在基于试题作答记录对学习者、试题特征进行评估时，需要依托特定的参数求解算法。本文基于贝叶斯估计与马尔可夫链蒙泰卡罗方法，设计了模型参数求解算法对认知反应模型进行求解，并设计了仿真实验验证使用该算法对模型中未知参数求解的可靠性。

（4）实验与结果分析

依托真实的数据集 HNU_SAS，利用构建的认知反应模型与模型求解算法对学习者的知识水平、知识特性、试题特性进行评估，并基于评估结果对学习者作答结果进行预测，讨论本文提出的模型与其他认知诊断模型的预测性能差异。

（5）基于评估结果的应用研究

编写个性化教学辅助系统，根据认知反应模型对学习者知识水平、课程知识特性、考试试题特性的评估结果建立个体与群体画像，将评估的特征值进行可视化呈现，供课程教师与学生查询了解。另外，结合评估结果，根据构建的认知反应模型推测学习者对未作答的试题的正确作答概率，根据该概率值量化得到题目针对学习者而言的难度等级，并根据学习者自定义的难度等级，推荐匹配的试题供学习者练习提高。

1.4 本文组织结构

本文主要分为四个章节：

第一章：绪论。介绍学习者评估模型的研究背景，分析国内外对学习者评估模型以及基于认知诊断理论的评估模型的研究现状，介绍了本文的研究思路与方法以及各章节的内容安排。

第二章：学习评估基本理论与模型。介绍了学习测验理论的发展历程，分析了常见的认知诊断模型，阐述了认知诊断模型求解算法的原理，并基于公共数据集对各认知诊断模型进行实验对比分析。

第三章：面向慕课学习者评估的认知反应模型。介绍了本文提出来的认知反应模型

的整体架构，详细阐述了对学习者认知阶段、反应阶段建模的机理与过程。此外，还介绍了基于马尔可夫链蒙泰卡罗方法的认知反应模型参数求解算法，并设计仿真实验，分析模型中待求解参数的可识别性以及样本数量对参数求解结果的精度影响。

第四章：基于 MOOC 数据的学习者评估实验与应用。介绍了基于 Python 爬虫技术获取慕课学习者学习数据的过程与结果，根据构造的学习者评估模型及对应的求解算法对学习者、知识、试题进行评估，并基于评估结果对学习者的试题作答结果进行预测，评估模型的预测性能。除此之外，还介绍了开发的教学辅助系统的评估结果展示与个性化试题推荐功能。

总结与展望：对本文的研究工作与成果进行简要总结，分析课题还存在的问题以及下一步的研究改进方向。

第 2 章　学习评估基本理论与模型

2.1 学习者评估理论

对学习者知识水平评估的本质在于对学习者的知识加工与运用过程进行建模，进而通过学习者的试题作答结果评估其目前所处的知识状态。上述建模过程属于测验理论的应用范畴，测验理论在上百年的发展历程中，先后经历了经典测量理论（Classical Test Theory,CTT）、概化理论（Generalizability Theory,GT）、项目反应理论（Item Response Theory，IRT）以及以认知诊断理论（Cognitive Diagnosis，CD）为代表的新一代测验理论等阶段。其中，在新一代测验理论出现之前的理论也被统称为标准测验理论，标准测验理论强调在宏观层次对学习者的能力水平进行测量与评估，即仅使用一个能力特征值来表征学习者的能力水平；与之不同，认知诊断理论更重视学习者在微观层次的知识加工过程，并使用多维的特征向量来表征学习者的对不同知识的掌握程度（多维知识水平），评估结果更加细致。

2.1.1 经典测量理论

经典测量理论认为：学习者的考试分数由反应学习者真实水平的真实分数及随机的误差分数组成。并有以下两个推论：

（1）学习者考试分数的平均数就是学习者的真实分数。

（2）学习者考试分数的方差等于真实分数的方差与误差分数的方差之和。

在经典测量理论中，使用真实分数来表示学习者的能力水平，也就是使用多次考试成绩的平均值衡量学习者的能力水平。显然，经典测量理论假设考试得分与能力水平是线性相关的，但是实际情况中，这种线性关系是很难成立的，并且这种利用多次考试分数均值来衡量能力的方法是十分依赖于考试试题难度的，即难度不同的考试情形下，对同一名学习者能力的衡量结果也是不同的，无法达到统一量表，现实应用存在比较大的局限性。

2.1.2 概化理论

概化理论认为测量误差的来源是多种多样的，比如测量工具不标准、测量对象不配合等等都会造成测量误差，因此经典测量理论仅使用一个误差值来概括所有误差的做法过于理想化，并且也无法体现各种误差的相对大小。因此，概化理论设计了实验性研究误差方差来源的方法。

2.1.3 项目反应理论

项目反应理论认为，学习者的能力水平越高，那么其正确作答试题的概率就越高，除此之外，试题本身的一些性质也会对学习者正确作答的概率产生影响，比如试题的难度、区分度等。因此，项目反应理论主张使用非线性的概率模型来描述学习者能力水平以及试题特性是如何联合作用影响学习者对试题的正确作答概率的。项目反应理论对学习者能力水平的评估具备参数不变性，即使用同一学习者群体中的不同样本集评估时，同一学习者的能力水平与同一试题的特性参数是不变的，并且学习者的能力水平与试题的难度参数具有统一的量表。

2.1.4 认知诊断理论

在认知诊断理论之前，对学习者的评估还停留在宏观层次上的整体能力水平评估，评估结果是一个代表学习者整体能力的参数值。具有相同得分的学习者，可能会在知识结构、知识状态等方面存在不同，但是前述理论只能给出同样的一个评估结果。而认知诊断理论则是专注于对学习者的知识、技能进行评估。认知诊断理论中，学习者的知识特性被描述为学习者对知识点的掌握情况，试题的特性则包括猜测性、失误性以及对各知识点的考察情况。

2.2 认知诊断基础理论

在测量学领域，认知诊断指的是对个体对技能的认知与加工过程进行诊断评估。将认知诊断理论应用于教育学领域时，我们希望探究学习者深层次的知识掌握与运用的机理：学习者个体是如何掌握作答试题所需要的知识的以及学习者是怎样根据自己所掌握的知识作答试题的。继而根据对学习者、知识、试题的诊断评估结果辅助教师教学与学习者自主学习。

2.2.1 认知诊断模型

个体心理内部对知识的认知加工过程是十分复杂的，而且也无法通过仪器设备对人类解决问题的过程进行显式测量，我们可以观测得到的与该过程相关的数据只有他们对考试试题的作答结果，而这些作答结果中就蕴藏着个体的知识、技能等信息。除此之外，还要结合认知心理学领域揭示的人类认知加工过程的内在机理，才能开发实现对人类内部心理进行计量的认知诊断模型。因此认知诊断模型本质上是结合认知心理学构建计量模型，从而实现对人类内部心理认知加工过程的测量，继而提供需要的认知诊断信息。目前，常用的认知诊断模型主要有规则空间模型、属性层级模型、决定性输入噪声与门模型、融合模型、多维项目反应理论模型等。

2.2.2 认知属性

认知诊断的目的之一就是对个人认知加工过程中所涉及的认知属性进行诊断。其中，认知属性也有着不同的解释。但是，从大多数学者的认识共性上来看，认知属性是指正确作答试题所需要的知识、策略等。根据 Leighton 等人的研究成果，认知属性之间是具有隐含的关联关系的，这种关联关系层层累积，从而构成了复杂的关联网络。

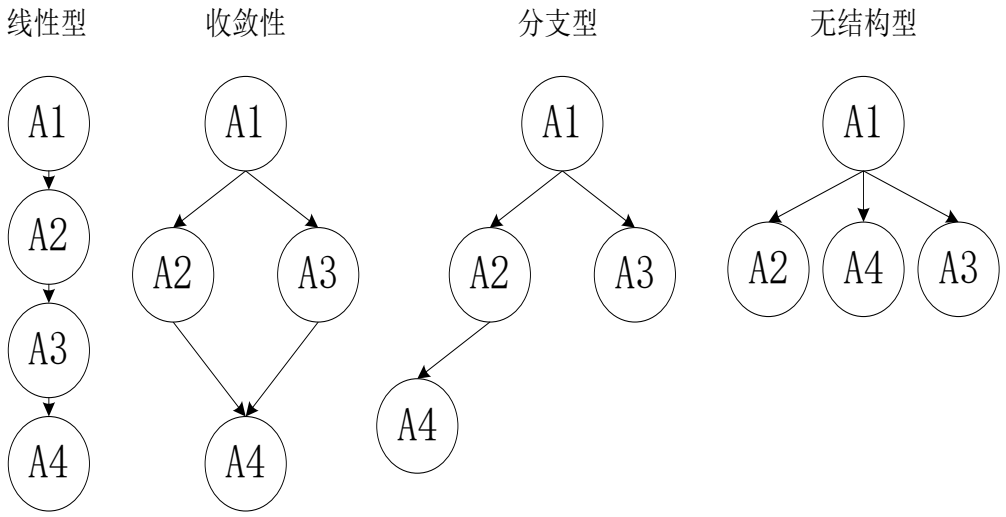

图 2.1 认知属性之间的四种层级关系

如图 2.1 所示，认知属性之间的关系可以分为四种类型：线性型、收敛型、分支型和无结构型。线性型关系中，属性与属性之间的关系是一对一，并且线性排列的，前一个属性为后一个属性的先决条件，只有先掌握了前一个属性，才有可能掌握后一个属性。收敛型关系中，某个属性会以多个属性为先决条件，将这些先决条件同时掌握，才可能掌握后续属性，图 2.1 收敛型关系中，只有同时掌握 A2，A3，才可能掌握 A4。分支型关系是最为常见的层级关系，属性之间的关系是层级递进的。图 2.1 分支型关系中，A1 为 A2，A3 属性的先决条件，并且 A2 属性为 A4 属性的先决条件。无结构型是一种比较极端的层级关系，A1 属性为其他所有属性的先决条件。将图中的四种层级关系重重组合就构成了某一领域涉及的属性之间的关联网络。

2.2.3 Q 矩阵

Q 矩阵主要是用来确定考试试题对认知属性（知识点）之间的对应考察关系，即通过 0-1 矩阵的形式标明试题是否考察了对应的知识点。Q 矩阵为 J 行 K 列的 0-1 矩阵，其中，J 是考试试题的数量，K 是考试涉及知识点的数量。元素 q_{jk} 为 1 说明试题 j 考察了知识点 k，为 0 则说明试题 j 未考察知识点 k。Q 矩阵可以通过试题涉及知识领域的权威专家根据经验标定，同时 Q 矩阵也是认知诊断模型中除了学习者的试题作答结果之外另一个可获取的已知条件。

2.3 经典认知诊断模型

2.3.1 IRT 模型

IRT 模型被认定是依托试题作答结果分析学习者整体知识水平的有效模型，是一种具备良好可解释性的模型结构。

IRT 的核心是根据学习者的单维知识水平以及试题的特性，对学习者的试题作答结果进行预测。IRT 模型通常表示为：

$$P(y=1|\theta,a,d)=\frac{1}{1+\exp(-Da(\theta-d))} \tag{2.1}$$

式 2.1 中，θ 表示学习者的知识水平，a 表示试题的区分度参数，d 表示试题的难度参数，D 表示尺度常数，通常取 1.7。$P(y=1|\theta,a,d)$ 表示知识水平为 θ 的学习者对特性为 (a,d) 的试题正确作答的概率。

根据上式 2.1，令试题属性 a=1，d=1，绘制试题正确作答概率 $P(y=1|\theta,a=1,d=1)$ 与学习者的知识水平 θ 的关系曲线图，如下图 2.2 所示：

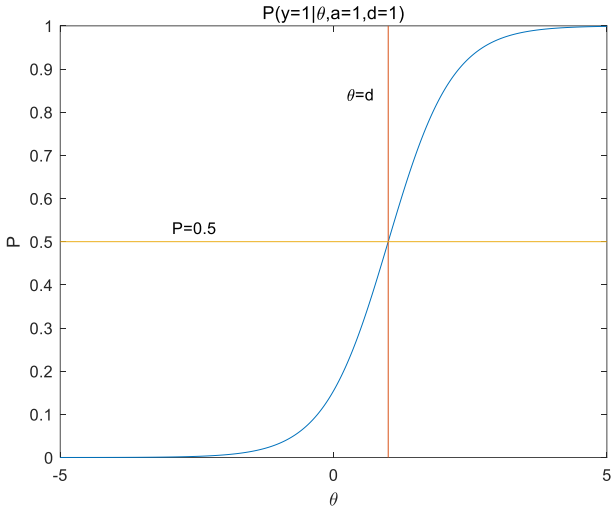

图 2.2 $P-\theta$ 曲线图

观察 $P-\theta$ 曲线图，横坐标表示学习者的知识水平，纵坐标表示学习者正确作答试题的概率，可以看到，IRT 模型有以下特征：学习者正确作答试题的概率随自身知识水平的增加而增加；说明学习者正确作答试题的概率与自身知识水平呈正相关。图 2.2 中，当学习者的知识水平 θ 与试题难度 d 相等时，学习者正确作答试题的概率 P 等于 0.5。说明当学习者知识水平与题目难度相当时，学习者正确作答与错误作答的概率都为 50%，学习者试题作答结果的不确定性最大。

计算试题正确作答概率 $P(y=1|\theta,a=1,d=1)$ 对学习者的知识水平 θ 的导数，绘制下图 2.3：

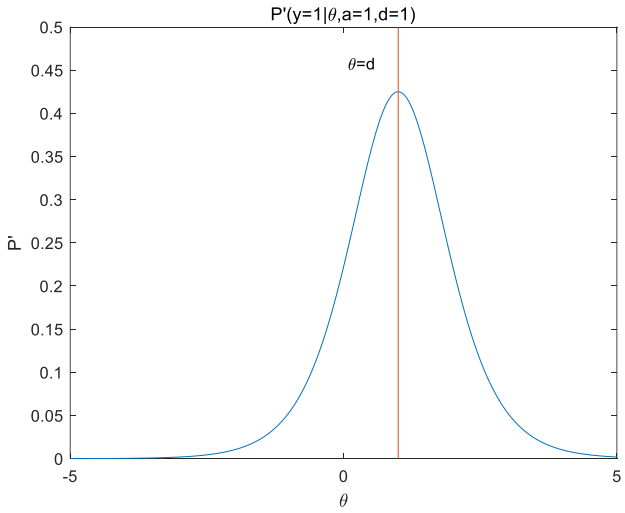

图 2.3 $P-\theta$ 导数曲线图

观察 $P-\theta$ 曲线的导数图，可以看到，IRT 模型有以下特征：当 θ 过大或过小，$P-\theta$ 曲线的导数偏小；说明当学习者具备较高或较低的水平时，知识水平的高低变化所引起的正确作答概率的变化的幅度往往是比较小的。图 2.3 中，当学习者的知识水平 θ 与试题难度 d 相等时，$P-\theta$ 曲线导数最大。因为此时学习者试题作答结果的不确定性最大，知识水平的变化往往能引起波动比较大的正确作答概率变化。

综上来看，IRT 在描述学习者整体知识水平，试题属性与试题作答结果之间的关系时，具备良好的可解释性。

2.3.2 MIRT 模型

多维 IRT 模型是 IRT 模型在试题考察多维知识时的泛化形式。常见的 MIRT 主要分为补偿性和非补偿性。

补偿模型：

$$\begin{aligned} &P(y_{ij}=1\mid\theta_i,a_j,d_j,c_j) \\ &=c_j+(1-c_j)\frac{1}{1+\exp(-(a_j\theta_i+d_j))} \end{aligned} \tag{2.2}$$

式 2.2 中，$\theta_i=[\theta_{i1},...\theta_{iK}]$，$a_j=[a_{j1},...a_{jK}]$ 分别代表了学习者 i 的 K 维知识水平以及试题 j 对各维度知识水平的区分度参数。补偿模型中，对于试题 j 来说，所有满足 $a_j\theta_i$ 相等的学习者 i 都具备相同的正确作答概率，这也就意味着其中一维知识水平低的学习者可以通过其他维度知识水平值的提升得到补偿，而且这种补偿效果是完全的，即单维度知识水平低的学习者可通过其他维度知识水平的增加达到任意值的试题正确作答概率。

部分补偿模型：

$$\begin{aligned} &P(y_{ij}=1\mid\theta_i,a_j,d_j,c_j) \\ &=c_j+(1-c_j)\prod_{t=1}^{m}\frac{1}{1+\exp(-(a_{jt}\theta_{it}+d_{jt}))} \end{aligned} \tag{2.3}$$

非补偿模型主要建立在各维度知识水平相互独立的情况下，模型认为学习者在作答考察多维知识的试题上正确作答概率应当为学习者各单维知识水平决定的正确作答概率的乘积。因而，学习者对试题的正确作答概率低于任一维度知识水平决定下的正确作答概率，不具备补偿性。

2.3.3 融合模型

融合模型的表达式为：

$$P(y_{ij}=1|\alpha_j,\theta_j)=\pi_i^*\prod_{k=1}^{K}r_{ik}^{*(1-\alpha_{jk})q_{jk}}p_{c_i}(\theta_j) \tag{2.4}$$

其中，$\pi_i^*=\prod_{k=1}^{K}P(y_{ijk}=1|\alpha_{jk}=1)^{q_{jk}}$，用来衡量学习者能够正确运用试题考察的所有知识答对试题的概率，该值越大，说明试题越容易。$r_{ik}^*=\frac{P(Y_{ijk}=1|\alpha_{jk}=0)}{P(Y_{ijk}=1|\alpha_{jk}=1)}$，为试题对知识的区分度参数，学习者不掌握知识 k 与掌握知识 k 但都答对试题的概率比，它反应了知识 k 的重要性，值越小说明知识越重要。c_i 表示学习者答对试题 i 所需其他知识的程度。

2.3.4 DINA 模型

DINA 模型将学习者的多维知识水平离散表示为 0 或 1 的二元类型，DINA 模型的表达式为：

$$P(y_{ij}=1|\alpha_i,s_j,g_j)=(1-s_j)^{\eta_{ij}}g_j^{(1-\eta_{ij})} \tag{2.5}$$

式中，$\eta_{ij}=\prod_{k=1}^{K}\alpha_{ik}^{q_{jk}}$，$\eta_{ij}$ 表示学习者 i 是否掌握试题 j 考察的所有知识点，$\eta_{ij}=1$ 表示学习者完全掌握试题，$\eta_{ij}=0$ 表示学习者不掌握该试题；α_{ik} 表示学习者 i 是否掌握知识点 k，q_{jk} 表示试题 j 是否考核知识点 k，η_{ij}，α_{ik}，q_{jk} 取值范围都为 0 或 1 的二元值。s_j，g_j 分别为试题 j 的粗心因子与猜测因子。s_j=$P(y_{ij}=0|\eta_{ij}=1)$，表示学习者在掌握试题 j 的情况下，因粗心导致错误作答的概率，g_j=$P(y_{ij}=1|\eta_{ij}=0)$ 表示学习者在未掌握试题 j 的情况下，通过猜测行为正确作答的概率。

2.3.5 HO-DINA 模型

DINA 模型中，学习者对各知识点的掌握程度之间没有关联关系的，即学习者的各维度的知识水平参数是相互独立的。实际情况并非如此，De la Torre 认为学习者的各个维度的知识水平之间存在相关性，并且存在相关性的原因是学习者

对各知识点的掌握程度跟学习者更高阶的潜在特征——能力特征相关。因此，在 DINA 模型的基础上，通过引入假设：学习者的知识水平（即对各知识点的掌握程度）从属于学习者更高阶的能力特征，构建了 HO-DINA 模型，HO-DINA 模型中，能力特征与知识水平之间的关系如下式 2.6、2.7 所示所示：

$$P(\alpha \mid \theta) = \prod_{k=1}^{K} P(\alpha_k \mid \theta) \tag{2.6}$$

$$P(\alpha_k \mid \theta) = \frac{\exp(\lambda_{0k} + \lambda_{1k}\theta)}{1 + \exp(\lambda_{0k} + \lambda_{1k}\theta)} \tag{2.7}$$

式中，λ_{0k} 为知识点 k 的截距参数，λ_{1k} 为知识点 k 在能力特征上的负荷。HO-DINA 模型除了像 DINA 模型一样可以描述学习者的知识水平，还可以描述学习者自身的能力特征以及学习者自身的知识水平是如何受制于能力特征的。

2.4 模型参数求解算法

认知诊断模型描述的是个体的知识、技能等特性以及测验项目的特性是如何影响学习者最终具体的反应结果的，对认知诊断模型求解的过程，就是通过实际可观测的 Q 矩阵、考试试题作答结果等数据以及一些其他的经验信息，针对具体的认知诊断模型，获取对模型中学习者、试题相关特征参数的求解结果。由于认知诊断模型属于概率图模型，因此需要借助统计学参数估计的方法对模型中的待求解参数推断求解。

2.4.1 联合极大似然估计

（1）极大似然估计

极大似然估计是根据极大似然原理衍生的一种参数统计方法，极大似然原理的直观理解为：随机试验的结果是所有可能出现的结果中出现概率最大的。例如随机实验结果可能会出现 A_1，A_2，… A_N 等 N 种情况，在某一次的实验中，实验结果为 A_1，那么可以认为此时的实验条件是最有利于出现 A_1 结果的，即在此时的实验条件下，结果 A_1 发生的概率最大。

假定 θ 表示学习者的特征参数，a、b 表示考试试题的特征参数，R 表示试题作答结果。在 R 已知的条件下，对 θ、a、b 进行诊断的似然函数为：

$$L(\theta, a, b \mid R) = \prod_{i=1}^{I} \prod_{j=1}^{J} P_{ij}^{r_{ij}} Q_{ij}^{1-r_{ij}} \tag{2.8}$$

式 2.8 中，I 表示学习者人数，J 表示考试试题总数，P_{ij} 表示第 i 名学习者正确作答试题 j 的概率，Q_{ij} 表示第 i 名学习者错误作答试题 j 的概率，$Q_{ij} = 1 - P_{ij}$。似然函数表示了此时的试题作答结果出现的概率，根据极大似然原理，当式 2.8 似然函数取最大值时，对应参数 θ、a、b 的取值就是参数的极大似然估计值。由于

$L(\theta,a,b|R)$与$\ln L(\theta,a,b|R)$同时取最大值，并且对数操作可以对似然函数的取值进行合理放缩，所以一般情况下讨论$\ln L(\theta,a,b|R)$的极大值，极值出现的条件为导数为 0，即极大估计值θ、a、b满足下式 2.9：

$$\begin{cases} \dfrac{\partial \ln L}{\partial \theta_i}=0, i=1,2,...I \\ \dfrac{\partial \ln L}{\partial a_j}=0, j=1,2,...J \\ \dfrac{\partial \ln L}{\partial b_j}=0, j=1,2,...J \end{cases} \tag{2.9}$$

因此求极大似然估计值的过程就是对上式 2.9 方程组求解的过程。

（2）条件极大似然估计

利用条件极大似然估计对认知诊断模型进行参数估计就是利用极大似然估计，在试题特征参数已知的条件下对学习者特征参数进行估计，或是在学习者特征参数已知的条件下对试题特征参数进行估计。即似然函数分别表示为$L(\theta|R,a,b)$和$L(a,b|R,\theta)$。

（3）联合极大似然估计

联合极大似然估计应用于在学习者特征参数与试题特征参数都未知的情况下，对学习者特征参数与试题特征参数进行同时估计。估计过程中可分解为对学习者特征参数的条件极大似然估计与对试题特征参数的条件极大似然参数估计，通过在估计过程中对学习者特征参数与试题特征参数不断互相校正、反复迭代，求取对参数的稳定估计结果。

2.4.2 贝叶斯估计

以上提到的参数估计方法是仅使用学习者对试题的作答结果数据对学习者和试题的特征参数进行估计，参数估计结果是最能拟合已有学习者试题作答结果数据的求解结果，这会导致利用参数估计结果预测学习者的试题作答结果时出现过拟合问题。实际上，还有一些先验信息也可以应用到参数估计中，以提高参数估计结果的实际解释性，避免过拟合。

贝叶斯估计的核心思想是联合求解参数的先验信息以及似然函数获取参数的后验分布，从而对参数进行估计：

$$P(\theta,a,b|R)\propto L(\theta,a,b|R)P(\theta)P(a)P(b) \tag{2.10}$$

式 2.10 中，$P(a)$和$P(b)$表示试题特征参数的先验分布，$P(\boldsymbol{\theta})$表示学习者特征参数的先验分布，$L(\theta,a,b|R)$表示似然函数，$P(\theta,a,b|R)$表示待求解参数的联合后验分布。

与极大似然估计区别的是式 2.10 中含有待求解参数的先验分布信息，除此之

外，贝叶斯估计的求解过程与极大似然估计相同。先验分布的作用是起收缩作用，将参数的估计值收缩到先验分布的均值附近。

2.4.3 马尔可夫链蒙泰卡罗

马尔可夫链蒙泰卡罗（Markov Chain Monte Carlo，MCMC）是基于贝叶斯估计的抽样算法，在利用贝叶斯公式计算出求解参数的后验概率分布之后，设计马尔可夫链采样生成满足该后验概率分布的样本序列，并计算样本的均值作为对对应参数的估计求解结果。

（1）蒙泰卡罗

蒙泰卡罗是一种随机模拟的方法。具体是指在求解概率问题的时候，对随机过程进行模拟，并根据观测到的模拟结果得到问题的解。基本的随机过程比如均匀分布抽样可以通过线性同余发生器来模拟，在此基础上，其他一些常见的概率分布基本都可以通过均匀分布得到的采样样本进行数据变换得到。但是对于复杂的概率分布，均匀分布无法转换，此时通常采用接受-拒绝采样来得到满足该分布的样本序列。如对图 2.4 中概率分布 $p(z)$ 进行抽样，可以先设定一个方便采样的常用概率分布 $q(z)$ 和常量 k，使得满足 $p(z) <= kq(z)$。采样时，首先得到 $kq(z)$ 的一个样本 z_0,然后从均匀分布 $(0, kq(z_0))$ 中采样得到一个值 u_0，如果 u_0 落在了图中的浅色区域，则拒绝这次抽样，否则，接受这个样本。重复以上过程得到 n 个接受的样本为抽样序列。但是，蒙泰卡罗方法在很多情况下还是难以得到想要的概率分布的抽样样本序列，比如对于二维分布 $p(x, y)$，大部分情况只能得到条件分布 $p(y|x)$ 和 $p(x|y)$，难以得到 $p(x, y)$ 的一般形式，这时候蒙泰卡罗方法就无法适用，另外，对于一些高维的复杂概率分布 $p(x_1, x_x, ...x_n)$，是难以找到一个蒙泰卡罗方法中需要的概率分布 $q(z)$ 和常量 k 的，因此使用蒙泰卡罗方法对复杂概率分布模拟采样时，具有一定的局限性。而马尔科夫链可以帮助生成这些复杂概率分布对应的抽样样本序列。

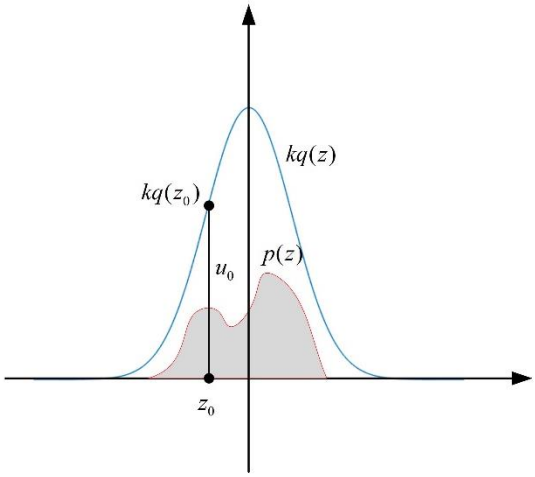

图 2.4 复杂概率密度抽样

（2）马尔可夫链

假设事物的在任何时刻所处的状态都是状态集合 $I=\{s_1,s_s,...s_N\}$ 中的元素。随着时间的变化，事物在不同的状态之间跳转，并且事物在任意时刻所处的状态只跟它前一时刻所处的状态有关，与其他时刻无关，该过程称为马尔可夫过程。对马尔可夫过程相继观测事务所处的状态构成马尔可夫链。马尔可夫链状态与状态之间的转移是随机的，常使用一个 $N*N$ 的状态转移矩阵 P 来表示状态之间转移的概率，$P=\{p_{ij}\}_{I\times J}$，p_{ij} 表示状态 i 转移到状态 j 的概率。当状态之间经过足够多次的转移之后，如果满足：

$$\pi=\pi P \tag{2.11}$$

则称 $\pi=(\pi_1,\pi_2,...\pi_N)$ 为马尔可夫链的平稳分布。平稳分布 π 意味着，在马尔可夫链的平稳期，状态 i 以 π_i 的稳定概率出现。并且只要状态转移矩阵已知，不论初始状态如何，所生成的马尔可夫链在平稳期都具有同样的唯一平稳分布。因此，只需要构造合适的马尔可夫链，就可以对其平稳期采样，得到满足指定概率分布的采样样本序列。

（3）基于马尔可夫链蒙泰卡罗的抽样

构造符合指定概率分布的马尔可夫链的关键就是构造合适的状态转移矩阵。对于马尔可夫链的状态转移矩阵 P 和概率分布 $\pi(x)$ 而言，当满足以下条件：

$$\pi(i)P(i,j)=\pi(j)P(j,i) \tag{2.12}$$

$\pi(x)$ 同样为马尔可夫链的平稳分布。

为了令 $\pi(x)$ 为我们需要的分布，需要找到满足式 2.12 的状态转移矩阵 P。对式 2.12 进行改造，引入一个拒绝接受概率 α，令：

$$\alpha(i,j)=\pi(j)P(j,i) \tag{2.13}$$

$$\alpha(j,i)=\pi(i)P(i,j) \tag{2.14}$$

则下式 2.15 恒成立。

$$\pi(i)P(i,j)\alpha(i,j)=\pi(j)P(j,i)\alpha(j,i) \tag{2.15}$$

令 $P'(i,j)=P(i,j)\alpha(i,j)$ 为新构造的状态转移矩阵，就可以得到期望的稳定分布 $\pi(x)$。也就是说，新构造的状态转移矩阵 P' 可以通过任意一个状态转移矩阵 P 与 α 相乘得到。α 一般称之为接受率，即根据新构造的状态转移矩阵，状态 i 首先以 $p(i,j)$ 的概率转移到状态 j，然后以 $\alpha(i,j)$ 的概率接受状态 j 作为抽样样本。

2.5 评估模型对比分析

在此，采用两个常用标准数据集 FrcSub[38]、Math[39]对 IRT、DINA 以及 FuzzyCDF 模型进行对比实验，评估 3 个模型的拟合与预测表现。数据集中包含了试题作答记录以及 Q 矩阵，FrcSub、Math 数据集的基本情况如下表 2.1 所示：

表 2.1 数据集基本情况

数据集	学习者数量	知识点数量	试题数量
FrcSub	536	8	20
Math	4209	11	15

对每个数据集随机抽取一定比例的试题作答记录作为训练集，评估学习者以及试题特性，然后基于评估结果对剩下的试题作答记录进行预测，分别对比评估模型对训练集数据的拟合表现以及对测试集数据的预测效果。

（1）FrcSub 数据集实验与分析

表 2.2 FrcSub 数据集拟合准确率

模型\训练数据比例	30%	40%	50%	60%	70%
IRT	0.8578	0.8587	0.8475	0.8506	0.8536
DINA	0.9012	0.8942	0.9023	0.8959	0.8866
Fuzzy-CDF	0.8856	0.8774	0.8746	0.8633	0.8661

表 2.3 FrcSub 数据集预测准确率

模型\训练数据比例	30%	40%	50%	60%	70%
IRT	0.7882	0.8022	0.8089	0.8179	0.8217
DINA	0.7212	0.7520	0.7678	0.7813	0.8067
Fuzzy-CDF	0.8047	0.8180	0.8246	0.8337	0.8356

FrcSub 的数据集规模较小，仅包含了 536 名学习者、20 道试题以及 8 个知识点。从拟合效果上来看，DINA 模型的拟合效果基本最佳，FuzzyCDF 模型次之，IRT 模型的拟合效果最差。在预测效果上，FuzzyCDF 模型的预测效果是最优的，说明该模型较好的建模了学习者的认知反应结构，IRT 模型的效果稍次于 FuzzyCDF 模型，DINA 模型的预测效果最差。

（2）Math 数据集实验分析

表 2.4 Math 数据集拟合准确率

模型\训练数据比例	30%	40%	50%	60%	70%
IRT	0.7362	0.7381	0.7305	0.7303	0.7346
DINA	0.7812	0.7790	0.7810	0.7734	0.7622
Fuzzy-CDF	0.7413	0.7297	0.7372	0.7392	0.7325

表 2.5 Math 数据集预测准确率

模型\训练数据比例	30%	40%	50%	60%	70%
IRT	0.6679	0.6751	0.6783	0.6845	0.6857
DINA	0.6436	0.6454	0.6508	0.6488	0.6491
Fuzzy-CDF	0.6769	0.6794	0.6830	0.6850	0.6896

Math 数据集的规模较 FrcSub 数据集有了显著提升，包含了 4209 名学习者对 15 道试题的作答记录，涉及知识点的数量为 11。从拟合效果来看，DINA 模型效果最佳，FuzzyCDF 模型次之，IRT 模型最差。从预测效果来看， FuzzyCDF 模型的预测效果最好，IRT 模型次之，DINA 模型效果最差。

IRT、DINA 以及 FuzzyCDF 3 个模型对 FrcSub 和 Math 数据集的拟合与预测性能的优劣情况基本一致，其中 FuzzyCDF 模型的预测效果是最优的。这说明高阶、多维的认知诊断模型相比较低阶、单维的认知诊断模型更符合学习者的认知规律。因此，还可以考虑研究认知诊断模型的高阶特性，并对学习者的高阶潜在特征进行扩展——学习者的高阶潜在特征可以分为先天能力特征与后天努力特征，从而构建新的认知诊断模型。

2.6 本章小结

本章主要介绍了四个方面的相关理论知识。第一方面是学习者测验理论，介绍了学习者测验理论的发展过程，分析了各个阶段测验理论的特点与缺陷。第二方面是认知诊断理论，详细介绍了认知诊断理论的基本组成。第三方面是认知诊断模型，分别介绍了认知诊断领域常用的几种经典模型：IRT 模型、MIRT 模型、融合模型、DINA 模型和 HO-DINA 模型。第四方面是模型的求解算法，因此认知诊断模型为概率模型，因此需要借助统计学参数估计的方法对模型中的待求解参数进行求解，主要介绍了仅考虑参数似然性的极大似然法与结合先验信息、似然函数的马尔可夫链蒙泰卡罗算法。最后，基于真实数据集 FrcSub 和 Math 评估了几类基本认知诊断模型的拟合与预测表现。

第 3 章　面向慕课学习者评估的认知反应模型

认知诊断模型是根据学习者的试题作答结果对学习者的知识水平进行评估的。现有认知诊断模型按照模型的深度可以分为两类：一类是低阶模型，比如 DINA,IRT 模型，仅对学习者的知识水平与试题作答结果之间的潜在关系进行建模。因此当评估学习者的知识水平时，只需要考虑学习者的试题得分记录。还有一类是高阶模型，比如 HO-DINA、Fuzzy-CDF 模型,高阶模型认为试题得分是知识水平的具体体现，但是更深层次的，学习者的知识水平受学习者更高阶的潜在特征——能力特征所主导。因此需要评估学习者高阶的能力特征，然后再得出学习者的知识水平。另外还有一些学者根据认知诊断模型设计神经网络结构，利用试题得分训练神经网络，得到对学习者知识水平评估的结果。本章提出了一种引入努力特征的新的高阶认知诊断模型——认知反应模型(Cognitive and Response Model,C&RM)，该模型考虑知识对能力、努力特征的联合考察性以及这两维特征之间的互相补偿效果，设置了联合补偿机制，通过融合能力、努力二维特征来表征学习者的知识水平。此外，模型中还引入了知识点弱项这一特征参数，以综合考虑学习者的知识水平与不同知识点对作答试题影响的重要性等级，提高模型的解释性。

3.1 C&RM 结构

在 C&RM 结构中，学习者的整个学习过程被划分为两个阶段：认知阶段和反应阶段。认知阶段中，学习者通过个体的学习活动对课程涉及的知识有了不同程度的掌握；反应阶段中，学习者运用自身掌握的知识对试题进行作答，同时考虑偶然因素（失误、猜测等），形成了学习者对试题不同的得分情况。

C&RM 的结构如下图 3.1 所示：

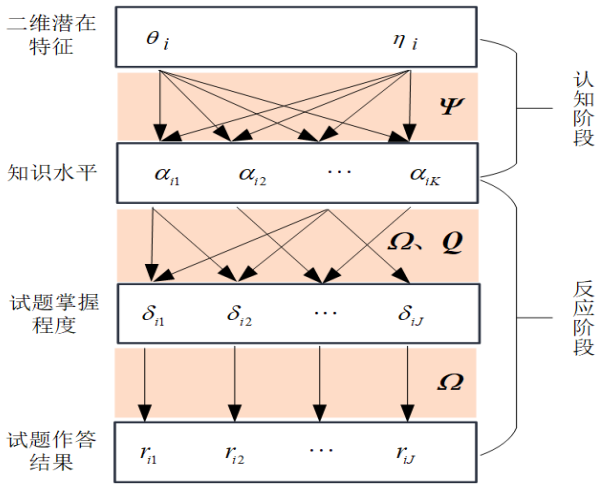

图 3.1 C&RM 结构图

C&RM 是一个四层的高阶模型。这四层从顶向下分别为高阶潜在特征（学习者对某一领域的先天学习能力，后天所花费的努力），知识水平（学习者对课程涉及的知识点的掌握程度），试题掌握程度（在仅考虑学习者知识掌握的条件下得到对考试试题的掌握程度），试题作答结果（在综合考虑粗心、猜测等偶然因素的条件下，根据学习者对考试试题的掌握程度得到作答结果，正确还是错误）。上图 3.1 中，$\boldsymbol{\theta}$ 表示学习者群体的能力特征向量，$\boldsymbol{\theta}=[\theta_1,\theta_2...\theta_I]$，$\theta_i$ 为学习者 i 的能力特征，I 为学习者人数。$\boldsymbol{\eta}$ 表示学习者群体的努力特征向量，$\boldsymbol{\eta}=[\eta_1,\eta_2...\eta_I]$，$\eta_i$ 为学习者 i 的努力特征。$\boldsymbol{\Psi}$ 为课程知识特性矩阵，$\boldsymbol{\Psi}=[\boldsymbol{\Psi}_1,\boldsymbol{\Psi}_2...\boldsymbol{\Psi}_K]^T$，$\boldsymbol{\Psi}_k$ 表示知识点 k 的特征向量，每个知识点有多个特征参数，K 为课程知识点数量。$\boldsymbol{\alpha}$ 表示学习者群体的知识水平矩阵，$\boldsymbol{\alpha}=[\boldsymbol{\alpha}_1,\boldsymbol{\alpha}_2,...\boldsymbol{\alpha}_I]^T$，$\boldsymbol{\alpha}_i=[\alpha_{i1},\alpha_{i2}...\alpha_{iK}]$，$\alpha_{ik}$ 为学习者 i 对知识点 k 的知识水平。$\boldsymbol{\Omega}$ 表示试题特性矩阵，$\boldsymbol{\Omega}=[\boldsymbol{\Omega}_1,\boldsymbol{\Omega}_2...\boldsymbol{\Omega}_J]^T$，$\boldsymbol{\Omega}_j$ 为试题 j 的特征向量，每道试题有多个特征参数，J 为试题的数量。$\boldsymbol{Q}$ 为试题-知识点考察矩阵，$\boldsymbol{Q}=[\boldsymbol{q}_1,\boldsymbol{q}_2...\boldsymbol{q}_J]^T$，$\boldsymbol{q}_j=[q_{j1},q_{j2}...q_{jK}]$，$q_{jk}$ 取值为二元类型，$q_{jk}=1$ 表示试题 j 考察了知识点 k，$q_{jk}=0$ 表示试题 j 未考察知识点 k。$\boldsymbol{r}$ 为学习者的试题作答结果矩阵，$\boldsymbol{r}=[\boldsymbol{r}_1,\boldsymbol{r}_2...\boldsymbol{r}_I]^T$，$\boldsymbol{r}_i=[r_{i1},r_{i2}...r_{iJ}]$，$r_{ij}$ 为学习者 i 对试题 j 的作答结果，取值为二元类型，$r_{ij}=1$ 表示作答正确，$r_{ij}=0$ 表示作答错误。

3.2 认知阶段建模

认知阶段指的是学习者对课程涉及的知识点学习掌握的阶段。在认知过程中，学习者不仅依靠天赋，也付出了努力。因此，学习者通过认知过程所具备的知识水平不仅与其先天能力有关，还与后天所付出的努力相关。出于这种考虑，学习者的知识水平应当由学习者的努力特征、能力特征知识特征三个主要因素决定。

$$\boldsymbol{\alpha}_i = f(\theta_i, \boldsymbol{\Psi}, \eta_i) \tag{3.1}$$

式 3.1 中，$\boldsymbol{\alpha}_i$表示学习者i的知识水平，$\boldsymbol{\alpha}_i = [\alpha_{i1}, \alpha_{i2} ... \alpha_{iK}]$，$\alpha_{ik}$表示学习者$i$对知识点$k$的掌握程度（知识水平），$\theta_i$表示学习者$i$的能力特征，$\eta_i$表示学习者$i$的努力特征，$\boldsymbol{\Psi}$表示知识特征矩阵，$\boldsymbol{\Psi} = [\boldsymbol{\Psi}_1, \boldsymbol{\Psi}_2 ... \boldsymbol{\Psi}_K]^T$，$\boldsymbol{\Psi}_k$表示知识点$k$的特征向量。$f(\square)$为需要建立的认知模型。

3.2.1 二维潜在特征

在对课程知识的学习过程中，并不是每一个学习者对知识的掌握都能实现从 0 到 1 的递增过程，一般情况下，不同的学习者所能达到的知识水平是不同的，造成这个差异的原因与学习者的个体潜在特征有关，这种个体潜在特征也被称为“能力”。这里所说的“能力”既包括学习者先天具备的能力，也包括学习者后天投入的努力。

3.2.1.1 先天能力特征的衡量

不同的学习者具备的能力是不同的，从经验上考虑，能力越高的学习者，其知识水平也应当越高。即学习者的知识水平对能力参数而言是单调递增的。除此之外，每个学习者的能力在群体中的位置是确定的，与学习的知识、作答的习题的难度无关，即无论是学习高难度的知识，参与高难度的考试，还是学习低难度的知识，参与低难度的考试，对学习者能力特征的评估结果应当是不变的。因此需要设计一个不依赖知识特性、试题特性的数值量来定义学习者的能力参数。

假设学习者i的能力特征参数使用θ_i表示（这里仅考虑学习者具有单一维度的能力特征），K表示课程知识点组成的集合，其中每个知识点的学习都依赖学习者的能力特征θ_i，F表示所有学习者组成的集合。

从K中任意取出 1 个知识点，从F随机取出I个学习者对该知识点进行学习，α_{ik}表示学习者i对该知识点k的掌握程度，令

$$P_{ik} = \frac{\text{对知识点}k\text{掌握程度不超过}\alpha_{ik}\text{的学习者数量}}{I} \tag{3.2}$$

P_{ik}表示学习者i对知识点k的掌握程度在所有学习者中的百分比。例如，如果P_{ik}=80%，表示 80%的学习者对知识点k的掌握程度不超过学习者i。当选择同一

批学习者学习不同的知识点 1 和 2 时，尽管受知识特性的影响，学习者 i 对这两个知识点的掌握程度可能不同，$\alpha_{i1} \neq \alpha_{i2}$。但是，由于同一批学习者中，每个学习者的能力特征在群体中的位置是固定的，并且知识点的学习与学习者的能力正相关，所以每个学习者对不同知识点的掌握程度在该批次学习者群体中的占据的百分比也是相同的，$P_{i1} = P_{i2}$，即对于 k 的不同取值，P_{ik} 都是相同的。P_{ik} 可简写为 P_i，P_i 是一个不变量，它仅与学习者有关，与知识特性无关，可以使用该不变量定义学习者的能力参数。

式 3.2 是用来衡量学习者的知识掌握程度在所有学习者中所占据的比例，因为知识掌握程度与学习者的能力特征正相关，所以它与学习者的能力特征在所有学习者中占据的比例是相同的。假定学习者群体的能力参数服从标准正态分布，则学习者 i 的能力特征参数 θ_i 与不变量 P_i 具备下式 3.3 中的关系：

$$P_i = \int_{-\infty}^{\theta_i} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt \tag{3.3}$$

式 3.3 中，能力参数为 θ_i 的学习者在所有学习者中所占百分比为 P_i，由于 θ_i 满足标准正态分布，所以 P_i 等于标准正态分布在 $-\infty \sim \theta_i$ 区间的累积分布值。

根据证明[40]，标准正态分布的累计函数有以下近似关系：

$$\int_{-\infty}^{\theta_i} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt \approx \frac{1}{1+e^{-1.7\theta_i}} \tag{3.4}$$

式 3.4 中的近似函数不再包含积分运算，更容易求解，并且对于 θ_i 在整个实数区间内，近似误差小于 0.01。因此，式 3.4 的近似计算公式为：

$$P_i = \frac{1}{1+e^{-1.7\theta_i}} \tag{3.5}$$

3.2.1.2 后天努力特征的衡量

学习者的后天努力特征作为另一维度的潜在特征，在对学习者知识水平的影响效果上应当与学习者的努力特征相似。此外，学习者的后天努力特征还与其先天能力特征有所不同：学习者的后天努力是有具体体现的，比如学习者对课程内容、作业、测验等相关学习活动所付出的精力。学习者在慕课平台学习的同时，慕课平台也收集了学习者相关的学习活动信息。因此，可以利用慕课数据中学习者相关学习活动数据直接量化评估学习者的努力特征，然后将量化之后的努力特征应用到认知模型构建中。

为了使学习者的努力特征与能力特征在取值上具有相同的量纲（取值范围 $-\infty \sim +\infty$，服从标准正态分布），通过下式 3.6 得到学习者 i 的努力特征 η_i：

$$\int_{-\infty}^{\eta_i} f(x)dx = \frac{rank(i)}{Total+1} \tag{3.6}$$

式 3.6 中，$f(x)$表示标准正态分布的概率密度，$Total$表示学习者群体中的学习者数量，$rank(i)$表示学习者i的努力程度在学习者群体中的逆序排名位次，例如$rank(i)=1$表示学习者i排名为倒数第一名。通过上式 3.6 变换得到的学习者努力特征η不仅维持所有学习者原来的努力程度排名位次，并且还服从标准正态分布。

3.2.2 知识水平衡量

3.2.2.1 单维潜在特征决定下的知识水平

学习者的知识水平除了跟学习者本身的潜在特征有关，还与知识的特性有关，这些特性包括知识的难度以及知识对学习者能力的区分度。

在仅考虑学习者具备单维潜在特征（以能力特征为例）的条件下，根据式 3.5，不超过θ_i能力的学习者占学习者群体的百分比为P_i。定义学习者i对知识点k的知识水平α_{ik}的取值区间为$[0,1]$，当且仅当$P_i=100\%$时，学习者的知识水平为 1。同时考虑知识特性，对知识水平建模如下：

$$\alpha_{ik}=\frac{1}{1+e^{-1.7(a_k(\theta_i-b_k))}} \tag{3.7}$$

式 3.7 中，a_k和b_k为知识点k的特征参数，a_k表示知识点k对学习者能力特征θ_i的区分度，因为学习者知识水平与其能力特征是正相关的，所以区分度a_k的取值范围为$(0,\infty)$，b_k表示知识点k的难度，该难度参数应当与学习者的能力参数在同一个量纲，因此难度参数b_k的取值范围内为$-\infty\sim\infty$。

根据式 3.7,能力特征对知识水平的影响关系如下图 3.2 所示：

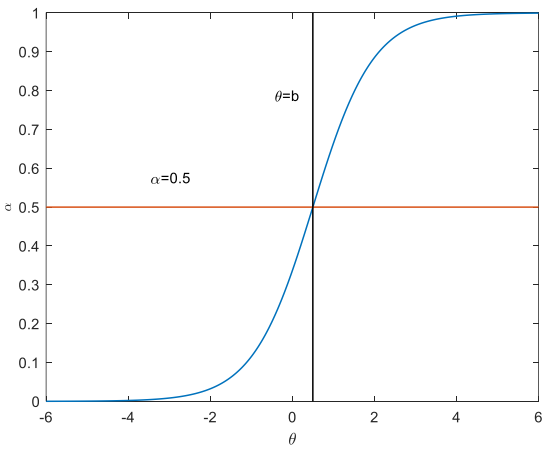

图 3.2 单维潜在特征决定下的知识水平

上图 3.2 中，横坐标为能力特征参数θ，纵坐标为知识水平参数α,区分度参数a取值为 0.8，难度参数b取值为 0.5。从图 3.2 中可以看出，能力特征越高，知识水平越高，当学习者的能力特征θ恰好与难度参数b相等时，知识水平为 0.5。此外，在能力特征过高或过低时，知识水平的变化都是比较平缓的。这是因为当学习者的能力特征很高时，凭借自身能力学习该知识是轻而易举的，即使能力再提

高，自身知识水平的提升也是微乎其微的。同样当学习者的能力特征很低时，凭借自身能力学习该知识是十分困难的，即使能力再降低，自身知识水平下降的幅度也是十分有限的。

3.2.2.2 二维潜在特征决定下的知识水平

式 3.7 中，将学习者的能力参数表示为一维的参数，但是前面提到，学习者的能力参数应当包括学习者的先天能力特征以及后天努力特征，并且可以认为能力特征与努力特征之间是相互独立的，因此需要对式 3.7 进行扩展，使用能力特征、努力特征二维特征来表征学习者的知识水平。

（1）考虑补偿机制的知识水平表示

能力特征、努力特征在对知识水平的影响效果上是可以相互补偿的，即能力低的学习者可以通过提升努力达到和能力高的学习者同样的知识水平。此外，这种补偿效果也是有限的，某些能力特征或努力特征低于一定范围的学习者，即使可以通过另一维度特征的提升而取得一些补偿效果，但是这种补偿效果并不能让学习者可以达到任意高的知识水平。因此，二维潜在特征决定的知识水平应当位于能力特征与努力特征分别在仅考虑单维潜在特征的条件下对应的知识水平之间：

$$\min[\alpha_{ik}(\theta_i),\alpha_{ik}(\eta_i)] \le \alpha_{ik}(\theta_i,\eta_i) \le \max[\alpha_{ik}(\eta_i),\alpha_{ik}(\eta_i)] \tag{3.8}$$

式 3.8 中，$\alpha_{ik}(\theta_i)$、$\alpha_{ik}(\eta_i)$ 分别表示将学习者的能力特征、努力特征代入式 3.7 中计算得到的知识水平，$\alpha_{ik}(\theta_i,\eta_i)$ 表示二维潜在特征决定的知识水平，上式 3.8 中，等号仅在 $\alpha_{ik}(\theta_i)$=$\alpha_{ik}(\eta_i)$ 时成立。

考虑上述补偿关系，构建如下式 3.8、3.9 所示的知识水平与二维潜在特征的关系表达式：

$$\alpha_{ik} = \frac{w_{k1}}{1+\exp(-1.7*(\theta_i - d_{\theta k1}))} + \frac{w_{k2}}{1+\exp(-1.7*(\eta_i - d_{\eta k1}))} \tag{3.9}$$

$$w_{k1} + w_{k2} = 1 \tag{3.10}$$

$d_{k\theta 1}$、$d_{k\eta 1}$ 分别表示知识点 k 对能力特征 θ_i 和努力特征 η_i 的难度参数。w_{k1}、w_{k2} 表示知识点 k 对能力特征、努力特征的区分度参数，取值为 0-1 之间，表示知识点 k 对能力特征 θ_i 与努力特征 η_i 的依赖程度。w_{k1}=0 表示知识点 k 的学习仅依赖学习者的努力特征，与能力特征无关；w_{k2}=0 表示知识点 k 的学习与学习者的努力特征无关，仅依赖学习者的能力特征。

根据上述关系表达式，二维特征对知识水平的影响关系如下图 3.3、3.4 所示：

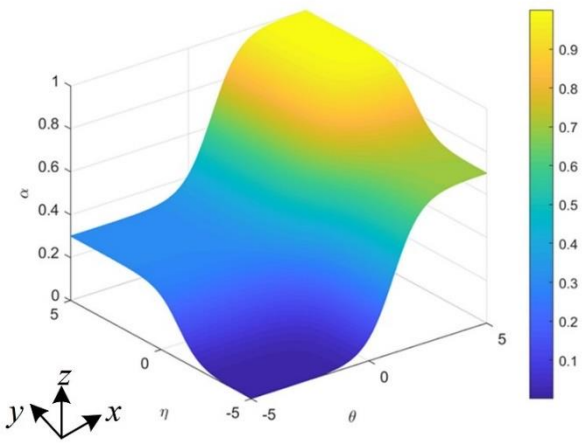

图 3.3 二维潜在特征决定的知识水平（平视图）

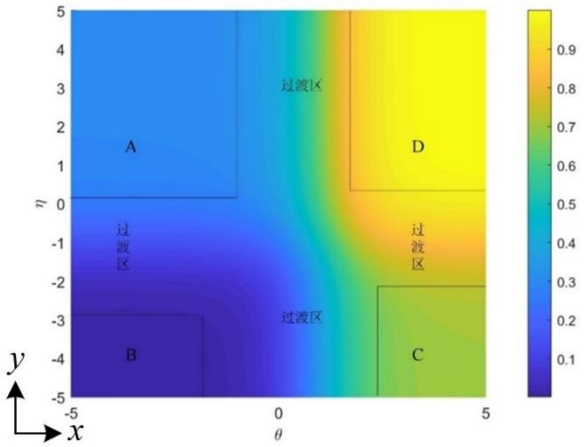

图 3.4 二维潜在特征决定的知识水平（俯视图）

图 3.3、3.4 中，x 轴方向为能力特征参数 θ，y 轴分析为努力特征参数 η，z 轴方向为知识水平参数 α，$w_{k1}=0.7$，$w_{k2}=0.3$，$d_{\theta k1}=1$，$d_{\eta k1}=-1$。由图 3.3、3.4 可以看出，学习者的知识水平随能力特征与努力特征的变化出现了明显的区域划分。图 3.4 中，A 区表示能力特征低，努力特征高； C 区表示努力特征低，能力特征高。B 区表示二维特征参数都低；D 区表示二维特征参数都高。区域内为模糊区分特征参数的平稳段，区域之间为显著区分特征参数的过渡段。另外，C 区的知识水平要高于 A 区，对应了知识水平对能力特征的依赖权重 w_{k1} 大于对努力特征的依赖权重 w_{k2}。

下图 3.5 是二维潜在特征决定的知识水平与单维潜在特征决定的知识水平的效果对比图。

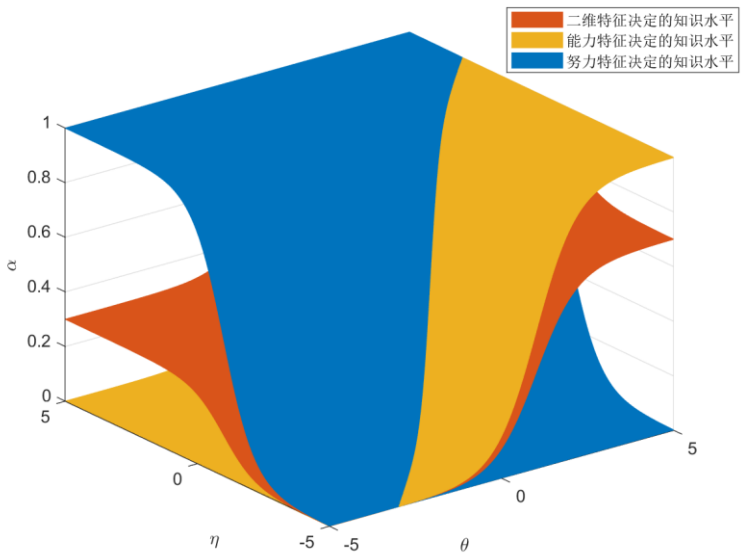

图 3.5 二维潜在特征与单维潜在特征决定的知识水平对比图

图 3.5 中，二维潜在特征决定的知识水平图被夹在两个单维潜在特征决定的知识水平图中间，诠释了上文提到的能力特征与努力特征之间的补偿机制：能力特征与努力特征联合决定的知识水平介于能力特征、努力特征分别在仅考虑单维潜在特质的条件下对应的知识水平之间。

（2）考虑联合补偿机制的知识水平表示

上述对知识水平的表征仍存在不足：在图 3.4 中，从 C、D 联合区（对应能力特征高的学习者）的学习者知识水平来看，在纵向上，知识水平随着努力特征 η 的减小而衰减，但是随着 η 的持续减小，知识水平仍维持在一个稳定的水平。这意味着，在极端情况下（这些学习者能力特征参数趋近于数值范围内的最小值的时候），学习者仍具有一定的知识水平，根据下式推导也可得到此结论：

$$\begin{aligned}&\lim_{\eta_i\to-\infty}\alpha_{ik}\\&=\lim_{\eta_i\to-\infty}\frac{w_{k1}}{1+\exp(-D*(\theta_i-d_{k\theta1}))}+\frac{w_{k2}}{1+\exp(-D*(\eta_i-d_{k\eta1}))}\\&=\frac{w_{k1}}{1+\exp(-D*(\theta_i-d_{k\theta1}))}\end{aligned}\tag{3.11}$$

这样一来，破坏了知识对学习者能力特征和努力特征的联合考察性。通常情况下，考虑极端情况，当能力特征与努力特征中的任意一维趋近于最小值的时候，学习者的知识水平也应当趋近于最小值。

因此，在考虑补偿效果的基础上分别对能力特征、努力特征引入衰减项，使得能力特征对努力特征的补偿效果随着努力特征的降低而逐渐衰减，同样，努力特征对能力特征的补偿效果也要随着能力特征的降低而衰减。上图 3.4 中，C 区代表的学习者的知识水平主要依赖于能力特征的补偿效果，知识水平下限的主要

依赖项是$\frac{w_{k1}}{1+\exp(-D*(\theta_i-d_{k\theta1}))}$，使用$\beta_{\theta_i k}=\frac{1}{1+w_{k2}\exp(-D*(\eta_i-d_{k\eta2}))}$作为补偿系数。分母系数$w_{k2}$为知识点$k$对努力特征的依赖参数，该值越大，$\lambda_{\eta_i k}$越小，说明努力特征越重要，因努力特征参数低导致能力特征对努力特征补偿效果越弱。同理利用$\beta_{\eta_i k}=\frac{1}{1+w_{k1}\exp(-D*(\theta_i-d_{k\theta2}))}$作为 A 区的衰减参数。

综上，结合补偿效果、联合考察性等考虑，构建联合补偿机制，对二维潜在特征决定下的知识水平表示如下：

$$\alpha_{ik}=\frac{\beta_{\theta_i k}w_{k1}}{1+\exp(-D*(\theta_i-d_{\theta k1}))}+\frac{\beta_{\eta_i k}w_{k2}}{1+\exp(-D*(\eta_i-d_{\eta k1}))} \tag{3.12}$$

$$\beta_{\theta_i k}=\frac{1}{1+w_{k2}\exp(-D*(\eta_i-d_{\eta k2}))} \tag{3.13}$$

$$\beta_{\eta_i k}=\frac{1}{1+w_{k1}\exp(-D*(\theta_i-d_{\theta k2}))} \tag{3.14}$$

$$w_{k1}+w_{k2}=1 \tag{3.15}$$

式中，α_{ik}为知识水平参数。θ_i、η_i分别为学习者i的能力特征与努力特征。w_{k1}，w_{k2}分别表示知识点k对学习者能力特征、努力特征的考察权重。$\beta_{\theta_i k}$，$\beta_{\eta_i k}$分别为能力特征或努力特征对知识水平作用效果的衰减系数。以$\beta_{\theta_i k}$为例说明，它是能力特征对知识水平作用效果的衰减系数，由式 3.13 可以看出，$\beta_{\theta_i k}$与努力特征权重w_{k2}负相关，与努力特征η_i正相关，这是因为知识的获取是对能力、努力两种特征联合考察的，当努力特征较低的时候，能力特征对知识水平的原本作用效果会出现衰减，并且努力特征越重要，衰减效果越严重。$d_{\theta k1}$，$d_{\theta k2}$，$d_{\eta k1}$，$d_{\eta k2}$为相关截距参数。D为常数 1.7。

根据上述 3.12-3.15 关系表达式，能力特征、努力特征对知识水平的影响关系如下图 3.6 所示：

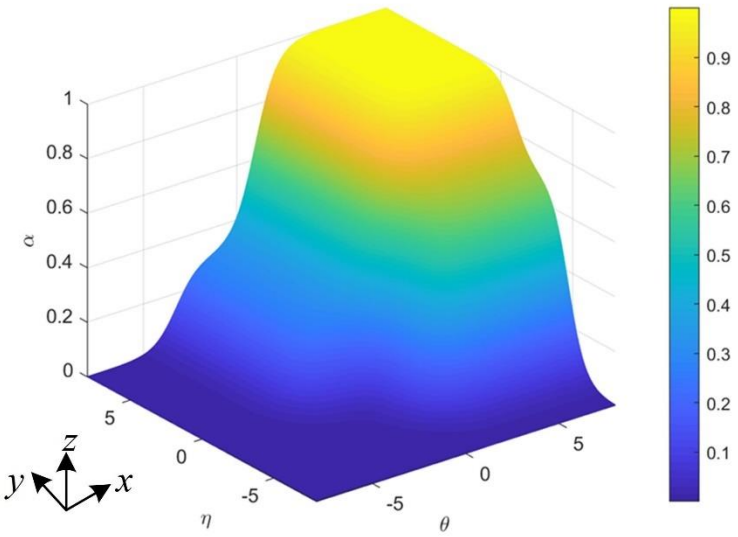

图 3.6 考虑联合补偿机制的知识水平（平视图）

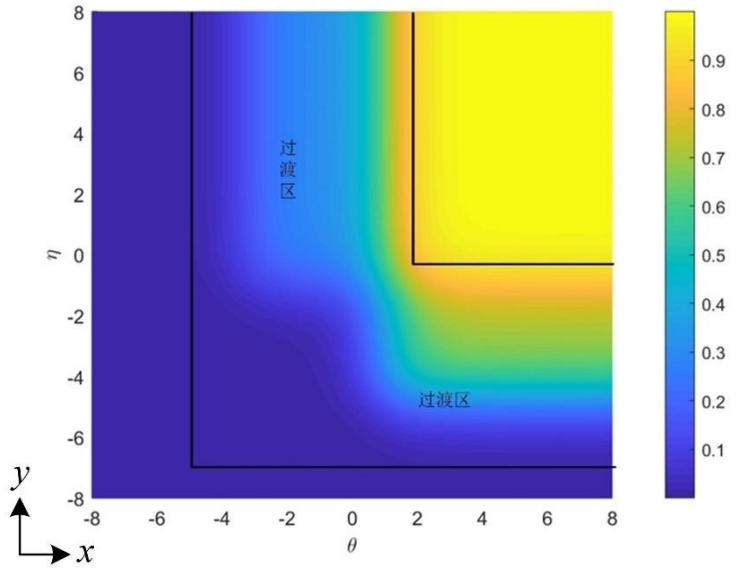

图 3.7 考虑联合补偿机制的知识水平（俯视图）

图 3.6、3.7 中，x 轴为能力特征参数 θ，y 轴为努力特征参数 η，z 轴为知识水平参数 α，$w_{k1}=0.7$，$w_{k2}=0.3$，$d_{\theta k1}=1$，$d_{\eta k1}=-1$，$d_{\theta k2}=-3$，$d_{\eta k2}=-4$。由上图 3.6 可以看出，学习者的知识水平在横向或纵向方向呈现双阶梯式衰减，并最终随着能力特征或努力特征的减小衰减为 0。分别从图 3.3、3.6 中取两个模型在 θ 和 η 方向的一条剖面线,绘制在下图 3.8、3.9 中。

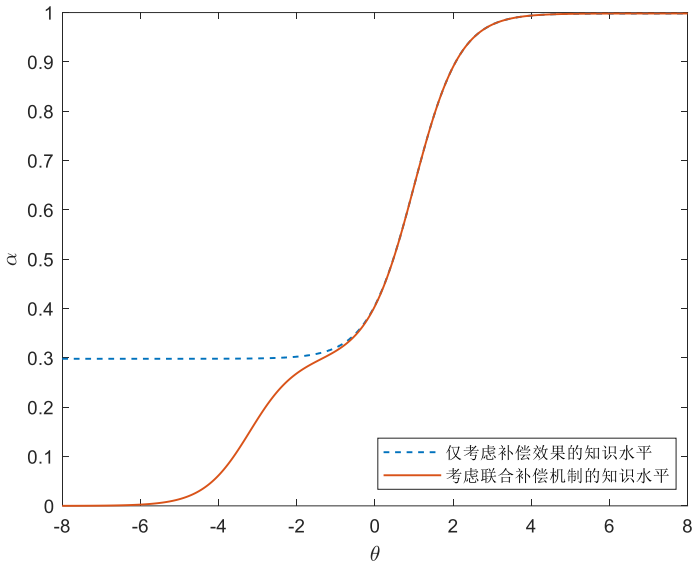

图 3.8 基于 θ 视角对比图

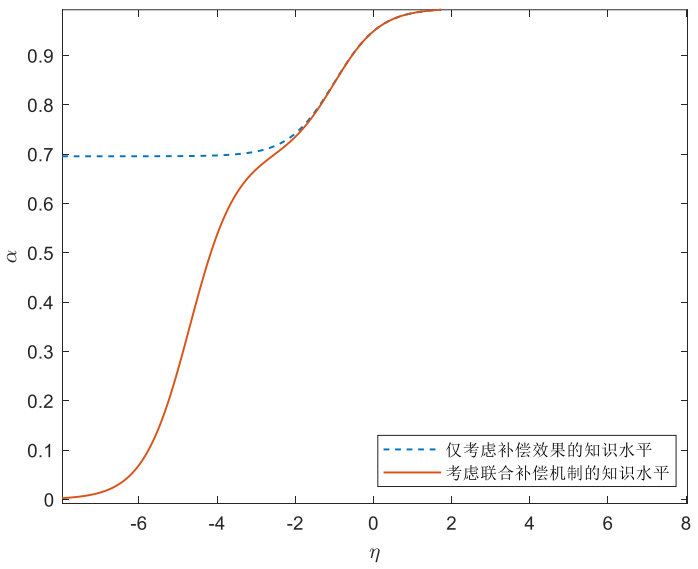

图 3.9 基于 η 视角对比图

可以明显观察到，在能力特征参数或努力特征参数足够大的时候，每个图中的两条曲线是接近重合的，这说明在该区间内，能力特征与努力特征之间的补偿效果是几近没有衰减的。当能力特征或努力特征低于该区间取值范围时，补偿系数造成的衰减效果才逐渐明显，考虑联合补偿机制的知识水平对应的曲线区别于仅考虑补偿效果的知识水平对应的曲线会一直持续衰减，直至衰减为 0。

3.2.2.3 联合补偿机制与证明

总结能力特征与努力特征对学习者知识水平的联合作用关系，学习者的能力特征与努力特征存在以下联合补偿机制：

①：能力特征与努力特征在对知识水平的作用中是具备相互补偿效果的，能力水平低的学习者可以通过提升努力水平达到和能力水平高的学习者同样的知识水平。

②：存在于能力特征与努力特征之间的补偿效果应当是有限的。某些能力特征或努力特征低于一定范围的学习者，即使可以通过另一维度属性的提升而取得一些补偿效果，但是这种补偿效果不是无尽的，而是具备上限的。

③：知识的获取是对学习者的能力特征和努力特征联合考察的。通常情况下，考虑极端情况，当能力特征或努力特征中的任意一维趋近于最小值，学习者的知识水平也应当趋近于最小值。

本文对使用二维潜在特征对知识水平的表示方式满足联合补偿机制的证明如下：

证明①：

式 3.12 中 α_{ik} 对 θ_i，η_i 单调递增，因此存在两名能力特征、努力特征分别为 (θ_1,η_1)、(θ_2,η_2) 的学习者 1 和 2，当 $\theta_1<\theta_2$ 时，存在 $\eta_1>\eta_2$，使得两人可以达到同样的知识水平 $\alpha_{1k}=\alpha_{2k}$。即单维特征低的学习者，可以通过另一维度特征的提升，达到相同的知识水平。

证明②：

$$\lim_{\eta_i\to\infty}\alpha_{ik}$$

$$=\beta_{\eta_i k}w_{k2}+\frac{w_{k1}}{1+\exp(-D*(\theta_i-d_{\theta k1}))}$$

$$\lim_{\theta_i\to\infty}\alpha_{ik}$$

$$=\beta_{\theta_i k}w_{k1}+\frac{w_{k2}}{1+\exp(-D*(\eta_i-d_{\eta k1}))}$$

当能力特征 θ_i 或努力特征 η_i 趋近于无穷大时，知识水平 α_{ik} 趋近于上限值 $\beta_{\theta_i k}w_{k1}+\frac{w_{k2}}{1+\exp(-D*(\eta_i-d_{\eta k1}))}$ 或 $\beta_{\eta_i k}w_{k2}+\frac{w_{k1}}{1+\exp(-D*(\theta_i-d_{\theta k1}))}$，而不是趋近于 1。说明单维特征的补偿效果是具备上限的。

证明③

$$\lim_{\eta_i\to-\infty}\alpha_{ik}$$

$$=\lim_{\eta_i\to-\infty}\frac{\beta_{\theta_i k}w_{k1}}{1+\exp(-D*(\theta_i-d_{\theta k1}))}+\frac{\beta_{\eta_i k}w_{k2}}{1+\exp(-D*(\eta_i-d_{\eta k1}))}$$

$$=0$$

$$\lim_{\theta_i \to -\infty} \alpha_{ik}$$

$$= \lim_{\theta_i \to -\infty} \frac{\beta_{\theta_i k} w_{k1}}{1+\exp(-D*(\theta_i - d_{\theta k1}))} + \frac{\beta_{\eta_i k} w_{k2}}{1+\exp(-D*(\eta_i - d_{\eta k1}))}$$

=0

当能力特征θ_i或努力特征η_i趋近于无穷小时，知识水平α_{ik}趋近于最小值 0。

3.3 反应阶段建模

通过对学习者的认知阶段建模，建立了学习者知识水平与其自身能力特征、努力特征的潜在关系结构。然而，不管是学习者能力特征还是知识水平都是学习者的潜在特征，无法直接测量，必须通过与知识特征相关的学习任务中推断出来。这种学习任务就是试题测验。因此需要对学习者运用知识作答习题的反应阶段建模，建立学习者的知识水平与试题作答结果之间的映射关系，并通过可观测的学习者的试题作答结果推断学习者的能力特征以及知识水平。

反应过程中，学习者的试题测验结果由学习者的知识水平以及试题的属性联合决定。

$$r_{ij} = h(\boldsymbol{\alpha}_i, \boldsymbol{\Omega}_j) \tag{3.16}$$

式 3.16 中，$\boldsymbol{\alpha}_i$表示认知模型中得到的学习者i的知识水平，$\boldsymbol{\alpha}_i = [\alpha_{i1}, \alpha_{i2} ... \alpha_{iK}]$。$\boldsymbol{\Omega}_j$表示试题$j$的属性。$r_{ij}$表示学习者$i$对试题$j$的作答结果。$h(\square)$则是需要建立的反应模型。

3.3.1 试题掌握程度表征

3.3.1.1 离散值表示的试题掌握程度

学习者对试题的掌握程度依赖于学习者对试题考察的知识点的掌握程度。与主观题分步作答、分步计分不同，在作答客观题时，学习者要么正确，要么错误。DINA 模型中，学习者对试题掌握程度是一个二元变量，即学习者只有掌握或不掌握两种状态，并且学习者只有掌握试题所考察的所有知识点，才能达到对试题完全掌握。根据 DINA 模型有：

$$\delta_{ij} = \prod_{k=1}^{K} \alpha_{ik}^{q_{jk}} \tag{3.17}$$

上式 3.17 中，α、δ、q取值范围为 0 或 1。对于$k = 1,...K$，当且仅当$q_{jk} = 1$且$\alpha_{ik} = 1$时，δ_{ij}=1。否则δ_{ij}=0.

3.3.1.2 连续值表示的试题掌握程度

客观题中的试题掌握程度受学习者对试题考察的知识点的掌握程度的联结型作用[41]。依此，Fuzzy-CDF[42]将学习者对联结型作用的试题的掌握程度模糊化为：

$$\delta_{ij} = \bigcap_{1 \le k \le K, q_{ik=1}} \alpha_{ik} \tag{3.18}$$

根据模糊交操作[43]：

$$\mu_{A \cap B}(x) = \min(\mu_A(x), \mu_B(x)) \tag{3.19}$$

可得：

$$\delta_{ij} = \min_{1 \le k \le K, q_{ik=1}} (\alpha_{ik}) \tag{3.20}$$

上式 3.20 中，学习者的知识水平参数 α_{ik} 与试题掌握程度 δ_{ij} 都为 $0-1$ 区间内的连续值。并且类比木桶效应，学习者掌握程度最差的知识点决定了学习者对试题的掌握程度。

3.3.1.3 改进的连续值表示的试题掌握程度

上式 3.20 中，学习者对试题考察的所有知识点的掌握水平中的最低值即为学习者对试题的掌握程度。但是，学习者掌握程度低的知识点可能对试题作答并不重要。为了更合理的对试题掌握程度进行建模，除了考虑学习者的知识水平之外，还需要考虑知识点对作答习题的重要性等级。令

$$l_{ijk} = \lambda_{jk}(1-\alpha_{ik}) \tag{3.21}$$

式 3.21 中，l_{ijk} 为知识弱项水平参数，l_{ijk} 表示学习者 i 在作答试题 j 时，知识点 k 对其造成知识弱项的程度。知识弱项水平 l_{ijk} 为知识点 k 对作答试题 j 的重要性 λ_{jk} 与学习者 i 对该知识点 k 未掌握程度 $1-\alpha_{ik}$ 的乘积，即知识点 k 在作答试题 j 时越重要且学习者 i 对该知识点 k 的掌握程度越低，那么知识点 k 构成知识弱项的程度就越高。基于知识弱项参数对学习者的试题作答结果建模如下：

$$1-\delta_{ij} = \max_{k=1,2...K \cap q_{jk}=1} (l_{ijk}) \tag{3.22}$$

式 3.22 表明，学习者对试题的掌握程取决于学习者对试题考察的知识点中弱项程度最高的。这既考虑了知识对试题的联结型作用，也考虑了试题中知识点的重要性。

3.3.2 试题作答结果

学习者对试题的作答结果除了跟学习者对试题的掌握程度有关之外，还与一些随机因素相关，比如学习者可能存在失误行为，即在掌握试题的情况下因为失误导致作答错误，以及猜测行为，即在未掌握试题的情况下通过猜测导致作答正确。考虑到这些随机因素，使用概率模型对学习试题作答结果建模如下：

$$P(r_{ij}=1|\delta_{ij},s_j,g_j)=(1-s_j)\delta_{ij}+g_j(1-\delta_{ij}) \tag{3.23}$$

式 3.23 中，s_j表示失误参数，即学习者在掌握试题的条件下因失误而错误作答的概率，$s_j=P(r_{ij}=0|\delta_{ij}=1)$。$g_j$表示猜测参数，即学习者在不掌握试题的条件下因猜测而正确作答的概率，$g_j=P(r_{ij}=1|\delta_{ij}=0)$。

3.4 参数估计算法

基于认知反应对学习者进行评估时，图 3.10 中阴影标记的各项参数为未知参数。其中，根据 3.2.2.2 节、3.3.1.3 节，可知试题特征向量为$\boldsymbol{\Omega}_j=[s_j,\boldsymbol{\lambda}_j,g_j]$,知识特征向量为$\boldsymbol{\Psi}_k=[w_{k1},w_{k2},d_{\theta k1},d_{\eta k1},d_{\theta k2},d_{\eta k2}]$。再由各参数之间的关系可知，只需要对参数$\boldsymbol{\theta}$、$\boldsymbol{\Psi}$、$\boldsymbol{\Omega}$进行求解，其他未知参数就可相继求出。

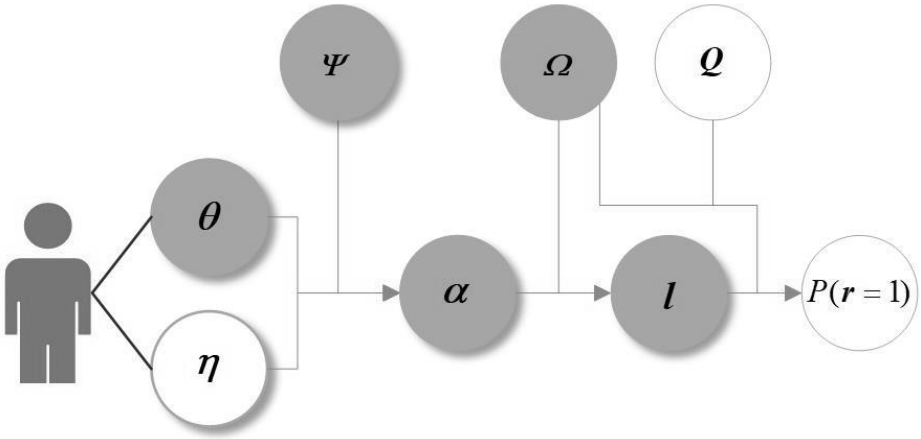

图 3.10 C&RM 参数估计思维路线图

根据贝叶斯公式，计算求解参数的联合后验分布：

$$P(\boldsymbol{\Psi},\boldsymbol{\theta},\boldsymbol{\Omega}|\boldsymbol{r})\propto P(\boldsymbol{\Psi})P(\boldsymbol{\theta})P(\boldsymbol{\Omega})L(\boldsymbol{r}|\boldsymbol{\Psi},\boldsymbol{\theta},\boldsymbol{\Omega}) \tag{3.24}$$

根据式 3.12-3.15,3.21-3.23 计算可得待求解参数的满条件分布分别为：

$$\begin{aligned}&P(\boldsymbol{\Psi}|\boldsymbol{\theta},\boldsymbol{\Omega},\boldsymbol{r})\propto P(\boldsymbol{\Psi})L(\boldsymbol{\theta},\boldsymbol{\Omega};\boldsymbol{\Psi})\\&=P(w_{k1})P(d_{\theta k1})P(d_{\eta k1})P(d_{\theta k2}|d_{\theta k1})P(d_{\eta k2}|d_{\eta k1})\\&\bullet\prod_{i=1}^{I}\prod_{j=1}^{J}(P(r_{ij}=1|\boldsymbol{\theta},\boldsymbol{\Omega},\boldsymbol{\Psi}))^{r_{ij}}(1-P(r_{ij}=1|\boldsymbol{\theta},\boldsymbol{\Omega},\boldsymbol{\Psi}))^{1-r_{ij}}\end{aligned} \tag{3.25}$$

$$\begin{aligned}&P(\boldsymbol{\theta}|\boldsymbol{\Psi},\boldsymbol{\Omega},\boldsymbol{r})\propto P(\boldsymbol{\theta})L(\boldsymbol{\Psi},\boldsymbol{\Omega};\boldsymbol{\theta})\\&=P(\boldsymbol{\theta})\prod_{j=1}^{J}(P(r_j=1|\boldsymbol{\theta},\boldsymbol{\Omega},\boldsymbol{\Psi}))^{r_j}(1-P(r_j=1|\boldsymbol{\theta},\boldsymbol{\Omega},\boldsymbol{\Psi}))^{1-r_j}\end{aligned} \tag{3.26}$$

$$\begin{aligned}&P(\boldsymbol{\Omega}|\boldsymbol{\Psi},\boldsymbol{\theta},r)\propto P(\boldsymbol{\Omega})L(\boldsymbol{\Psi},\boldsymbol{\theta};\boldsymbol{\Omega})\\&=P(\boldsymbol{\Omega})\prod_{i=1}^{I}(P(r_i=1|\boldsymbol{\theta},\boldsymbol{\Omega},\boldsymbol{\Psi}))^{r_i}(1-P(r_i=1|\boldsymbol{\theta},\boldsymbol{\Omega},\boldsymbol{\Psi}))^{1-r_i}\end{aligned} \tag{3.27}$$

基于 MCMC 的参数估计求解算法步骤如下所示（算法中转移概率计算参照式 3.25-3.27）：

Step1：生成 L 条马尔科夫链，对每条链随机初始化待估参数 $\boldsymbol{\Psi}^0$，$\boldsymbol{\theta}^0$，$\boldsymbol{\Omega}^0$；

Step2: 对每条马尔科夫链迭代执行（1）（2）（3），第 t 步迭代产生的 $\boldsymbol{\Psi}$，$\boldsymbol{\theta}$，$\boldsymbol{\Omega}$ 分别表示为 $\boldsymbol{\Psi}^t$，$\boldsymbol{\theta}^t$，$\boldsymbol{\Omega}^t$。

A1：对 $\boldsymbol{\Psi}$ 参数的计算，如下：

对于 $k=1,...K$，分别执行：

从均匀分布 $U(w_{k1}^t-\delta_{w_{k1}},w_{k1}^t+\delta_w)$，正态分布 $N(d_{\theta k1}^{t-1},\sigma_{d_\theta}^2)$，$N(d_{\eta k1}^{t-1},\sigma_{d_\eta}^2)$ 中分别随机抽样 w_{k1}^*，$d_{\theta k1}^*$，$d_{\eta k1}^*$，根据式（3.10）计算得到 w_{k2}^*，根据初始参数设置得到 $d_{\theta k2}^*$、$d_{\eta k2}^*$、δ_w、$\sigma_{d_\theta}^2$、$\sigma_{d_\eta}^2$；

通过如下的 $\boldsymbol{\Psi}_k^t$ 向 $\boldsymbol{\Psi}_k^*$ 转移概率计算式计算转移概率 $P(\boldsymbol{\Psi}_k^t,\boldsymbol{\Psi}_k^*)$：

$$P(\boldsymbol{\Psi}_k^t,\boldsymbol{\Psi}_k^*)=\min\{\frac{P(\boldsymbol{\Psi}^*|\boldsymbol{\theta}^t,\boldsymbol{\Omega}^t,\boldsymbol{r})}{P(\boldsymbol{\Psi}^t|\boldsymbol{\theta}^t,\boldsymbol{\Omega}^t,\boldsymbol{r})},1\}$$

其中，$\boldsymbol{\Psi}^*$ 为将 $\boldsymbol{\Psi}^t$ 中的第 k 维向量 $\boldsymbol{\Psi}_k^t$ 替换成 $\boldsymbol{\Psi}_k^*$ 得到的。

从均匀分布 $U(0,1)$ 中生成随机数 $rand$，若 $rand$ 小于等于转移概率 $P(\boldsymbol{\Psi}_k^t,\boldsymbol{\Psi}_k^*)$，则接受 $\boldsymbol{\Psi}_k^*=\{w_{k1}^*,w_{k2}^*,d_{\theta k1}^*,d_{\theta k2}^*,d_{\eta k1}^*,d_{\eta k2}^*\}$ 为 $\boldsymbol{\Psi}^t$ 中的第 k 维向量 $\boldsymbol{\Psi}_k^t$，否则对 $\boldsymbol{\Psi}^t$ 不作调整。

执行完 K 步后，令 $\boldsymbol{\Psi}^{t+1}=\boldsymbol{\Psi}^t$ 继续迭代。

A2：对 $\boldsymbol{\theta}$ 参数的计算，如下：

对于 $i=1,...I$，分别执行：

从正态分布 $N(\theta_i^t,\sigma_{\boldsymbol{\theta}}^2)$ 中随机抽样 θ_i^*，通过初始参数设置得到 $\sigma_{\boldsymbol{\theta}}^2$；

通过如下的 θ_i^t 向 θ_i^* 概率转移计算式计算转移概率 $P(\boldsymbol{\theta}_i^t,\boldsymbol{\theta}_i^*)$：

$$P(\boldsymbol{\theta}_i^t,\boldsymbol{\theta}_i^*)=\min\{\frac{P(\boldsymbol{\theta}^*|\boldsymbol{\Omega}^t,\boldsymbol{\Psi}^{t+1},\boldsymbol{r})}{P(\boldsymbol{\theta}^t|\boldsymbol{\Omega}^t,\boldsymbol{\Psi}^{t+1},\boldsymbol{r})},1\}$$

其中，$\boldsymbol{\theta}^*$ 为将 $\boldsymbol{\theta}^t$ 中的第 i 维 $\boldsymbol{\theta}_i^t$ 替换成 $\boldsymbol{\theta}_i^*$ 得到的。

从均匀分布 $U(0,1)$ 中生成随机数 $rand$，若 $rand$ 小于等于转移概率 $P(\boldsymbol{\theta}_i^t,\boldsymbol{\theta}_i^*)$，则接

受θ_i^*为$\boldsymbol{\theta}^t$中的第i维θ_i^t，否则对$\boldsymbol{\theta}^t$不作调整。

执行完I步后，令$\boldsymbol{\theta}^{t+1}=\boldsymbol{\theta}^t$继续迭代。

A3：对$\boldsymbol{\Omega}$参数的计算，如下：

对于$j=1,...J$，分别执行：

从均匀分布$U(a_j^t-\delta_{\boldsymbol{\lambda}},a_j^t+\delta_{\boldsymbol{\lambda}})$，$U(g_j^t-\delta_{\boldsymbol{g}},g_j^t+\delta_{\boldsymbol{g}})$，$U(s_j^t-\delta_s,s_j^t+\delta_s)$中随机抽样$a_j^*$，$g_j^*$，$s_j^*$；

通过如下的$\boldsymbol{\Omega}_j^t$向$\boldsymbol{\Omega}_j^*$概率转移计算式计算转移概率$P(\boldsymbol{\Omega}_j^t,\boldsymbol{\Omega}_j^*)$：

$$P(\boldsymbol{\Omega}_j^t,\boldsymbol{\Omega}_j^*)=\min\{\frac{P(\boldsymbol{\Omega}^*|\boldsymbol{\theta}^{t+1},\boldsymbol{\Psi}_k^{t+1},\boldsymbol{r})}{P(\boldsymbol{\Omega}^t|\boldsymbol{\theta}^{t+1},\boldsymbol{\Psi}_k^{t+1},\boldsymbol{r})},1\}$$

其中，$\boldsymbol{\Omega}^*$为将$\boldsymbol{\Omega}^t$中的第j维向量$\boldsymbol{\Omega}_j^t$替换成$\boldsymbol{\Omega}_j^*$得到的。

从均匀分布$U(0,1)$中生成随机数$rand$，若$rand$小于等于转移概率$P(\boldsymbol{\Omega}_j^t,\boldsymbol{\Omega}_j^*)$，则接受$\boldsymbol{\Omega}_j^*$为$\boldsymbol{\Omega}^t$中的第$j$维向量$\boldsymbol{\Omega}_j^t$，否则对$\boldsymbol{\Omega}^t$不作调整。

执行完J步后，令$\boldsymbol{\Omega}^{t+1}=\boldsymbol{\Omega}^t$继续迭代。

Step3:算法结束后，判断参数对应的马尔可夫链的收敛性，若收敛，则对该马尔可夫链的平稳期进行采样，计算多条马尔可夫链采样的平均值作为该参数的估计求解结果，若不收敛，则增大T的取值并继续进行算法流程直至马尔可夫链收敛为止，然后再进行采样计算平均值。

3.5 基于 C&RM 的仿真实验分析

基于 C&RM 对学习者的知识水平进行评估时，模型中只有学习者努力特征$\boldsymbol{\eta}$，学习者试题作答结果矩阵$\boldsymbol{r}$以及试题-知识点考察矩阵Q是可获取的，学习者能力特征、知识水平，试题特征矩阵，知识特性矩阵都是待求解的。为了保证本章构建的 C&RM 在实际教育环境中的应用可行，需要设计仿真实验验证模型中的未知参数是可以根据现有已知条件求解的。

3.5.1 实验基础

（1）参数模拟

根据待求解参数的先验分布，利用 MATLAB 随机分布函数生成对应参数的模拟值。随机生成 Q 矩阵。根据式 3.12-3.15,3.21-3.23 描述的 C&RM 计算学习者的试题正确作答概率矩阵$P(r=1)$。根据对应的正确作答概率$P(r_{ij}=1)$，利用均匀分

布$U(0,1)$生成模拟的学习者试题作答结果：

1.从均匀分布$U(0,1)$采样随机值$rand$。

2.如果$rand <= P(r_{ij}=1)$，$r_{ij}=1$,否则$r_{ij}=0$。

根据先前学者的研究基础，参数的先验分布设定如下：

$\theta_i \sim N(0,1), \eta_i \sim N(0,1), w_{k1} \sim Beta(2,2), d_{\eta k1} \sim N(0,1), d_{\theta k1} \sim N(0,1), g_j \sim 4-Beta(0,0.6,1,2)$

$1-s_j \sim 4-Beta(0.4,1,2,1), 1-a_j \sim Beta(\mu_a, s_a)$ $\mu_a, \sim U(0.1,0.9), s_a \sim U(0.5,10)$

为了简化求解过程，令：

μ_a=0.5, s_a=5.25

$$d_{\eta k2} = d_{\eta k1} + \frac{\log(0.001)-\log(w_{k2})-\log(0.999)}{D}$$

$$d_{\theta k2} = d_{\theta k1} + \frac{\log(0.001)-\log(w_{k1})-\log(0.999)}{D}$$

(2)参数求解

利用模拟得到的参数Q、η和r，对 C&RM 中的其他参数α、Ψ、Ω进行求解。选择马尔可夫链蒙泰卡罗方法来实现。针对每个未知参数的求解，生成 5 条独立的马尔可夫链，链长为 10000，取后 5000 次采样结果计算平均值作为对对应参数的估计结果。采用 MATLAB 语言编写程序实现基于 MCMC 方法的 C&RM 参数求解。

3.5.2 参数估计精度评价指标

选择以下两个指标，对比参数的求解结果与模拟真实值之间的误差，评估算法对参数估计求解的精度。

1. 平均绝对离差指标（ABSE）

平均绝对离差指标反映了参数估计值与真值之间的绝对偏离程度，该值越小说明估计结果越准确，越能考察参数估计的反真性、精确性，继而说明参数的可识别性。计算公式为：

$$ABSE = \sum_{n=1}^{N} \frac{|\hat{x}_n - x_n|}{N} \tag{3.28}$$

$\hat{x}_n$表示对应参数的估计值，x_n表示对应参数的真值。N表示观测次数。

2. 均方误差(RMSE)

均方误差是评估值与真值偏差的平方和与评估次数比值的平方根。用来衡量估计值与真值之间的偏差。

$$RMSE = \sqrt{\sum_{n=1}^{N} \frac{(\hat{x}_n - x_n)^2}{N}} \tag{3.29}$$

$\hat{x}_n$表示对应参数的估计值，x_n表示对应参数的真值。N表示观测次数。

3.5.3 实验内容与结果

3.5.3.1C&RM 参数估计的实现及估计精度

（1）学习者知识水平估计

表 4.1 对学习者知识水平估计估计误差

指标	ABSE	RMSE
学习者知识水平参数	0.0760	0.0973

（2）试题特征参数估计

表 4.2 对试题特征参数的估计误差

指标		ABSE	RMSE
试题参数	s	0.0633	0.0815
	g	0.0712	0.0883
	λ	0.1086	0.1740

对学习者群体 500 人，题库试题 100 道，课程知识点 3 个的模拟样本数据集进行参数估计。从 ABSE 和 RMSE 指标来看，基于 MCMC 的参数估计方法基本可实现对学习者知识水平、试题特征参数的精准估计，并且误差基本控制在 0.1 以内。

3.5.3.2 学习者人数对参数估计精度的影响

表 4.3 在不同学习者人数的条件下参数估计误差对比

试验条件		300 人		500 人		800 人	
指标		ABSE	RMSE	ABSE	RMSE	ABSE	RMSE
试题参数	s	0.0769	0.0961	0.0633	0.0815	0.0470	0.0605
	g	0.0740	0.0991	0.0731	0.0930	0.0712	0.0883
	λ	0.1166	0.1804	0.1086	0.1740	0.0990	0.1645

固定知识点数量为 3，试题数量为 100，设置了三组对照实验，分别是 300 人、500 人、800 人。从参数估计效果来看，随着学习者样本数量的增加，对试题参数的估计误差越来越小。因为题目的数量是固定的，更多的学习者参与作答试题意味着可获得的关于试题特征的信息量更多，从而估计结果更加接近真实值。

3.5.3.3 试题个数对参数估计精度的影响

表 4.3 在不同试题数的条件下参数估计误差对比

试验条件	50 题		80 题		100 题	
指标	ABSE	RMSE	ABSE	RMSE	ABSE	RMSE

学习者知识水平参数	α	0.0774	0.0970	0.0638	0.0835	0.0542	0.0739

固定知识点数量为 3，学习者样本数量为 500，设置了三组对照实验，分别是 50 题、80 题、100 题。从参数估计效果来看，随着试题样本的个数的增加，对学习者知识水平参数的估计误差越来越小，这是因为面对同一批学习者，在测验中加入更多的试题，试题作答结果也就更能细致化体现学习者的知识水平，对学习者知识水平的评估结果也就越准确。

3.5.3.4 知识点数量对参数估计精度的影响

表 4.4 在不同知识点数量的条件下参数估计误差对比

实验条件		平均每道题考察 1 个知识点		平均每道题考察 2 个知识点		平均每道题考察 3 个知识点	
指标		ABSE	RMSE	ABSE	RMSE	ABSE	RMSE
学习者知识水平参数	α	0.0688	0.0823	0.0677	0.0810	0.0712	0.0933
试题参数	s	0.0396	0.0505	0.0603	0.0843	0.0517	0.0665
	g	0.0713	0.0907	0.0539	0.0668	0.0532	0.0680
	λ	0.0127	0.0428	0.0236	0.0560	0.0455	0.0830

固定知识点总数量为 6，学习者样本数量为 500，试题数量为 100，设置了三组对照实验，分别是平均每道题考察 1 个知识点、平均每道题考察 2 个知识点、平均每道题考察 3 个知识点。从参数估计效果来看，平均每道题考察的知识点数量对试题参数的整体估计影响无法直观得出。这是因为随着试题考察的知识点的平均数量的增长，题目结构也变得复杂，这会造成部分试题参数估计精度的下降（比如知识点的重要性 λ）。但是从另一方面讲，试题考察的知识点的平均数量的增长也会导致学习者各项知识水平的使用频次增多，试题作答结果中所包含的信息量更多，从而提升部分试题参数估计的精度（比如试题的猜测参数 g）。

3.6 本章小结

本章主要分为四个部分：第一部分介绍了本文提出的 C&RM 的整体架构：学习者的能力特征、努力特征与知识特性决定了学习者的知识水平，学习者的知识水平与试题特征决定其试题掌握程度及试题作答结果，其中，前者对知识水平建模，为学习者认知阶段，后者对学习者试题作答结果建模，为学习者反应阶段。第二部分介绍认知阶段建模，详细介绍了能力特征、努力特征的表征方式以及如何将知识水平的表示方式由仅考虑单维潜在特征扩展为考虑二维潜在特征，并结合二维潜在特征之间的联合补偿机制对模型进行改进与优化。最后，证明了构建的认知模型是满足所提出的联合补偿机制的。第三部分介绍反应阶段建模，该过

程可分为两步，第一步是对学习者的试题掌握程度进行建模，学习者对试题的掌握程度是由学习者对试题考察的知识点的掌握程度以及这些知识点对作答试题的重要性等级联合决定的，因此具备不同知识水平的学习者对同样的试题也具备不同的掌握程度。第二步是对学习者的试题作答结果进行建模，试题作答过程中，并非学习者完全掌握试题考察的知识点就一定能正确作答试题，也不是在完全不掌握试题考察的知识点就一定错误作答试题，还有一些随机因素会对学习者作答试题造成影响，这些随机因素包括失误、猜测等。基于 C&RM 对学习者进行评估时，需要对模型中学习者的特征参数、试题的特征参数进行求解。因此，针对 C&RM 的参数求解，在本章第四部分设计了基于贝叶斯估计与 MCMC 抽样方法的求解算法，并设计了仿真对照实验，通过实验结果数据说明模型中的未知参数是可求解的，除此之外，还探讨了学习者样本数量、试题样本数量、知识点数量对参数求解的影响。

第 4 章　基于 MOOC 数据的学习者评估实验与应用

4.1 基于 MOOC 数据的学习者评估实验

4.1.1 MOOC 数据获取与处理

目前对结合学习者努力特征的认知诊断模型研究极少，并且 FrcSub、Math 等公开数据集中均不包含学习者的努力特征信息，因此没有合适的数据集用于评估 C&RM 的评估效果。本章利用爬虫技术对中国大学 MOOC 湖南大学《信号与系统》课程的相关学习数据进行采集与处理，构建了新的学习数据集——HNU_SYS 数据集。

（1）数据获取

中国大学 MOOC 是由爱课程与网易公司联合开发的免费在线学习平台。参与课程学习的学习者可以观看课程课件，参与课堂讨论、章节测验、章节作业、期中考试、期末考试等课程内容；课程管理者可以上传作业、试题等教育资源，以及查看课程学习者的学习信息。该平台涉及的学习领域范围广，并且参与学习人数较多，可以提供丰富的数据样本。下图 4.1 为 MOOC 平台的课程页面。

图 4.1 课程页面

本章选择中国大学 MOOC 平台的湖南大学《信号与系统》课程作为数据采集的目标。该课程教学资源丰富，选修学习者众多，且学习者对课程任务的完成度比较高，数据质量相对较好。但是，课程相关数据维度多，数据量大，并且每个学习者在考试时作答的试题都是从题库中随机抽取的，这些问题都给数据统计工作带来了很大的压力，因此选择采用 Python 爬虫技术采集学习者章节测验成绩、作业成绩以及期中、期末考试作答记录。基于爬虫技术的数据采集流程如下图 4.2

所示：

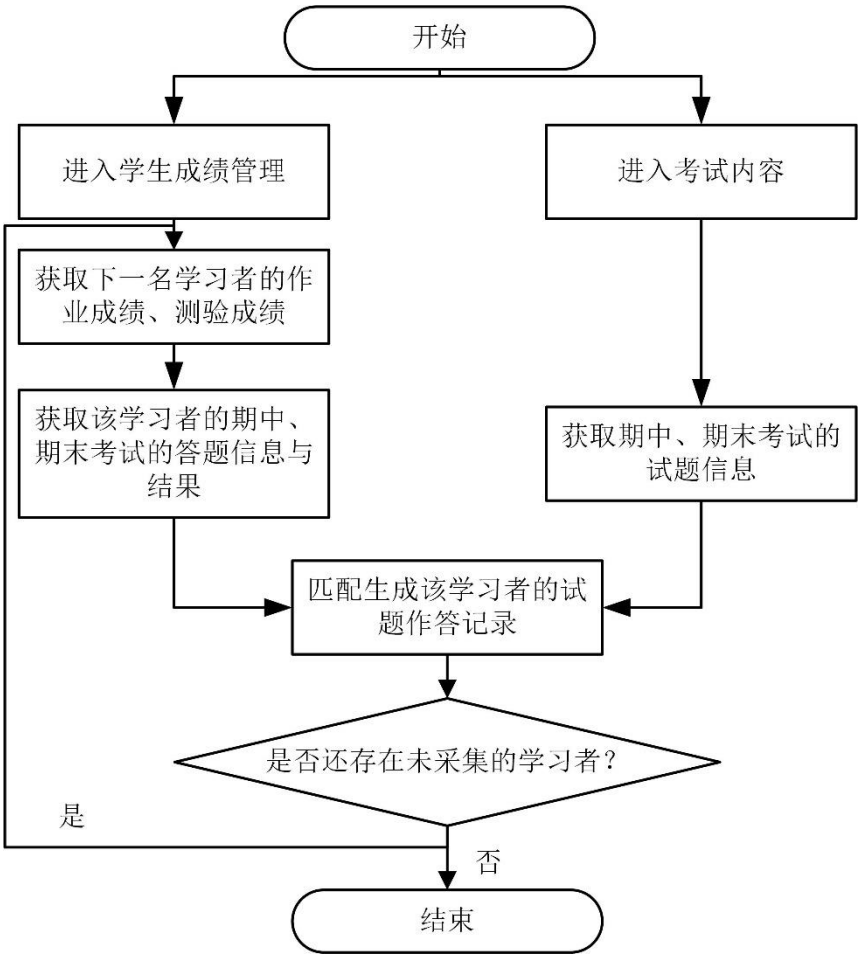

图 4.2 数据采集流程图

基于 Python 爬虫技术采集数据时，首先使用 selenium 控制浏览器打开 MOOC 官网，登录账户进入后台管理界面。进入教学内容发布-期中/期末考试，使用 beautiful soup 构建文档树，以字典形式保存题目及对应的题干信息。然后进入学生成绩管理，循环操作，采集学生的作业成绩、测验成绩、考试答题信息与答题结果，并使用 beautiful soup 获取学生考试答题信息中的题干信息，根据上一步构建的字典获取题目序号，生成学习者的试题作答记录。

编写的相关函数及功能：

downHtml(url)：模拟 get 请求获取指定 url 的相关资源。

mouseClickXpath(driver,xpath):跳转到 xpath 定位的页面。

TestData.getStuData(self,driver):获取学习者的考试答题信息

TestData.getItemData(self,driver,itemNum):获取题库的题目信息

TestData.getStuData(self,stuId,stuItems,stuItemsResult):匹配考试答题信息与题库题目信息，得到学习者的试题作答记录

storStuData(self,stuId):保存学习者的试题作答记录

（2）数据预处理

通过爬虫技术采集了中国大学生 MOOC 湖南大学《信号系统》课程的学习者学习数据。经过处理，构建了包含 466 名学习者的学习数据集。数据集包括学习者的 id，努力特征参数提取，试题得分记录以及试题-知识点考察矩阵。其中，学习者的努力特征参数是对学习者的作业、测验总成绩通过下式 4.1 变换得到；因为作业、测验内容难度较低，学习者对这部分内容的成绩基本体现了在课程学习过程中所付出的努力程度。学习者作答的试题是从具有 90 道习题的题库中随机抽取的。题库中的题目难度层次分明，考察知识点全面（共 6 个知识点），对学习者知识水平的区分度显著。试题得分记录包含学习者的每道考试习题得分情况（0 表示未作答，1 表示作答正确，-1 表示作答错误），对应 C&RM 中的试题作答矩阵。试题-知识点考察矩阵是任课教师经过讨论论证总结得到的，对应 C&RM 中的试题-知识点关联矩阵 $\boldsymbol{Q}$ 。

表 4.1 数据集概要

数据集	学生数量	知识点数量	试题数量
HNU_SAS	466	6	90

在上文第 3.4 节参数估计中提到，学习者的努力特征参数选择正态分布为先验分布。因此学习者测试、作业总成绩与努力特征参数提取变换的原则是保证变换前后学习者 i 所在的位次比例是相等的，并且变换后的努力特征参数基本服从标准正态分布。下式 4.1 中，$f(x)$ 为标准正态分布的概率密度函数，$rank(i)$ 为学习者 i 作业、测验总成绩在所有学习者的逆序排名位次，$rank(i)=1$ 表示学习者位次为最后一名。$Total$ 为学习者总人数。分母 $Total+1$ 是为了避免等式右边取值为 1 导致等式左边 η_i 取值为无穷大的问题。

$$\int_{-\infty}^{\eta_i} f(x)dx = \frac{rank(i)}{Total+1} \tag{4.1}$$

对变换提取的努力特征参数绘制分布特征统计图，绘图如下：

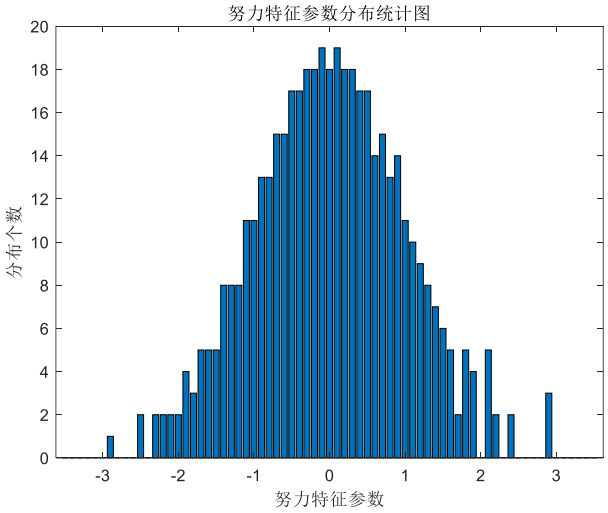

图 4.3 努力特征参数分布统计图

图 4.3 中，横坐标表示努力特征参数取值，纵坐标表示学习者群体中，努力特征参数在横坐标对应的努力特征参数取值±0.05 区间范围内的学习者个数。从图中的分布特性来看，基本服从正态分布。计算学习者群体的努力特征参数的分布特性，得到均值为 0.0051，方差为 0.9951。因此，变换提取的学习者群体努力特征参数取值基本服从标准正态分布。

4.1.2 实验对比模型及特点分析

（1）DINA 模型[44]

DINA 模型使用学习者的多维知识水平与试题的多维特性来建模学习者的试题作答结果，但是该模型对学习者知识水平的表示方式是二元类型的。

（2）HO-DINA 模型[45]

HO-DINA 模型在 DINA 模型基础上，考虑学习者的知识水平由学习者自身的能力特征所主导。因此 HO-DINA 模型可以对学习者的能力特征与知识水平进行评估。HO-DINA 模型中，能力特征的取值是连续值，知识水平的取值是二元离散值。

（3）Fuzzy-CDF 模型[9]

该模型为 Liuqi 在 2017 年提出来的高阶模型，Fuzzy-CDF 模型[42]在继承 HO-DINA 模型的基础上，对学习者的知识水平建模进行了改进：将学习者的知识水平参数的取值范围优化为 0-1 之间的连续值。

（4）Neural-CD 模型[36]

该模型为 Wangfei 在 2020 年提出的新模型，Neural-CD 模型使用一个四层的神经网络从数据中学习学习者与试题之间的交互关系。神经网络的输入为答题记录中学习者和试题的 one-hot 向量 $\boldsymbol{x}^s$ 和 $\boldsymbol{x}^e$，输出为学习者答对该试题的预测概率 y。

神经网络的第一层表示为：

$$\boldsymbol{x} = Q_e \circ (\boldsymbol{h}^s - \boldsymbol{h}^{diff}) \times h^{disc} \tag{4.2}$$

上式 4.2 中，$\boldsymbol{h}^s$ 为学习者的知识水平向量，表示学习者对每个知识点的掌握程度，$\boldsymbol{h}^s = sigmoid(\boldsymbol{x}^s \times A)$，sigmoid 为 sigmoid 函数，$A$ 为神经网络的训练参数矩阵。$\boldsymbol{h}^{diff}$ 为试题的知识点难度向量，表示试题对每个知识点考察的难度，$\boldsymbol{h}^{diff} = sigmoid(\boldsymbol{x}^e \times B)$，$B$ 为神经网络的训练参数矩阵。h^{disc} 为试题的区分度参数，$\boldsymbol{h}^{disc} = sigmoid(\boldsymbol{x}^e \times D)$，$D$ 为神经网络的训练参数矩阵。$\boldsymbol{Q}_e$ 为试题与知识点的关联向量，$\boldsymbol{Q}_e = x^e \times \boldsymbol{Q}$。$\boldsymbol{x}$ 为该层的输出向量。

神经网络的第二、三、四层均为全连接层，并使用 sigmoid 函数作为激活函数。

$$\boldsymbol{f}_1 = sigmoid(\boldsymbol{W}_1 \times \boldsymbol{x}^T + \boldsymbol{b}_1) \tag{4.3}$$

$$\boldsymbol{f}_2 = sigmoid(\boldsymbol{W}_2 \times \boldsymbol{f}_1 + \boldsymbol{b}_2) \tag{4.4}$$

$$y = sigmoid(\boldsymbol{W}_3 \times \boldsymbol{f}_2 + \boldsymbol{b}_3) \tag{4.5}$$

式中，$\boldsymbol{W}_1$、$\boldsymbol{W}_2$、$\boldsymbol{W}_3$、$\boldsymbol{b}_1$、$\boldsymbol{b}_2$、$\boldsymbol{b}_3$为各网络层中的权重参数与偏置参数，$\boldsymbol{f}_1$、$\boldsymbol{f}_2$、y分别为各网络层的输出参数。与上面提到的认知诊断模型基于统计学理论的求解算法不同，NeuralCD 模型采用梯度下降法对参数进行求解。

4.1.3 实验结果与分析

由于针对学习者、知识、试题特征参数的评估结果不存在标准参考值，所以评估认知诊断模型性能的方法为利用训练集中的数据评估所有学习者、所有试题的特征参数，然后根据得到的参数计算所有学习者对所有试题的正确作答概率，评估模型对训练集数据的拟合表现以及对测试集数据的预测表现。

模型输出为学习者正确作答试题的预测概率 $P(r_{ij}=1)$，本文基于下式生成学习者的试题预测作答结果 r_{ij}：

$$r_{ij} = \begin{cases} 1, P(r_{ij}=1) >= 0.5 \\ 0, P(r_{ij}=1) < 0.5 \end{cases} \tag{4.6}$$

选择平均绝对误差（MAE）和均方根误差（RMSE）作为模型的拟合性能评价指标，选择正确率（accuracy）、精确率（precision）、召回率（recall）、F1 作为模型的预测性能评价指标。

$$MAE = \frac{FP + FN}{TP + TN + FP + FN} \tag{4.7}$$

$$RMSE = \sqrt{\frac{FP + FN}{TP + TN + FP + FN}} \tag{4.8}$$

$$Recall = \frac{TP}{TP + FN} \tag{4.9}$$

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} \tag{4.10}$$

$$precision = \frac{TP}{TP + FP} \tag{4.11}$$

$$F1 = \frac{2 \times precision \times recall}{precision + recall} \tag{4.12}$$

上式 4.7-4.12 中，TP为预测学习者作答正确，实际学习者作答正确的学习者人数；TN 为预测学习者作答错误，实际学习者作答错误的人数；FP为预测学习者作答正确，实际学习者作答错误的学习者人数；FN 为预测学习者作答错误，实

际学习者作答正确的学习者人数。

考虑不同的训练数据量，我们从每个学习者已有的作答记录中分别随机抽选40%,50%,60%,70%,80%,90%组成训练集（考虑到40%以下时，数据量太小，训练模型时算法难以收敛），剩下的作答记录组成测试集。然后比较 DINA 模型[44],HO-DINA 模型[45]，Fuzzy-CDF 模型[42]、NeuralCD 模型[36]与本文提出的 C&RM 的预测表现。

（1）拟合表现

使用 MAE 和 RMSE 两个指标分析各模型对训练集中的学习者作答记录的拟合效果。

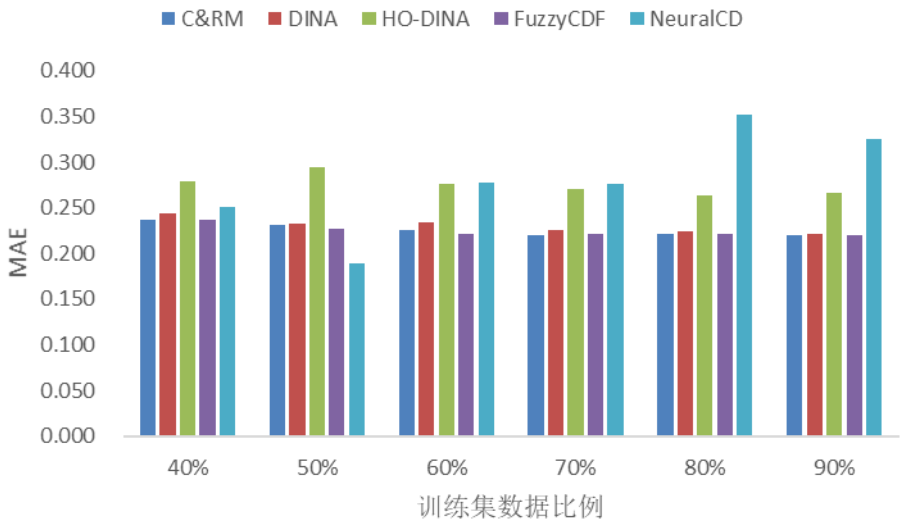

图 4.4 训练集数据拟合效果（MAE）

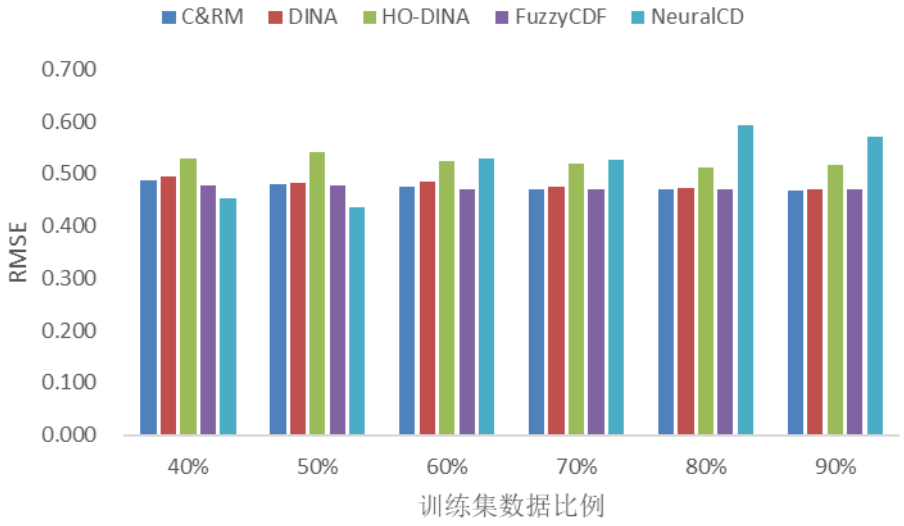

图 4.5 训练集数据拟合效果（RMSE）

如上图 4.4、4.5 所示，基本上在所有的训练集数据抽取比例下，C&RM 对训练集中学习者的试题作答结果数据的拟合效果都是最优的，并且对数据量的敏感

性比较低，在数据量从 40%到 90%的增长过程中，评估拟合效果的 MAE 值仅变化了 0.017，与之对比，DINA 模型变化了 0.022，HO-DINA 模型变化了 0.031，FuzzyCD 模型变化了 0.017，NeuralCD 模型变化了 0.163。其中，NeuralCD 模型变化幅度最大，这是因为 NeuralCD 模型是采用复杂的神经网络来对学习者的试题作答结果进行拟合的，因而对训练集的数据量要求较其他模型更高，在低数据量的条件下，模型的拟合效果不够理想。同样的情况也发生在 RMSE 参数指标上，在训练集数据量从 40%到 90%的变化过程中，C&RM 对应的 RMSE 值仅变化了 0.018，与之对比，DINA 模型变化了 0.023，HO-DINA 模型变化了 0.030，FuzzyCD 模型变化了 0.009，NeuralCD 模型变化了 0.159。尽管如此，除了 NeuralCD 模型之外，各模型的数据拟合效果相差并非特别明显，这表明各模型的复杂度是足以用来拟合原始数据的。

（2）预测表现

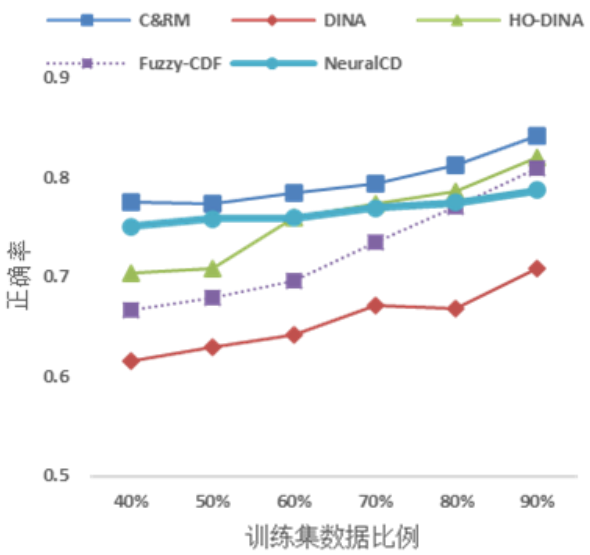

图 4.6 测试集数据预测效果（Accuracy）

如上图 4.6 所示，在所有的训练集数据比例情况下，C&RM 对测试集中的学习者作答记录的预测准确率都是最优的。并且随着训练集数据比例从 90%降至 40%，C&RM 的平均预测准确率从 84.15%降低到 77.50%,降幅 7.90%。与之对比，HO-DINA 模型从 82.00%降低到 70.33%，降幅 14.23%，DINA 模型从 70.84%降低到 61.62%，降幅 13.01%，Fuzzy-CDF 从 80.89%降低到 66.60%，降幅 19.65%，NeuralCD 从 78.69%降低到 75.03%，降幅 4.66%。C&R 模型在训练数据集数据比例最低的情况下（占比 30%），预测准确率 77.76%，相比较 DINA 模型的 57.94%高出 25.49%，相比较 HO-DIAN 的 67.71%高出 12.92%，相比较 Fuzzy-CDF 的 64.71%高出 20.17%.这一准确率相当于 HO-DINA 模型在训练数据集占比 70%时、

Fuzzy-CDF 在训练数据集占比 80%才具有的预测准确率，并且比 DINA 模型在训练数据集占比 90%时的预测准确率还要高。这表明了 C&RM 相比较 DINA 模型、HO-DINA 模型、Fuzzy-CDF 模型能更好的建模学习者试题作答结果的生成结构，对学习者的评估结果更加具有说服力，并且对训练集数据量的鲁棒性更好。

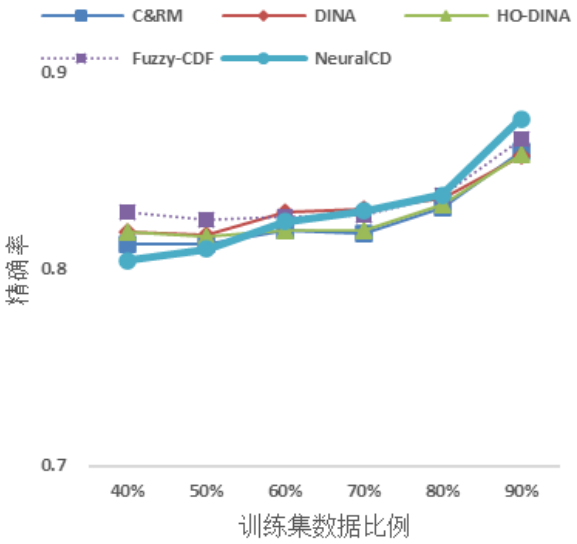

图 4.7 测试集数据预测效果（Precision）

如上图 4.7 所示，在所有的训练集数据比例情况下，五个模型预测的精确率基本上相差无几，最大差距不超过 2%。在训练集数据比例为 40%时，C&RM 的预测精确率为 81.3%，与之相比，DINA 模型为 82.0%，HO-DINA 为 82.0%，FuzzyCDF 模型为 82.5%，NeuralCD 为 80.5%，在训练集数据比例从 40%提升至 90%的过程中，C&RM 提升了 5.8%，DINA 模型提升了 4.8%，HO-DINA 模型提升了 4.8%，FuzzyCD 模型提升了 4.4%，NeuralCD 模型提升了 9.0%；

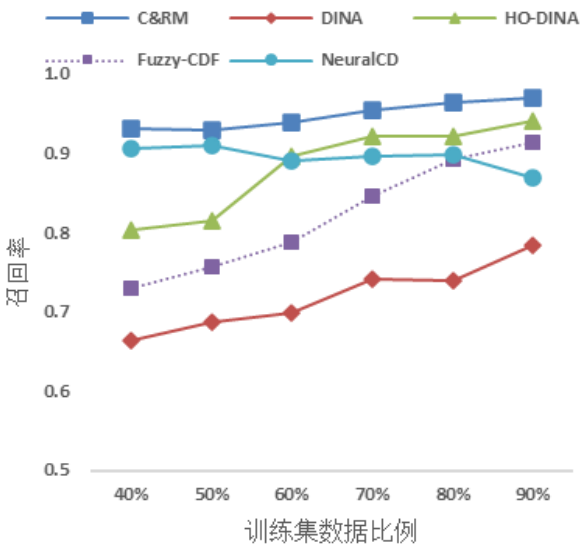

图 4.8 测试集数据预测效果（Recall）

如上图 4.8 所示，在所有的训练集数据比例条件下，C&RM 的召回率都是最优的，随着训练集数据比例从 90%降至 40%，C&RM 的平均预测召回率从 97.05%降低到 93.12%,降幅 4.22%。与之对比，HO-DINA 模型从 94.20%降低到 80.40%，降幅 17.16%，DINA 模型从 78.44%降低到 66.32%，降幅 18.30%，Fuzzy-CDF 从 91.50%降低到 72.95%，降幅 25.42%，NeuralCD 模型从 87.02%提升到 90.96%。C&RM 在训练数据集数据比例最低的情况下，预测召回率 93.12%，相比较 DINA 模型的 66.32%高出 40.41%，相比较 HO-DIAN 的 80.41%高出 15.81%，相比较 Fuzzy-CDF 的 72.95%高出 27.6%,相比较 NeuralCD 模型的 90.55%，高出 2.8%。

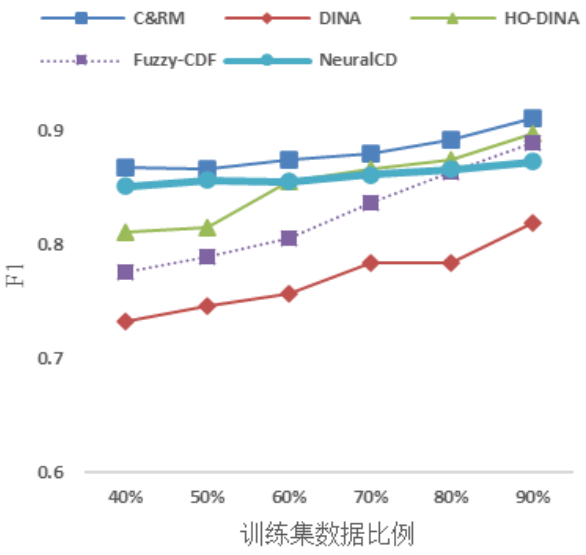

图 4.9 测试集数据预测效果（F1）

如上图 4.9 所示，在所有的训练集数据比例条件下，C&RM 的 F1 值都是最优的，随着训练集数据比例从 90%降至 40%，C&RM 的平均预测 F1 值从 91.18%降低到 86.79%,降幅 5.06%。与之对比， HO-DINA 模型从 89.81%降低到 81.15%，降幅 10.68%，DINA 模型从 82.00%降低到 73.29%，降幅 11.82%，Fuzzy-CDF 从 88.99%降低到 77.62%，降幅 14.65%，NeuralCD 模型从 78.69%降低到 75.03%，降幅 4.89%。C&RM 在训练数据集数据比例最低的情况下（占比 40%），预测 F1 指标值 86.79%，相比较 DINA 模型的 73.29%高出 18.42%，相比较 HO-DINA 的 81.15%高出 6.96%，相比较 Fuzzy-CDF 的 77.62%高出 11.81%,相比较 NeuralCD 模型的 75.02%，高出 15.68%。

对 Precision，Recall，F1 三个指标图（图 4.7-4.9）分析可看出，C&RM 的优势主要体现在：能在保持不错的 Precision 指标值的条件下显著提高 Recall 指标值（在训练集数据比例降低的过程中，始终维持在 0.93 以上）；另外一个优势是 C&RM 的 Recall 指标值具备出色的稳定性，训练集数据比例从 90%降为 40%的过程中，C&RM 的 Recall 指标值降幅仅为 4.05%。

4.2 基于评估结果的个性化教学辅助系统

根据学习者的在线学习数据，利用 C&RM 及对应参数求解算法，可以诊断出学习者特征（能力特征，知识水平特征），试题特征（试题的猜测特征、失误特征、知识点对作答习题的重要性特征），知识点特征（知识点的难度、对能力、努力特征的区分度），通过开发个性化教学辅助系统将诊断结果进行可视化，并应用到教与学中。针对教师，在教学辅助系统中构建全体学习者的个体画像及群体画像供其参考，画像内容包括学习者的能力特征参数分布情况、努力参数分布情况以及各知识点掌握水平的分布情况，从而使得教师可以针对群体掌握差的知识点调整授课安排。其次，针对学习者学习，一方面，通过教学辅助系统展示其知识诊断结果以及知识、试题的属性诊断结果，帮助学习者进行学习分析。另一方面展开个性化试题推荐，推荐适当难度的题目供学习者强化练习。

4.2.1 个性化分析功能

个性的教学辅助系统的学习分析功能面向的对象是教师和学习者，教师使用账号密码登录系统后进入教师操作页面，可选择查看学生分析、知识分析、试题分析的结果。学生分析的内容包括学习者群体特征分析与指定学号的学习者个体特征分析，分析的特征包括能力特征值、努力特征值以及对各知识点的掌握程度。知识分析的内容为指定知识点对能力特征、努力特征的区分度以及难度。试题分析的内容包括题库特征分析与指定题号的试题特征分析，分析的特征包括试题的猜测率，失误率，对知识点的考察等级。学生使用个人学号与密码登录系统后，与教师操作页面相同，可选择查看学生分析、知识分析、试题分析的结果。不过，在学生分析界面中，学生用户仅可查看自己的特征分析结果。

（1）教师操作界面

教师在操作时，首先需要登录该系统，登录界面如下图 4.10 所示：

图 4.10 系统登录界面

登录时，教师根据自己的账号和密码登录系统，系统会判别输入的账号是否在信息库中以及密码与账号是否匹配，错误提示信息有“账号错误”、“密码错误”，在确认账号密码无误之后，系统会根据账号自动识别用户的教师身份，进入教师操作页面。教师操作页面如下图 4.11 所示：教师操作页面为三个选项按钮，分别是学生分析、知识分析以及试题分析，教师点击按钮后即可进入相关分析界面。

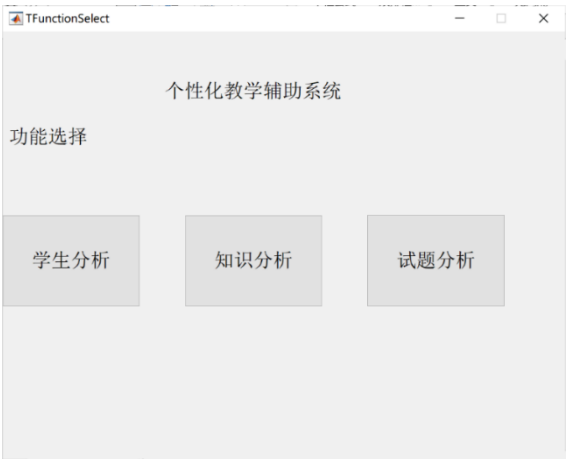

图 4.11 教师操作界面

学生分析：学生分析界面有两个功能，第一个功能是针对学习者群体的能力特征、努力特征、知识水平分析。下图 4.12 是对学习者群体的知识水平 6 的分析结果，其中横坐标表示知识水平评估值，纵坐标表示学习者群体中知识水平评估值在横坐标对应的知识水平值±0.01 区间内的学习者个数。下方“平均值”处显示为所有学习者知识水平评估值的平均值。第二个功能是指定学习者的特征分析功能，如下图 4.13 所示，在该界面输入学习者的学号，点击“ok”按钮，即可看到学号对应的学习者的特征分析结果，其中右上方图中柱形图对应的纵坐标值分别为该学习者能力特征与努力特征评估值，右下方图中柱形图对应的纵坐标值分别为该学习者对各知识点的知识水平评估值。

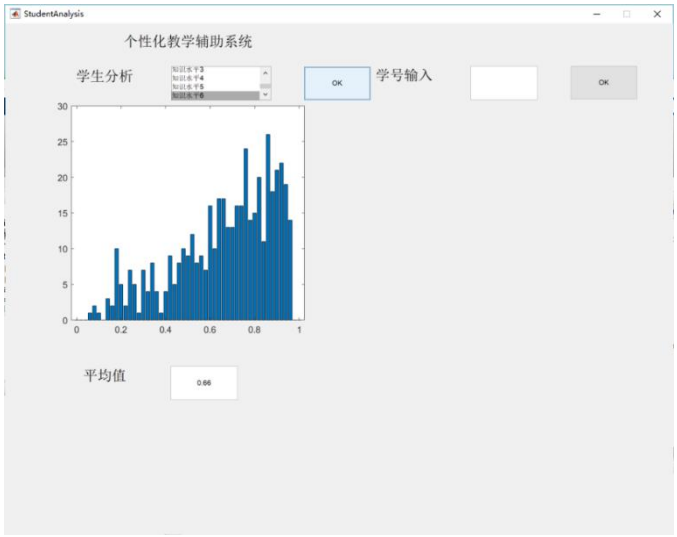

图 4.12 学生群体分析界面

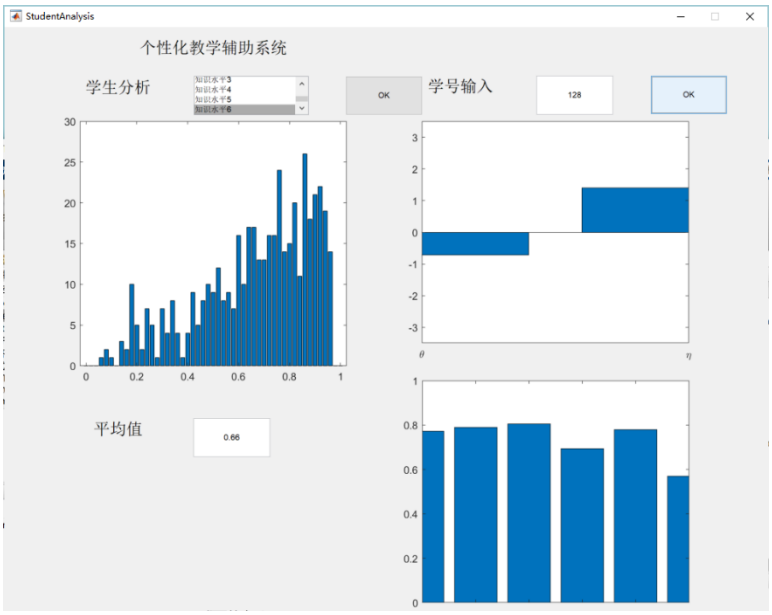

图 4.13 学生个体分析界面

知识分析：知识分析界面提供对课程涉及的知识点的特征分析，输入知识点的编号，点击“ok”按钮，即可查看分析结果。下图 4.14 为对知识点 2 的分析结果展示，左图所示柱形图对应的纵坐标值分别为知识点 2 对学习者能力特征、努力特征的难度评估值，右图所示柱形图对应的纵坐标值分别为知识点 2 对学习者能力特征、努力特征的区分度评估值。

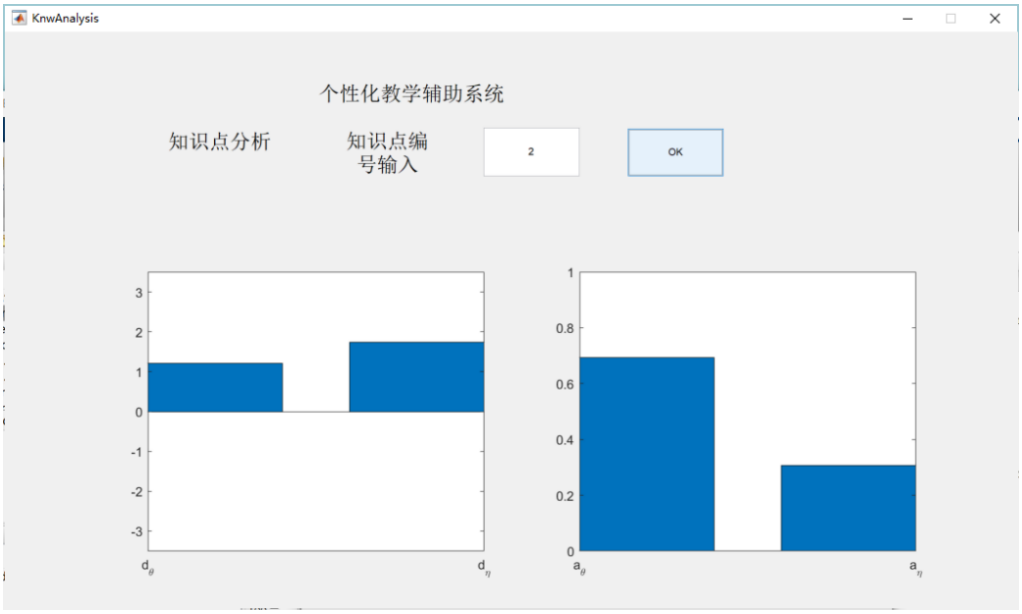

图 4.14 知识分析界面

试题分析：试题分析界面提供两个功能，第一个是针对题库中所有试题的特征分析统计结果，涉及的试题特征有猜测率、失误率、知识点考察等级等。通过选中试题特征或输入题号即可查看相关试题特征分析结果。下图 4.15 为对题库试题失误率统计分析的结果。图 4.15 左图横坐标为失误率评估值，纵坐标为题库中

失误率评估值在横坐标对应的失误率±0.05 区间内的试题个数。除此之外，分析结果图下方还给出了题库中所有试题失误率评估值的平均值。第二个功能为指定题号的试题特性分析，输入题号，点击 ok 按钮，即可查看题号对应的试题特征分析结果，如下图 4.16 所示，右上图中所示柱形图对应的纵坐标值分别为第 88 题的失误率与猜测率，右下图中所示柱形图对应的纵坐标值分别为知识点对作答该题的重要性量值。图中可以看出，该题仅考察了知识点 2、3、4。

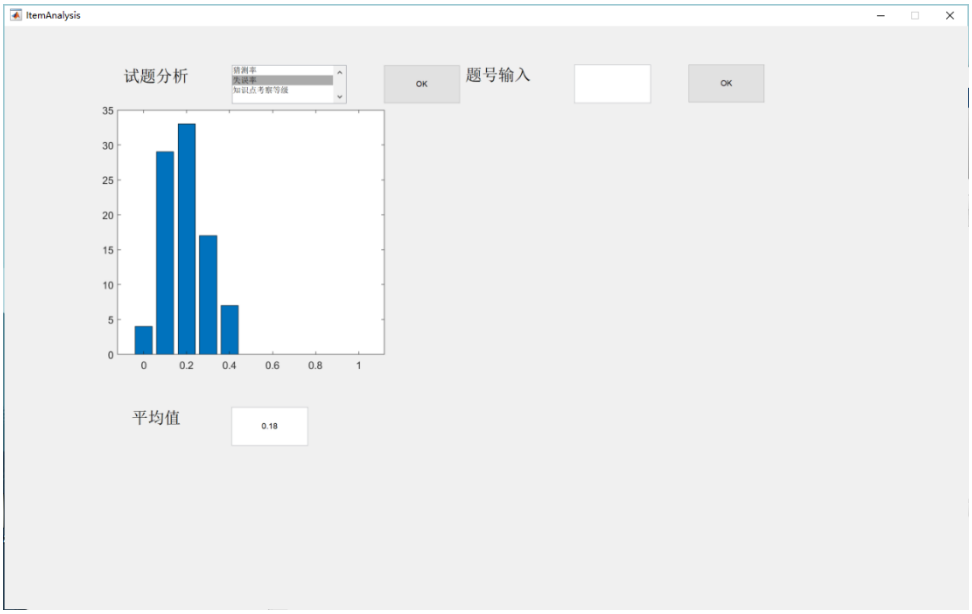

图 4.15 题库分析

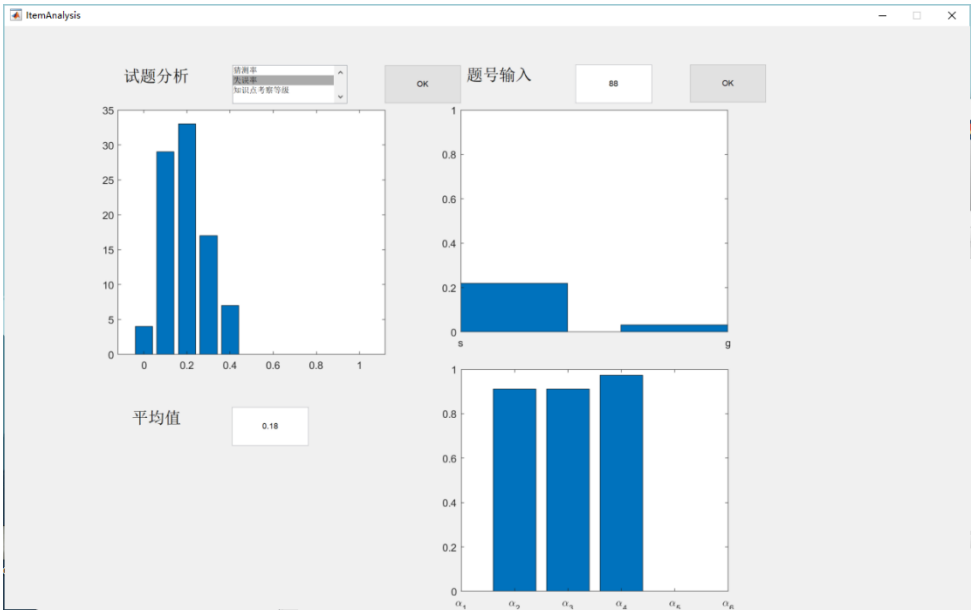

图 4.16 试题分析

（2）学习者操作页面

在学习分析展示功能上，学习者操作页面与教师类似，仅在学生分析功能不同（学习者在学生分析仅可查看自己的相关特征分析结果），因此不再重复介绍。

4.2.2 个性化试题推荐功能

试题个性化推荐功能仅面向学习者提供，学习者在正确输入账号密码，成功登录系统之后，点击试题推荐按钮即可进入试题推荐界面，如下图 4.17 所示。在试题推荐界面，学习者可设定想要作答的试题难度，该难度是依据学习者自身知识水平计算得到的试题相对难度，因此，同样的试题对不同的学习者来讲，该项难度参数是不同的，在设定好难度参数之后，点击“确认”按钮，下方的推荐试题列表会展示推荐的试题序号（默认推荐 20 个试题），点击试题序号，会弹出该题在题库中对应的序号，方便学习者通过试题分析功能查看该题目的特征信息，右侧区域显示该道试题的题干信息，另外，学习者还可以通过点击“查看答案”按钮查看题目对应的答案，如下图 4.18 所示。

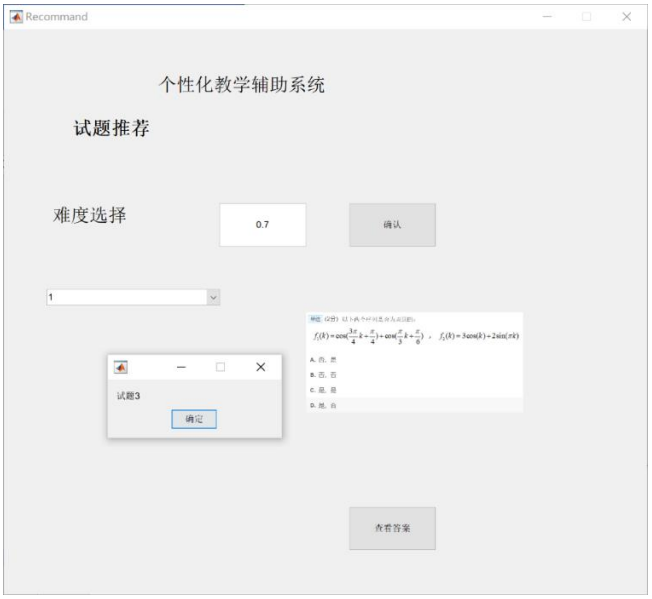

图 4.17 个性化试题推荐界面

图 4.18 查看答案

4.3 本章小结

本章内容主要包含两个部分：第一部分主要介绍文中构建的基于 C&RM 的学习者评估模型对真实学习数据集 HNU_SYS 的评估与预测表现。文中介绍了基于 Python 爬虫技术对中国大学生 MOOC《信号与系统》课程学习数据采集的详细实现流程，以及如何利用采集的数据计算得到 C&RM 中的部分先验信息。在建立数据集之后，随机以 40%-90%的比例选择数据作为训练集，剩下的 60%-10%作为测试集，利用训练集中的数据以及第四章介绍的模型求解算法评估所有学习者、所有知识、所有试题的特征参数值，并基于评估结果计算测试集中的学习者试题作答记录，评估 C&RM 与其他认知诊断模型的性能差异。从实验结果来看，本文构建的 C&RM 预测准确率更高，并且对数据量的鲁棒性更好。第二部分介绍了基于模型评估结果的个性化教学辅助系统，该系统能根据用户登录的账号识别用户身份，针对教师用户，提供学习者群体与个体特征、知识点特征、题库与试题特征的人性化界面展示。针对学生用户，除了提供自身特征、知识点特征、题库与试题特征展示之外，还基于第一部分对学习者未作答试题的预测结果推荐匹配学习者设定难度的试题供学习者训练提升。

总结与展望

1 论文总结

智能化教育时代，如何对学习者、教育资源的关键特征进行合理量化评估是当前研究的重点。认知诊断模型可以对学习者的知识特征、试题特性以及试题作答结果之间的潜在作用关系进行模型化表示。因此，基于认知诊断模型可以实现对学习者、试题的特征诊断与评估。当前的认知诊断模型主要存在以下问题：

（1）模型结构有待进一步完善。在利用学习者的潜在特征表征知识水平时，仅考虑先天能力特征，忽视了学习者的后天努力特征；在表征学习者的试题掌握程度时，仅考虑学习者对知识的掌握程度，忽视了知识点对作答试题的重要性这一特征。

（2）认知诊断模型可利用的先验信息较少，参数求解的质量对样本规模比较敏感。在对模型参数求解过程中，已知条件仅有学习者的试题作答结果与试题-知识点关联矩阵。

本文针对以上问题进行了认知诊断模型的优化设计，将学习者学习与运用知识的过程分为认知与反应阶段，并根据学习者的认知与反应机理，构建了新的高阶认知诊断模型——认知反应模型，主要工作内容如下：

（1）引入学习者的努力特征以及联合补偿机制建立认知模型。结合慕课中的学习者学习活动数据对学习者的努力特征进行评估，然后使用能力、努力特二维潜在特征对学习者的认知阶段建模，并考虑能力特征与努力特征之前存在以下联合补偿机制：能力特征与努力特征对知识水平的影响效果是可以相互补偿，其中任意一维特征的改变导致的学习者知识水平变化可由另一维特征在相反方向上的改变得到弥补。并且，这种补偿效果是有限的，某些能力特征或努力特征低于一定范围的学习者，即使可以通过另一维度属性的提升而取得一些补偿效果，但是这种补偿效果不是无尽的，而是具备上限的。此外，知识的获取是对学习者的能力特征和努力特征联合考察的。在极端情况下，能力特征或努力特征中的任意一维趋近于最小值，此时学习者的知识水平也应当趋近于最小值。通过引入努力特征与联合补偿机制，提高了模型结构的合理性与评估结果的解释性。

（2）引入知识点对作答习题的重要性等级构建了知识弱项这一特征参数应用于学习者的反应阶段建模。知识弱项与学习者的知识水平以及知识对作答习题的重要性相关：知识点对作答试题越重要，并且学习者对该知识点的掌握程度越低，那么该知识点对学习者而言的弱项程度就越高。考虑到木桶效应，学习者对试题

的掌握程度取决于弱项程度最高的知识点。然后结合学习者对试题的掌握程度以及失误、猜测等随机特征得到对学习者的试题作答结果预测。

除此之外，对建立的认知反应模型进行了如下的实验研究与应用：

（1）关于模型参数可识别性的仿真实验。认知反应模型用于对学习者的知识水平与试题特征进行评估，模型结构复杂且已知条件少，因此本文设计了仿真实验来探究模型中参数是否可根据已知条件求解，以及样本数量对求解结果的影响。

（2）基于 MOOC 真实数据的评估实验。利用爬虫技术获取了学习者线上学习的真实数据，构建了标准数据集 HNU_SYS，利用该数据集，评估本文提出的认知反应模型与其他认知诊断模型的性能差异，进一步说明本文提出的认知反应模型的优越性。

（3）基于认知反应模型评估结果开发个性化教学辅助系统。该教学辅助系统将模型对学习者和试题特征的评估结果进行可视化，展示给教师和学习者，并且能够为学习者提供指定难度等级的试题推荐功能。

2 课题展望

尽管本文提出的认知反应模型在解释性、准确度等方面较现有模型都有了一定的进步，但是还存在一些不足：

（1）模型结构复杂，待求解参数繁多，一定程度上造成了求解算法迭代次数多，运行时间长。下一步对研究针对求解算法的优化方案。

（2）对学习者努力特征参数的提取有待进一步优化，由于技术原因，本文仅采集了学习者的线上学习数据提取努力特征，实际上，学习者的学习过程是多元化的，除了线上数据之外，还应当从线下学习生活中采集数据，综合对学习者的努力特征进行量化。

（3）本文搭建的个性化教学辅助系统在操作性和美观性等方面还可以进一步改进。

参考文献

[1] 邓东元.中国教育改革中的慕课(MOOC)发展研究综述(2012-2018).昆明理工大学学报(社会科学版),2019, 19 (01): 76-83.

[2] 吴永和, 刘博文, 马晓玲.构筑“人工智能+教育”的生态系统.远程教育杂志,2017, 35 (05): 27-39.

[3] 蔡慧英, 陈明选.智能时代数字教育资源建设与发展研究.现代远距离教育,2019 (03): 74-81.

[4] 郑庆华, 董博, 钱步月, et al.智慧教育研究现状与发展趋势.计算机研究与发展,2019, 56 (01): 209-224.

[5] Vagale V, Niedrite L. Learner Model's Utilization in the e-Learning Environments.In:Tenth International Baltic Conference on Databases and Information Systems.Vilnius,2012.162-174

[6] Abyaa A, Idrissi M K, Bennani S.Learner modelling: systematic review of the literature from the last 5 years.Etr&D-Educational Technology Research and Development,2019, 67 (5): 1105-1143.

[7] Adda S A, Amar B, Ieee. The impact of digital library in detecting of learning difficulties. Warwickshire:University of Warwick 2014.30-32

[8] Torre D L, J.DINA Model and Parameter Estimation: A Didactic.Journal of Educational and Behavioral Statistics,2009, 34 (1): 115-130.

[9] Liu Q, Wu R, Chen E, et al.Fuzzy Cognitive Diagnosis for Modelling Examinee Performance.ACM transactions on intelligent systems,2018, 9 (4): 296-321.

[10] Bicans, Janis.The Acquisition of Context Data of Study Process and their Application in Classroom and Intelligent Tutoring Systems.Applied Computer Systems,2015, 18 (1).

[11] Thai-Nghe N, Schmidt-Thieme L. Multi-Relational Factorization Models for Student Modeling in Intelligent Tutoring Systems.In:the 2015 Seventh International Conference on Knowledge and Systems Engineering.Ho Chi Minh City,2016,61-66

[12] Shavelson R J: An Approach to Testing & Modeling Competence, Blömeke S, Zlatkin-Troitschanskaia O, Kuhn C, Fege J,editor,Modeling and Measuring Competencies in Higher Education: Tasks and Challenges, Rotterdam: SensePublishers,2013: 29-43.

[13] Liu Q, Huang J, Wu L, et al. Study on Learner Model in Adaptive Learning System Based on Ant Colony Algorithm.In: 8th International Conference on Hybrid Learning (ICHL).Wuhan,2015,267-280

[14] Schmidt S, Zlatkin-Troitschanskaia O, Fox J P.Pretest - Posttest - Posttest Multilevel IRT Modeling of Competence Growth of Students in Higher Education in Germany.Journal of Educational Measurement,2016, 53 (3): 332-351.

[15] Park J Y, Cornillie F, Han L, et al.A Multidimensional IRT Approach for Dynamically Monitoring Ability Growth in Computerized Practice Environments.Frontiers in Psychology,2019, 10: 620.

[16] Lockwood J R, Castellano K E.Estimating True Student Growth Percentile Distributions Using Latent Regression Multidimensional IRT Models.Educational & Psychological Measurement,2016, 77 (6): 917-944.

[17] Torre J, Douglas J A.Higher-order latent trait models for cognitive diagnosis[J].Psychometrika,2004, 69 (3): 333-353.

[18] Chou C Y, Tseng S F, Chih W C, et al.Open Student Models of Core Competencies at the Curriculum Level: Using Learning Analytics for Student Reflection.IEEE Transactions on Emerging Topics in Computing,2017, 5 (1): 32-44.

[19] Zhang D J, Allon G, Mieghem J.Does Social Interaction Improve Learning Outcomes? Field Evidence from Massive Open Online Courses (MOOCs).Social Science Electronic Publishing,2015, Forthcoming (3).

[20] Lei S, Cristea A I, Hadzidedic S. Multifaceted Open Social Learner Modelling[C].The 13th International Conference on Web-based Learning (ICWL2014),2014.

[21] Vinciarelli A, Mohammadi G.A Survey of Personality Computing.IEEE Transactions on Affective Computing,2014, 5(3):273-291.

[22] Halawa M S, Hamed E, Shehab M E. Personalized E-learning recommendation model based on psychological type and learning style models.In:IEEE Seventh International Conference on Intelligent Computing & Information Systems.CAIRO,2016,578-584

[23] Souki A M, Paraskeva F, Alexiou A, et al.Developing personalised e-courses: Tailoring students' learning preferences to a model of self-regulated learning.International Journal of Learning Technology,2015,10(3):188-202.

[24] Hammad R, Odeh M, Khan Z.eLEM: A Novel e-Learner Experience Model.International Arab Journal of Information Technology,2017, 14 (4A): 586-597.

[25] Papamitsiou Z, Economides A A. Student Modeling in Real-Time during Self-Assessment Using Stream Mining Techniques.In:IEEE International Conference on Advanced Learning Technologies.Timisoara,2017,286-290

[26] Sottilare R A. Using Learner Data to Influence Performance during Adaptive Tutoring Experiences.In:HCI International Augmented Cognition Conference.Heraklion,2014,265-275

[27] Thüs, Hendrikchatti, Aminebrandt M, et al. Evolution of Interests in the Learning Context Data Model.Berlin:Springer International Publishing,2015.35-36

[28] Liu H, Zhao W, Liang M: Pedagogical Strategy Model in Adaptive Learning System Focusing on Learning Styles, Zhang X P, Zhong S C, Pan Z G, Wong K, Yun R W,editor,Entert

ainment for Education: Digital Techniques and Systems,2010: 156-164.

[29] Fan X.Item Response Theory and Classical Test Theory: An Empirical Comparison of their Item/Person Statistics.Educational & Psychological Measurement,1998, 58 (3): 357-381.

[30] Hartz M C.A Bayesian Framework for the Unified Model for Assessing Cognitive Abilities: Blending Theory With Practicality.American Journal of Gastroenterology,2002, 95 (4): 906–909.

[31] Leighton J P, Hunka G.The Attribute Hierarchy Method for Cognitive Assessment: A Variation on Tatsuoka\"s Rule-Space Approach.Journal of Educational Measurement,2004, 41 (3): 205-237.

[32] 涂冬波, 蔡艳, 戴海琦, et al.一种多级评分的认知诊断模型:P-DINA 模型的开发.心理学报, 2010, 042 (010): 1011-1020.

[33] 蔡艳, 赵洋, 刘舒畅, et al.一种优化的多级评分认知诊断模型.心理科学,2017 (06): 1491-1497.

[34] 李忧喜, 文益民, 易新河, et al.一种改进的模糊认知诊断模型.数据采集与处理,2017, 032 (005): 958-969.

[35] Yamaguchi K, Okada K.Hybrid cognitive diagnostic model.Behaviormetrika,2020,47:497 -518.

[36] Wang F, Liu Q, Chen E, et al. Neural Cognitive Diagnosis for Intelligent Education Systems.In:Proceedings of the AAAI Conference on Artificial Intelligence.online-only conference,2020,323-333

[37] Shavelson R J.An Approach to Testing & Modeling Competence.SensePublishers,2013.

[38] Decarlo, L. T.On the Analysis of Fraction Subtraction Data: The DINA Model, Classification, Latent Class Sizes, and the Q-Matrix.Applied Psychological Measurement,2011, 35 (1): 8-26.

[39] 吴润泽. 基于认知诊断的学生作答行为建模方法及应用研究[中国科学技术大学博士学位论文]. 合肥:中国科学技术大学,2018,21-25

[40] 宋延文. 基于稳健统计的公路短时交通流组合预测[天津大学硕士学位论文]. 天津:天津大学,2012,30-32

[41] Pardos Z A, Heffernan N T, Ruiz C, et al. The Composition Effect: Conjuntive or Compensatory? An Analysis of Multi-Skill Math Questions in ITS.In:International Conference on Educational Data Mining.Montreal,2008,147-156

[42] Liu Q, Wu R Z, Chen E H, et al.Fuzzy Cognitive Diagnosis for Modelling Examinee Performance.Acm Transactions on Intelligent Systems and Technology,2018, 9 (4).

[43] Klir G J, Yuan B.Fuzzy Sets and Fuzzy Logic: Theory and Applications.Upper Saddle River: Prentice Hall,1995, 13.

[44] De La Torre J.DINA Model and Parameter Estimation: A Didactic.Journal of Educational and Behavioral Statistics,2009, 34 (1): 115-130.

[45] De La Torre J, Douglas J A.Higher-order latent trait models for cognitive diagnosis.Psychometrika,2004, 69 (3): 333-353.

附录 A　攻读学位期间获得的研究成果

[1]王炼红,刘畅,罗志辉.面向慕课学习者评估的认知反应模型[J]，电子学报(已投在审)

[2]王炼红,刘畅,周熊等，基于数据挖掘技术的选课指导探索[J],科研管理,2021.05（已录用）

[3]王炼红,刘畅,周熊,帅智康.基于学习者认知反应模型的认知诊断方法.发明专利202110122198.0，2021.05.07（导师排名第一，本人排名第二，已公布进入实审）

[4]刘畅. 个性化教学辅助系统 V1.0.软件著作权.登记号：2021SR0743812

附录 B　攻读学位期间参加的科研项目

[1]中国高校产学研创新基金重点项目“基于线上线下多模态教育数据挖掘及应用（2019ITA01016）”。

致谢

转眼间，三年的研究生生活就要迎来终点，我也将彻底和“学生”这一身份告别。回望这三年，迷失过方向，经历过失败的尝试，收获过成功的喜悦…其中滋味，唯有亲身经历、时间打磨才能体会。

在这里，首先要感谢湖南大学带给我的这一段宝贵经历，其次要感谢我的导师——王炼红老师，王老师待人亲切、和善，在生活和学习上都给予了我许多帮助。尤其是修改论文，老师耐心负责、严谨认真的态度，是我在以后工作生活中要加倍学习的。其次，感谢实验室的同门周熊，在枯燥的学习生活中能够互相陪伴。感谢师兄杜敏、彭心辰、谢超鹏，师姐李潇瑶、张万红、李梓瑶对我人生规划方面的启发。感谢师妹戴文，师弟罗志辉、王河，有你们的参与，实验室更像一个大家庭，更加温暖。感谢袁礼鹏、付晶、周文亮、田力、徐章胜同学的一路陪伴，以后江湖再见。

求学期间，少了很多与家人的陪伴时光，感谢家人的理解。感谢女朋友王瑞，调剂了我的原本枯燥无味的生活，在我失心灰意的时候尽力安抚我，使我能够继续完成本文的研究。感谢你们！